Proximal Policy Optimization

钟珊珊（学号：22214624）

2023年1月2日

Reinforcement Learning

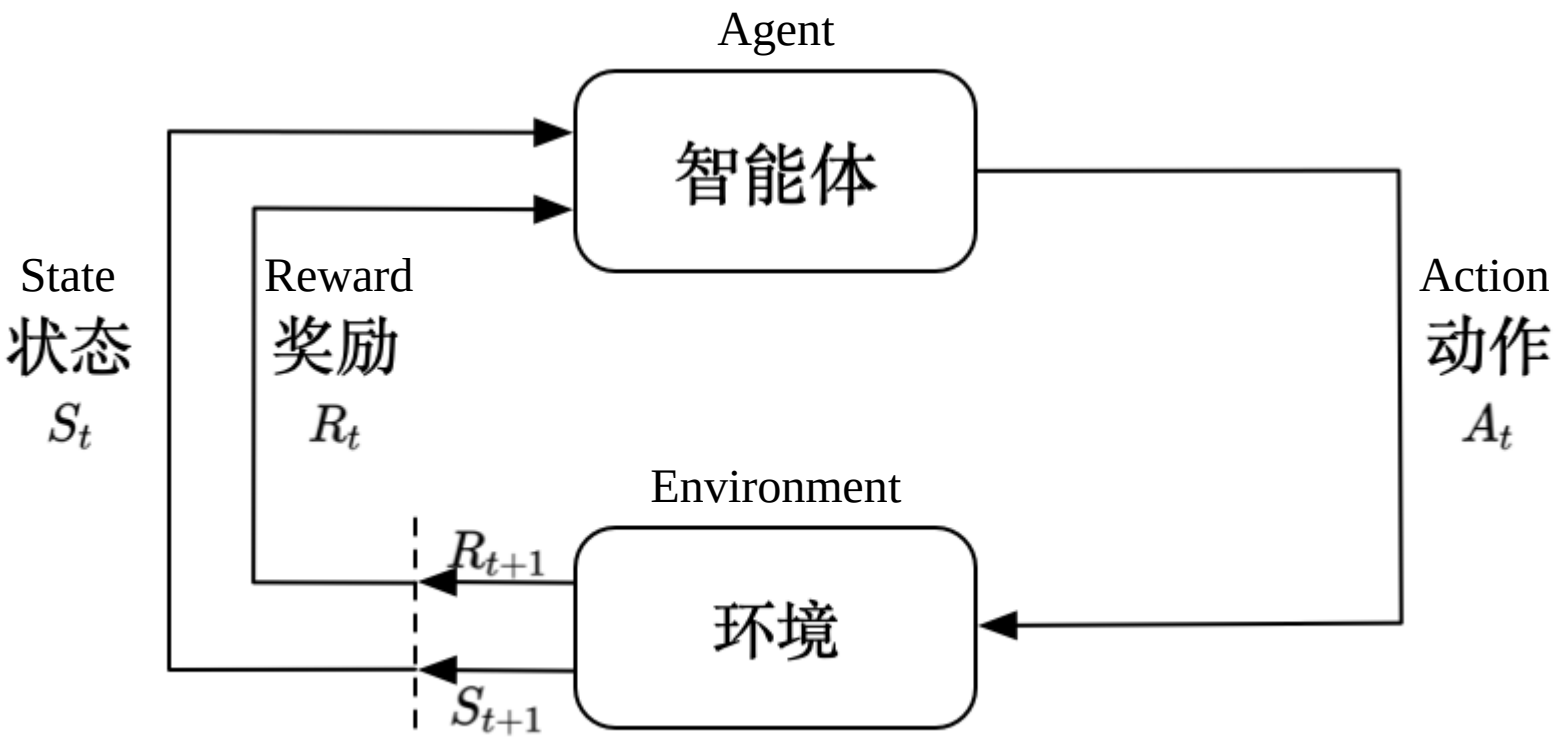

on-policy 到 off-policy

- on-policy：学习到的agent以及和environment进行互动的agent是同一个agent
- off-policy：学习到的agent以及和environment进行互动的agent是不同的agent

为什么要引入 off-policy？

on-policy下，智能体与环境交互以后，接下来就要更新参数。我们只能更新参数一次，然后就要重新采样数据， 才能再次更新参数。这显然是非常花时间的。

怎么让不同agent采集的样本用于训练呢？

Important sampling。

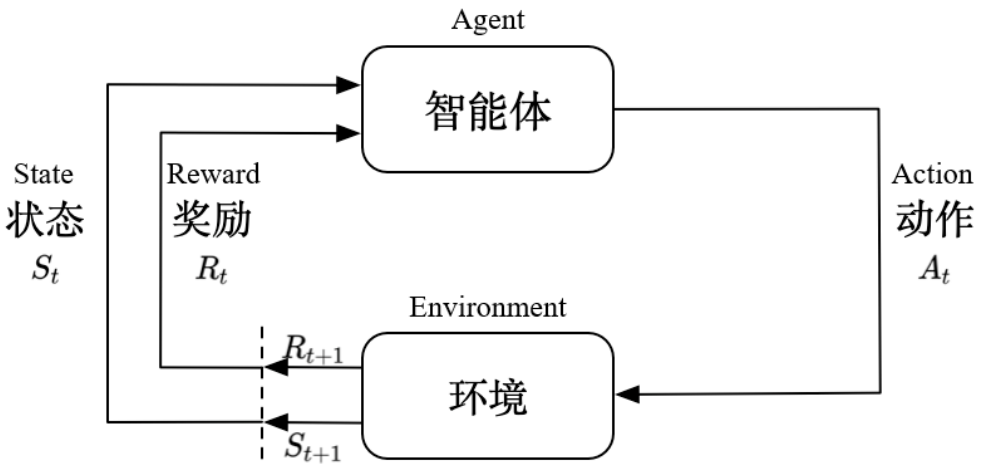

Important Sampling

- 假设我们有一个函数 f(x)，要计算从分布 p 采样 x，再把 x 代入 f，得到 f(x)。我们该怎么计算 f(x) 的期望值呢？

$$\mathbb{E}_{x\sim p}[f(x)] \approx \frac{1}{N}\sum_{i=1}^{N} f(x^i)$$

- 如上式所示，假设我们不能对分布 p 做积分，但可以从分布 p 采样一些数据 x^i。把 x^i 代入 f(x)，取它的平均值，就可以近似 f(x) 的期望值。
- 假设我们不能从分布 p 采样数据，只能从**另外一个分布 q 采样数据x**，q 可以是任何分布。Ex~p[f(x)] 就是 ∫f(x)p(x)dx，我们对其做如下的变换：

$$\int f(x)p(x)\mathrm{d}x = \int f(x)\frac{p(x)}{q(x)}q(x)\mathrm{d}x = \mathbb{E}_{x\sim q}[f(x)\frac{p(x)}{q(x)}]$$

$$\mathbb{E}_{x\sim p}[f(x)] = \mathbb{E}_{x\sim q}\left[f(x)\frac{p(x)}{q(x)}\right]$$

Important Sampling

- 那么important sampling下的方差是否相同？

$$\mathbb{E}_{x\sim p}[f(x)] \approx \frac{1}{N}\sum_{i=1}^{N} f(x^i) \longrightarrow \mathbb{E}_{x\sim p}[f(x)] = \mathbb{E}_{x\sim q}\left[f(x)\frac{p(x)}{q(x)}\right]$$

$$\mathrm{Var}_{x\sim p}[f(x)] = \boxed{\mathbb{E}_{x\sim p}\left[f(x)^2\right]} - \left(\mathbb{E}_{x\sim p}[f(x)]\right)^2$$

$$\mathrm{Var}_{x\sim q}\left[f(x)\frac{p(x)}{q(x)}\right] = \mathbb{E}_{x\sim q}\left[\left(f(x)\frac{p(x)}{q(x)}\right)^2\right] - \left(\mathbb{E}_{x\sim q}\left[f(x)\frac{p(x)}{q(x)}\right]\right)^2$$

$$= \boxed{\mathbb{E}_{x\sim p}\left[f(x)^2\frac{p(x)}{q(x)}\right]} - \left(\mathbb{E}_{x\sim p}[f(x)]\right)^2$$

- 如果$\frac{p(x)}{q(x)}$差距很大，f(x) $\frac{p(x)}{q(x)}$的方差就会很大。

off-policy 的优化目标

- $\bar{R}_\theta = \sum_\tau R(\tau) p_\theta(\tau) = \mathbb{E}_{\tau \sim p_\theta(\tau)}[R(\tau)]$
- $\tau = \{s_1, a_1, s_2, a_2, \cdots, s_t, a_t\}$
- $p_\theta(\tau) = p(s_1)\, p_\theta(a_1|s_1)\, p(s_2|s_1, a_1)\, p_\theta(a_2|s_2)\, p(s_3|s_2, a_2) \cdots$

$$= p(s_1) \prod_{t=1}^{T} p_\theta(a_t|s_t)\, p(s_{t+1}|s_t, a_t)$$

求导

on-policy

$$\nabla \bar{R}_\theta = \sum_\tau R(\tau) \nabla p_\theta(\tau)$$

$$= \sum_\tau R(\tau) p_\theta(\tau) \frac{\nabla p_\theta(\tau)}{p_\theta(\tau)}$$

$$= \sum_\tau R(\tau) p_\theta(\tau) \nabla \log p_\theta(\tau)$$

$$= \mathbb{E}_{\tau \sim p_\theta(\tau)}[R(\tau) \nabla \log p_\theta(\tau)]$$

- $\nabla \bar{R}_\theta = \mathbb{E}_{\tau \sim p_{\theta'}(\tau)} \left[\frac{p_\theta(\tau)}{p_{\theta'}(\tau)} R(\tau) \nabla \log p_\theta(\tau) \right]$

off-policy

Important sampling

off-policy 的优化目标

- $\nabla \bar{R}_\theta = \mathbb{E}_{\tau \sim p_{\theta'}(\tau)} \left[\frac{p_\theta(\tau)}{p_{\theta'}(\tau)} R(\tau) \nabla \log p_\theta(\tau) \right]$
- 实际在做策略梯度的时候，我们并不是给整个轨迹 τ 一样的分数，而是将每一个状态-动作对分开计算，这个计算函数定义为 A^θ。实际更新梯度的过程可写为
- $\mathbb{E}_{(s_t,a_t)\sim\pi_\theta} \left[A^\theta \left(s_t, a_t\right) \nabla \log p_\theta \left(a_t^n | s_t^n\right) \right]$
- 改写成off-policy：
- $\mathbb{E}_{(s_t,a_t)\sim\pi_{\theta'}} \left[\frac{p_\theta \left(s_t, a_t\right)}{p_{\theta'} \left(s_t, a_t\right)} A^\theta \left(s_t, a_t\right) \nabla \log p_\theta \left(a_t^n | s_t^n\right) \right]$
- $\mathbb{E}_{(s_t,a_t)\sim\pi_{\theta'}} \left[\frac{p_\theta \left(a_t | s_t\right)}{p_{\theta'} \left(a_t | s_t\right)} \frac{p_\theta \left(s_t\right)}{p_{\theta'} \left(s_t\right)} A^{\theta'} \left(s_t, a_t\right) \nabla \log p_\theta \left(a_t^n | s_t^n\right) \right]$

off-policy 的优化目标

- $\mathbb{E}_{(s_t,a_t)\sim\pi_{\theta'}}\left[\frac{p_\theta\left(a_t|s_t\right)}{p_{\theta'}\left(a_t|s_t\right)}\frac{p_\theta\left(s_t\right)}{p_{\theta'}\left(s_t\right)}A^{\theta'}\left(s_t,a_t\right)\nabla\log p_\theta\left(a_t^n|s_t^n\right)\right]$
- 最终的优化目标函数：
- $J^{\theta'}\left(\theta\right)=\mathbb{E}_{(s_t,a_t)\sim\pi_{\theta'}}\left[\frac{p_\theta\left(a_t|s_t\right)}{p_{\theta'}\left(a_t|s_t\right)}A^{\theta'}\left(s_t,a_t\right)\right]$

Proximal Policy Optimization

- Loss Function

$$J^{\theta'}(\theta) = \mathbb{E}_{(s_t,a_t)\sim\pi_{\theta'}}\left[\frac{p_\theta(a_t|s_t)}{p_{\theta'}(a_t|s_t)}A^{\theta'}(s_t,a_t)\right]$$

$$J^{\theta'}_{\mathrm{PPO}}(\theta) = J^{\theta'}(\theta) - \beta\mathrm{KL}(\theta,\theta')$$

$$J^{\theta'}_{\mathrm{TRPO}}(\theta) = \mathbb{E}_{(s_t,a_t)\sim\pi_{\theta'}}\left[\frac{p_\theta(a_t|s_t)}{p_{\theta'}(a_t|s_t)}A^{\theta'}(s_t,a_t)\right], \mathrm{KL}(\theta,\theta') < \delta$$

Proximal Policy Optimization

- Adaptive KL Penalty Coefficient

$$J_{\mathrm{PPO}}^{\theta'}(\theta) = J^{\theta'}(\theta) - \beta \mathrm{KL}(\theta, \theta')$$

- 如果 KL(θ, θ′) > KLmax，增大 β
- 如果 KL(θ, θ′) < KLmin，减小 β

Proximal Policy Optimization

- Clipped Surrogate Objective

$$J_{\mathrm{PPO2}}^{\theta^k}(\theta) \approx \sum_{(s_t,a_t)} \min\left(\frac{p_\theta\left(a_t|s_t\right)}{p_{\theta^k}\left(a_t|s_t\right)} A^{\theta^k}\left(s_t,a_t\right),\right.$$
$$\left.\mathrm{clip}\left(\frac{p_\theta\left(a_t|s_t\right)}{p_{\theta^k}\left(a_t|s_t\right)}, 1-\varepsilon, 1+\varepsilon\right) A^{\theta^k}\left(s_t,a_t\right)\right)$$

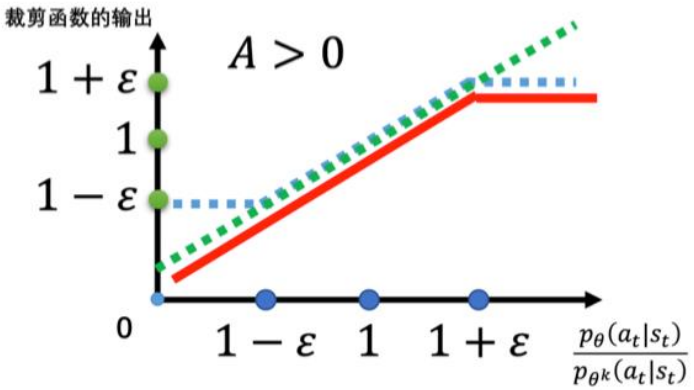

(a) $A > 0$

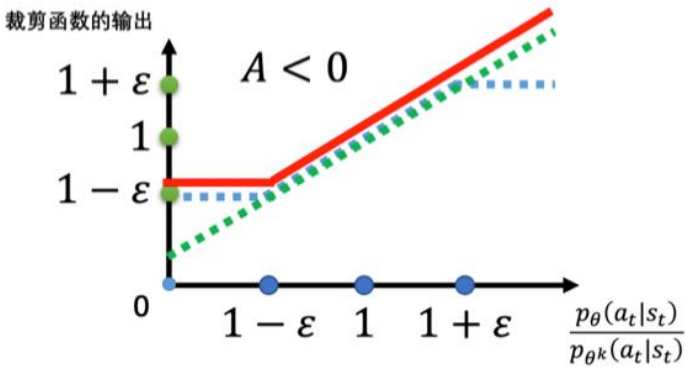

(b) $A < 0$

Proximal Policy Optimization

- Experiments

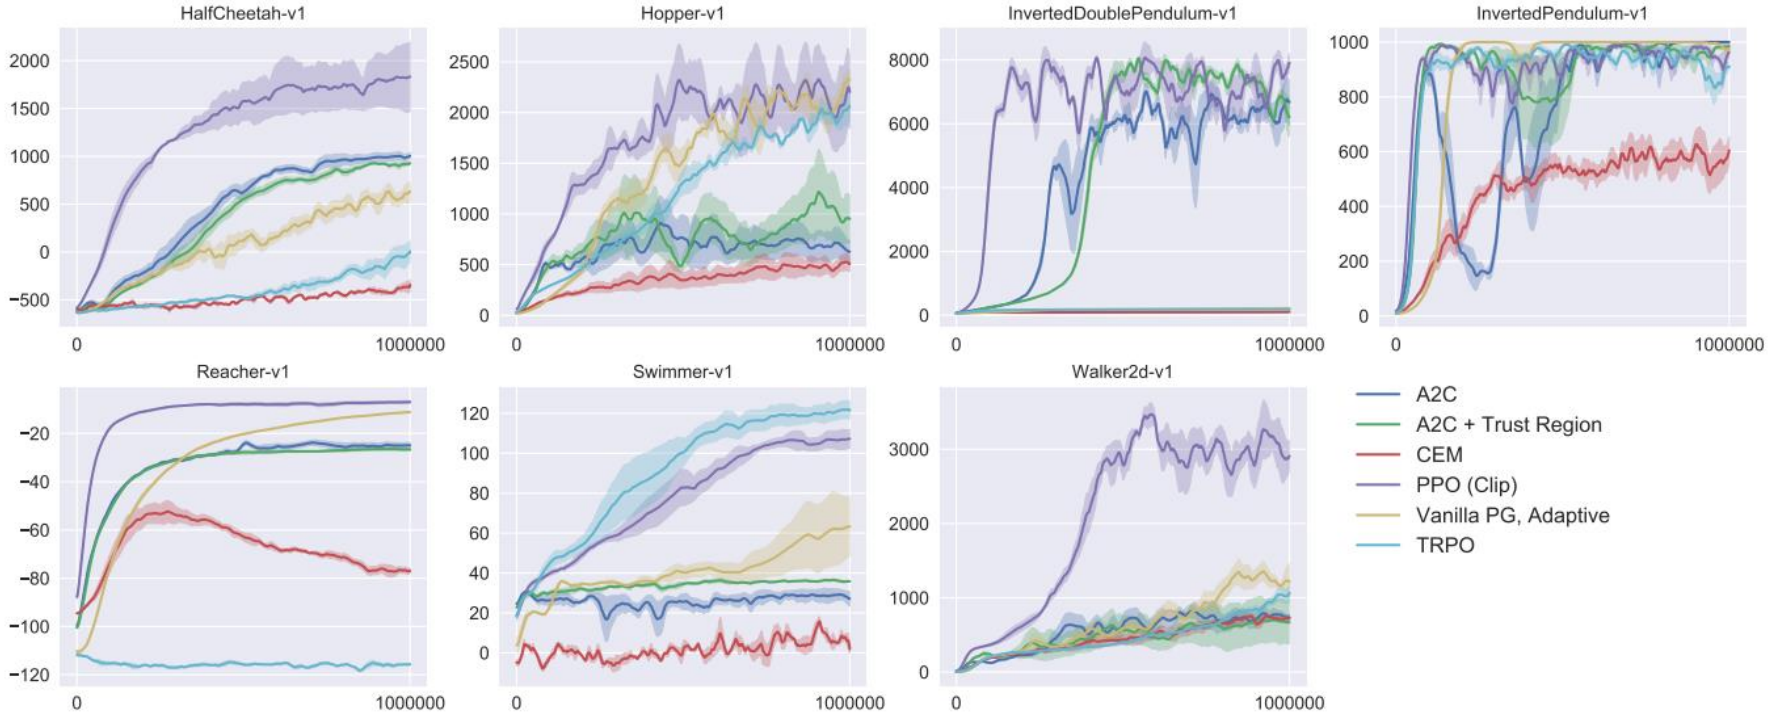

Figure 3: Comparison of several algorithms on several MuJoCo environments, training for one million timesteps.

PPO + Chatbot

- 将 PPO 运 用 在 Machine-Human Chatting Handoff (MHCH)当中。
- MHCH任务如图所示，即判断多轮对话是否需要转人工。输入为多轮对话，输出为handoff label，辅助信息为local sentiment和global satisfaction。

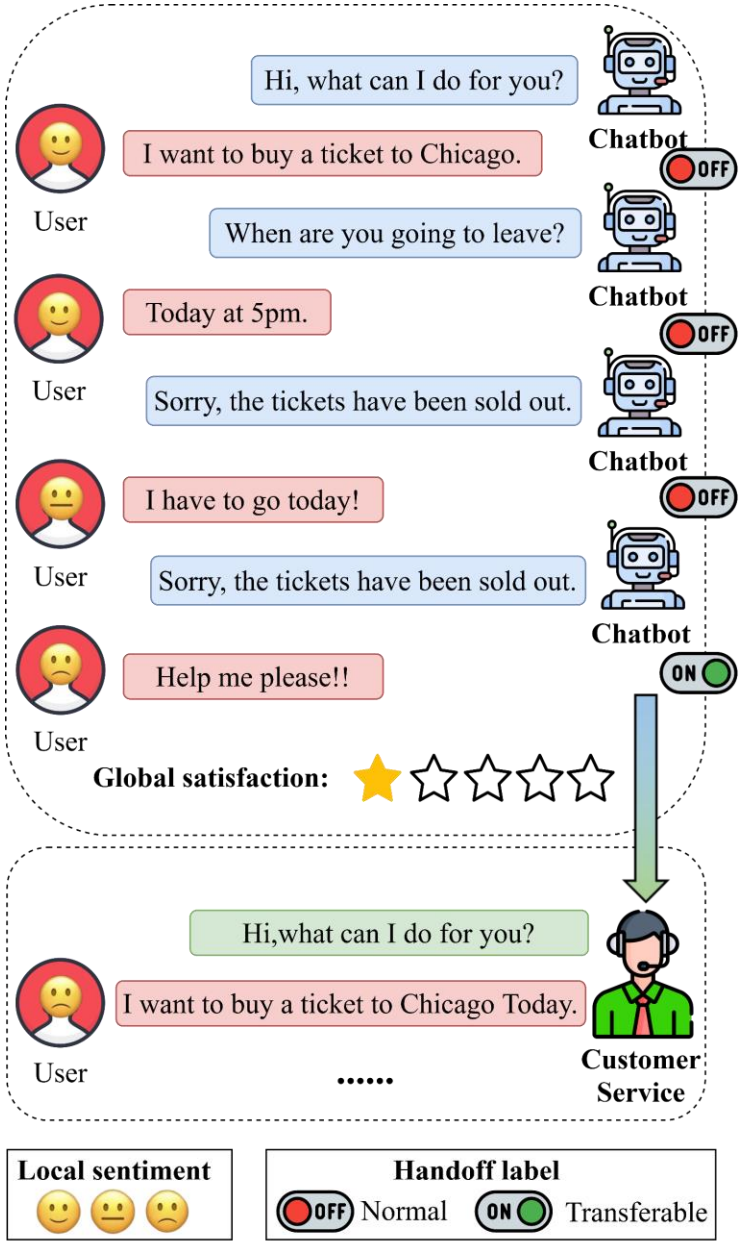

PPO + Chatbot

基于PPO的建模：

- Action：handoff label
- State：对话和local sentiment
- Reward：综合考虑情绪、满意度、服务时间、人工成本和准确度
  - Local sentiment
  - Global satisfaction
  - 服务时间：当前对话所处的相对位置的倒数
  - 人工成本：如果handoff label为1，则reward降低
  - 准确：如果action与handoff label匹配，则reward增加
- Environment：如果action为0，则继续对话；如果action为1，则对话结束

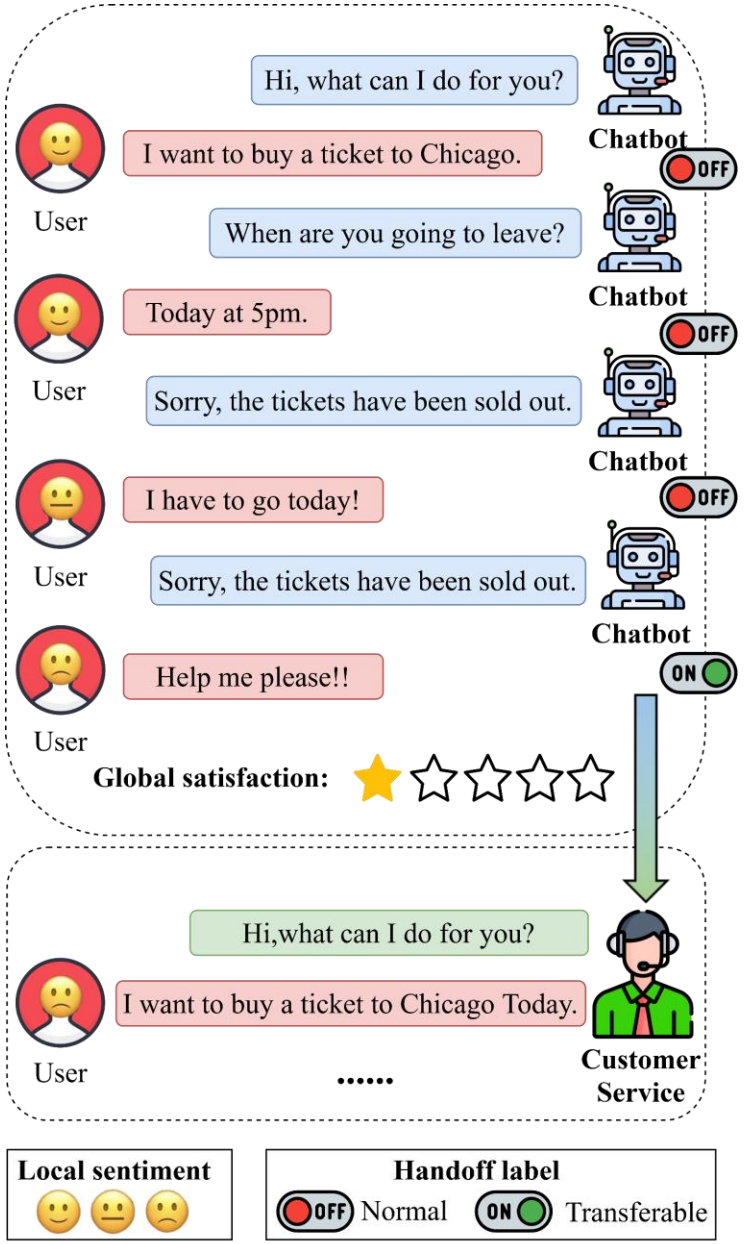

PPO + Chatbot

- 数据集：Makeup (https://github.com/LauJames/RSSN/tree/main/MHCH_SSA/makeup)
- 代码参考：https://github.com/seungeunrho/minimalRL
- 实验结果：

	RSSN [1]	PPO
F1	0.659	0.118
Macro F1	0.815	0.392
GT-I [2]	0.751	0.125
GT-II [2]	0.766	0.196
GT-III [2]	0.776	0.249

[1] Liu J , Song K , Kang Y , et al. A Role-Selected Sharing Network for Joint Machine-Human Chatting Handoff and Service Satisfaction Analysis[C]// 2021.
[2] Liu J , Gao Z , Kang Y , et al. Time to Transfer: Predicting and Evaluating Machine-Human Chatting Handoff[C]// National Conference on Artificial Intelligence. 2021.rvice Satisfaction Analysis[C]// 2021.

总结

- 本次报告从reinforcement learning开始讲起，介绍了reinforcement learning为什么需要从on-policy到off-policy，以及实现on-plicy到off-policy的important sampling，抛出了important sampling存在的问题——即使可以使用不同的分布计算期望，但是不同的分布之间差异不能太大。
- 接着介绍PPO如何控制off-policy下不同agent的分布差异：（1）Adaptive KL Penalty Coefficient引入了KL散度；（2）Clipped Surrogate Objective提出了clip函数。
- 最后，本报告介绍了使用PPO在chatbot领域的实验探索。这是一次失败的探索，原因可能在于reward和environment设计上。从这次实践中，我认识到reinforcement learning并不是一个容易训练好的方法，数据量要足够多才能维护一个好的environment，reward设计主观性也比较强。后续我计划从反事实学习角度来解决chatbot的environment问题。

敬请老师批评指正

钟珊珊（学号：22214624）

2023年1月2日