第二章
贝叶斯分类器

饶洋辉
副教授，计算机学院

课件来源：李航. 统计学习方法. 清华大学深圳研究生院袁春教授讲解材料；吴飞. 人工智能导论：模型与算法

贝叶斯

- 贝叶斯(约1701-1761) Thomas Bayes，英国数学家。约1701年出生于伦敦，做过神甫。1742年成为英国皇家学会会员。1761年4月7日逝世。贝叶斯在数学方面主要研究概率论。他首先将归纳推理法用于概率论基础理论，并创立了贝叶斯统计理论，对于统计决策函数、统计推断、统计的估算等做出了贡献。他死后，理查德·普莱斯(Richard Price)于1763年将他的著作《机会问题的解法》(An essay towards solving a problem in the doctrine of chances)寄给了英国皇家学会，对于现代概率论和数理统计产生了重要的影响。

贝叶斯决策

- 贝叶斯决策就是在不完全情报下，对部分未知的状态用主观概率估计，然后用贝叶斯公式对发生概率进行修正，最后再利用期望值和修正概率做出最优决策。
- 贝叶斯决策理论方法是统计模型决策中的一个基本方法，其基本思想是：
- 1、已知类条件概率密度参数表达式和先验概率。
- 2、利用贝叶斯公式转换成后验概率。
- 3、根据后验概率大小进行决策分类。

条件概率的谬论

- 条件概率的谬论

  假设 P(A|B) 大致等于 P(B|A)

例子：

P(disease) = 1% = 0.01

P(well) = 99% = 0.99

P(negative | disease) = 1%

P(positive | disease) = 99%

P(positive | well) = 1%

P(negative | well) = 99%

? P(disease|positive) = ?

$$p(d|p) = \frac{P(p|d)P(d)}{P(p|w)P(w) + P(p|d)P(d)}$$

$$= \frac{0.99 * 0.01}{0.01 * 0.99 + 0.99 * 0.01}$$

$$= 50\%$$

Problem: if P(d)=0.1% , P(d|p)=?

概率(回顾)

样本空间的划分

定义　设 Ω 为试验E的样本空间, $B_1, B_2, \cdots, B_n$ 为 E 的一组事件, 若

1^0　$B_i B_j = \varnothing, i, j = 1, 2, \cdots, n;$

2^0　$B_1 \cup B_2 \cup \cdots \cup B_n = \Omega,$

则称 $B_1, B_2, \cdots, B_n$ 为样本空间 Ω 的一个划分.

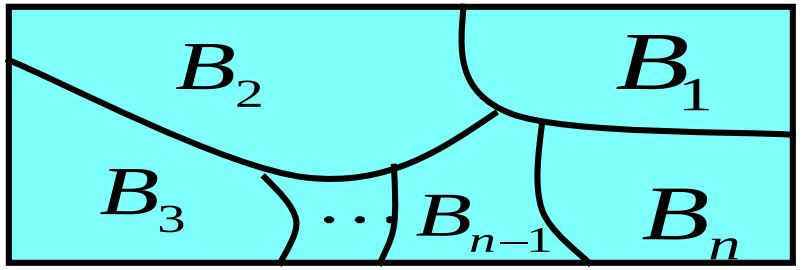

概率(回顾)

全概率公式

定义 设Ω为试验E的样本空间, A为E的事件, $B_1, B_2, \cdots, B_n$为Ω的一个划分, 且$P(B_i) > 0$ $(i = 1, 2, \cdots, n)$, 则

$$\boxed{\begin{aligned} P(A) &= P(A|B_1)P(B_1) + P(A|B_2)P(B_2) \\ &\quad + \cdots + P(A|B_n)P(B_n) \\ &= \sum_{i=1}^{n} P(B)P(A|B_i) \end{aligned}}$$

练习

- What's the value of

$$\sum_G P(G \mid X = \text{boy})$$
$$= P(G = \text{A} \mid X = \text{boy}) + P(G = \text{B} \mid X = \text{boy})$$
$$+ P(G = \text{C} \mid X = \text{boy}) + P(G = \text{D} \mid X = \text{boy})$$

  - 1
  - $P(X=\text{boy})$
  - None of the above

练习

- What's the value of $\sum_G P(G \mid X = \text{boy})$
  - 1
  - $P(X=\text{boy})$
  - None of the above

$$= P(G = \text{A} \mid X = \text{boy}) + P(G = \text{B} \mid X = \text{boy})$$
$$+ P(G = \text{C} \mid X = \text{boy}) + P(G = \text{D} \mid X = \text{boy})$$

练习

- What's the value of

$$\sum_G P(G \mid X = \text{boy})$$
$$= P(G = \text{A} \mid X = \text{boy}) + P(G = \text{B} \mid X = \text{boy})$$
$$+ P(G = \text{C} \mid X = \text{boy}) + P(G = \text{D} \mid X = \text{boy})$$

  - 1
  - $P(X=\text{boy})$
  - None of the above

- Others:

$$\sum_G P(G \mid X = \text{boy}, ID = \text{s})$$
$$= P(G = \text{A} \mid X = \text{boy}, ID = \text{s}) + P(G = \text{B} \mid X = \text{boy}, ID = \text{s})$$
$$+ P(G = \text{C} \mid X = \text{boy}, ID = \text{s}) + P(G = \text{D} \mid X = \text{boy}, ID = \text{s})$$

练习

- 假设有一盒骰子，里面有4面的（点数为1、2、3、4），6面的、8面的、12面的、20面的均匀骰子各1个。如果我随机从盒子中选一个骰子，投掷它得到了点数5。那么我选中的骰子为4面、6面、8面、12面、20面的概率各是多少？

练习

- 假设有一盒骰子，里面有4面的（点数为1、2、3、4），6面的、8面的、12面的、20面的均匀骰子各1个。如果我随机从盒子中选一个骰子，投掷它得到了点数5。那么我选中的骰子为4面、6面、8面、12面、20面的概率各是多少？

$$Pr(\text{骰子}=4\,|\,\text{点数}=5)=\frac{Pr(\text{骰子}=4)Pr(\text{点数}=5\,|\,\text{骰子}=4)}{Pr(\text{点数}=5)}=\frac{0.2\times 0}{Pr(\text{点数}=5)}$$

$$Pr(\text{骰子}=6\,|\,\text{点数}=5)=\frac{Pr(\text{骰子}=6)Pr(\text{点数}=5\,|\,\text{骰子}=6)}{Pr(\text{点数}=5)}=\frac{0.2\times\frac{1}{6}}{Pr(\text{点数}=5)}$$

…

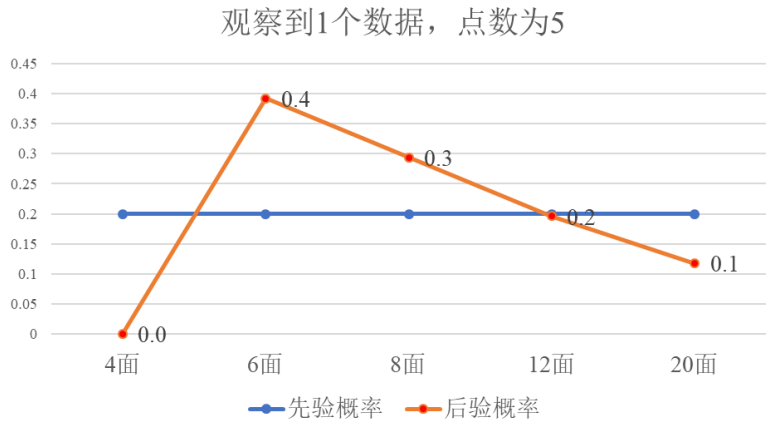

练习

- 假设有一盒骰子，里面有4面的（点数为1、2、3、4），6面的、8面的、12面的、20面的均匀骰子若干个，这些骰子的先验概率分布为(0.1, 0.1, 0.4, 0.2, 0.2)。如果我随机从盒子中选一个骰子，投掷它得到了点数5。那么我下次随机选一个骰子并投掷它得到的点数的概率分布预测是多少？
- 贝叶斯学习 $P(X|d) = \sum_i P(X|d, h_i)P(h_i|d) = \sum_i P(X|h_i)P(h_i|d)$
- 极大似然（Maximum Likelihood） $h_{\mathsf{ML}} = \mathsf{argmax}_h P(d|h)$ $h_{\mathsf{ML}} = \mathsf{argmax}_h \sum_i \log P(d_i|h)$ $P(X|d) \approx P(X|h_{\mathsf{ML}})$ 无法引入先验
- 极大后验（Maximum A Posteriori） $h_{\mathsf{MAP}} = \mathsf{argmax}_h P(h)P(d|h)$ $h_{\mathsf{MAP}} = \mathsf{argmax}_h \log P(h) + \sum_i \log P(d_i|h)$ $P(X|d) \approx P(X|h_{\mathsf{MAP}})$

先验概率分布的影响

- 如何选择先验概率分布？
- 示例：当以边缘转动一元硬币250次之后，得到的结果是：正面140次反面110次。在观察到上述数据的前提下，如何得到以边缘旋转这枚硬币时，正面朝上的后验概率分布？

先验概率分布的影响

- 如何选择先验概率分布？
- 示例：当以边缘转动一元硬币250次之后，得到的结果是：正面140次反面110次。在观察到上述数据的前提下，如何得到以边缘旋转这枚硬币时，正面朝上的后验概率分布？

我们定义一个假设**H**，其中H_x是假设正面朝上的概率为x%，其值从0到100。

如果先验概率为均匀分布，则对所有的x，H_x的概率都是相同的。

似然度为：如果H_x为真，正面朝上的概率为$x/100$，而反面朝上的概率为$1-x/100$。

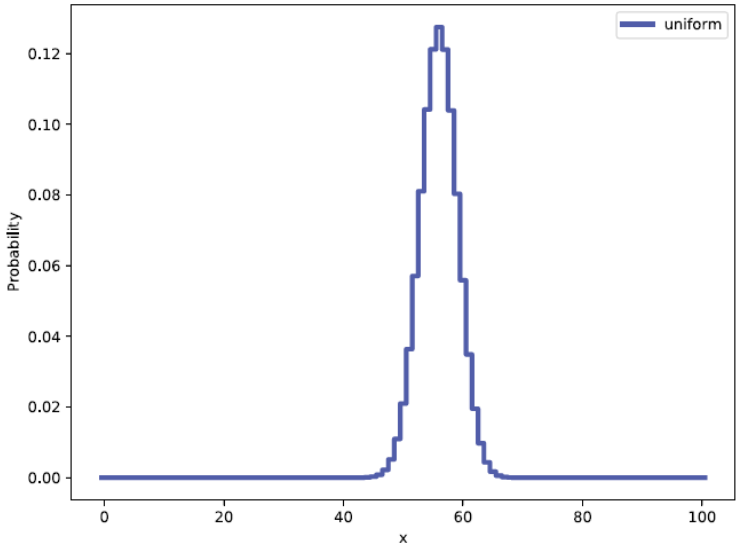

先验概率分布的影响

- 如何选择先验概率分布？
- 示例：当以边缘转动一元硬币250次之后，得到的结果是：正面140次反面110次。在观察到上述数据的前提下，如何得到以边缘旋转这枚硬币时，正面朝上的后验概率分布？

如果构建一个三角形状的先验概率分布，即认为50%附近（硬币是均匀的）有较高概率，而在极端值上的概率较低，如左图所示。两种情况下，后验概率分布的对比如右图所示。

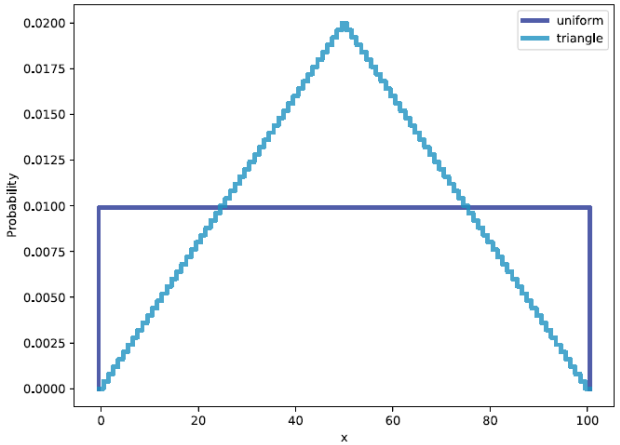

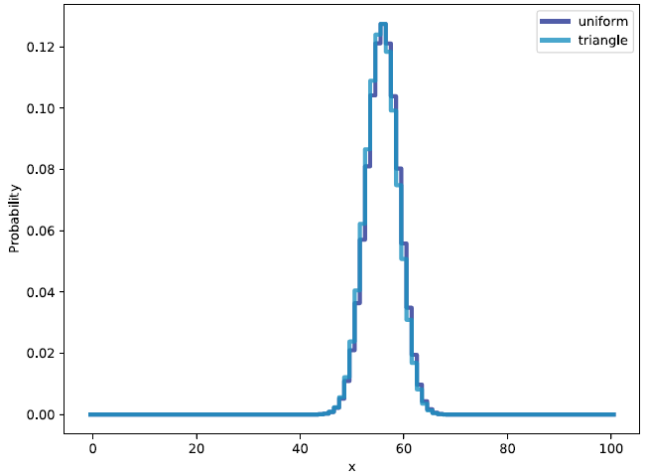

先验概率分布的影响

- 如何选择先验概率分布？
- 示例：当以边缘转动一元硬币250次之后，得到的结果是：正面140次反面110次。在观察到上述数据的前提下，如何得到以边缘旋转这枚硬币时，正面朝上的后验概率分布？

如果构建一个三角形状的先验概率分布，即认为50%附近（硬币是均匀的）有较高概率，而在极端值上的概率较低，如左图所示。两种情况下，后验概率分布的对比如右图所示。

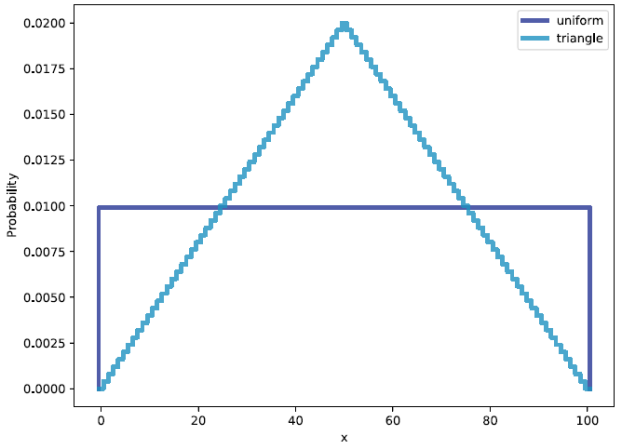

先验概率的湮没：如果有足够的数据，即使在先验概率分布上持有不同观点，人们也会得到趋于收敛的后验概率。

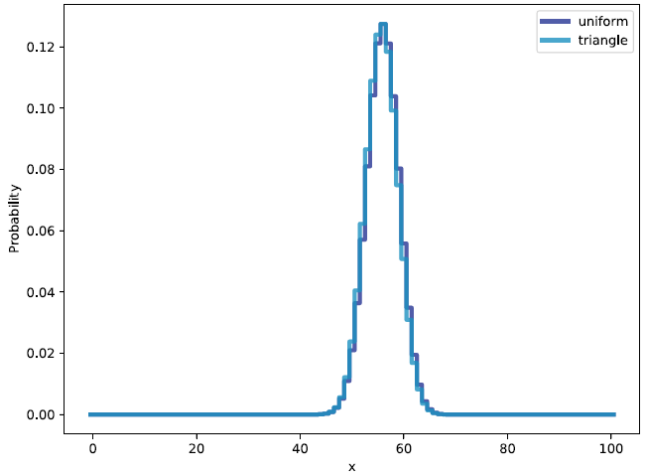

先验概率分布的影响

- 如何选择先验概率分布？
- 示例（对比）：当以边缘转动一元硬币25次之后，得到的结果是：正面14次反面11次。在观察到上述数据的前提下，如何得到以边缘旋转这枚硬币时，正面朝上的后验概率分布？

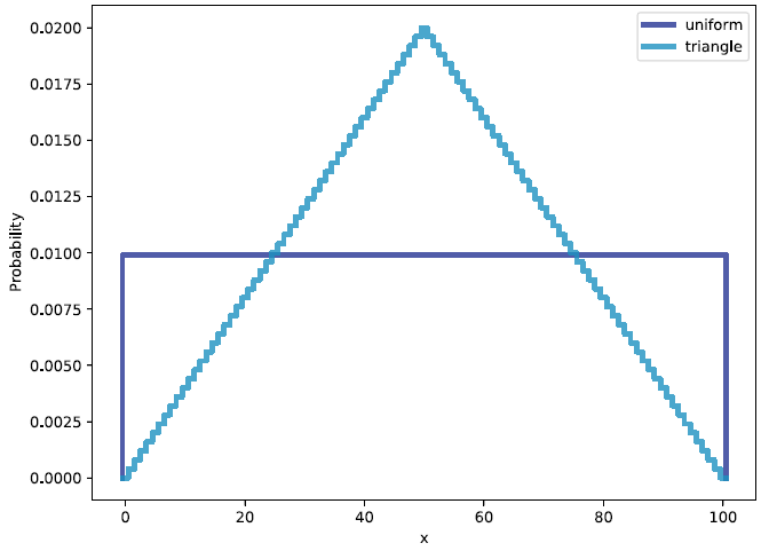

当数据较少时，受先验概率分布的影响较大。

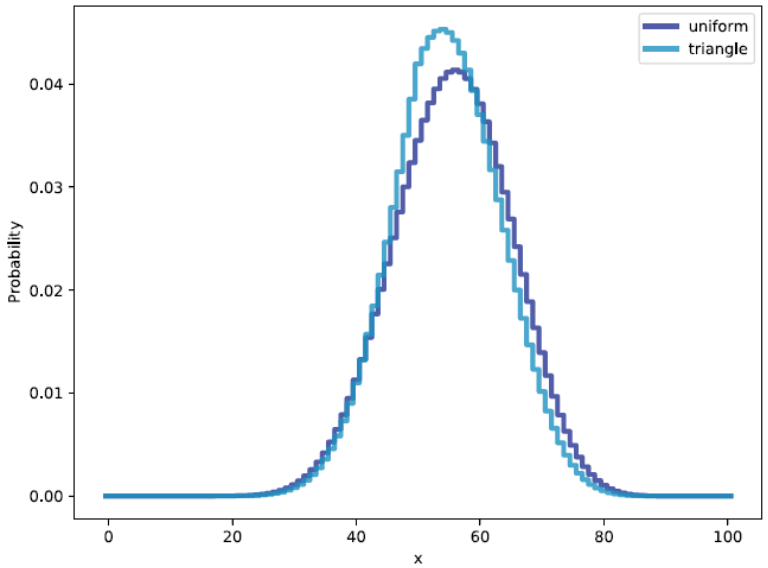

统计建模推断

传统以统计建模为核心的推理手段

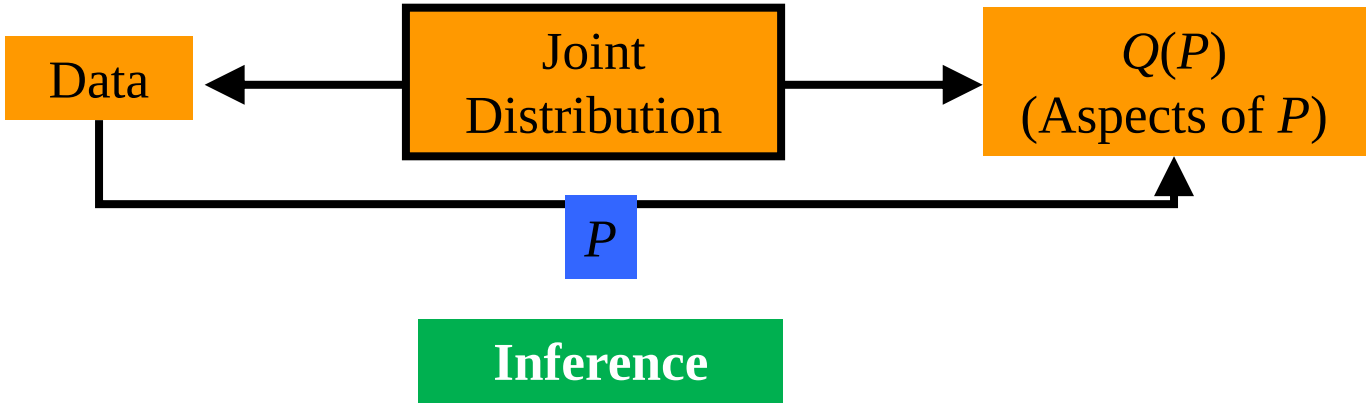

"The object of statistical methods is the reduction of data" (Fisher 1922).

购买了A商品的顾客是否会购买B商品(对A和B的联合分布建模)：$Q = P(B \mid A)$

Judea Pearl，Causality: models, reasoning, and inference (second edition)，Cambridge University Press, 2009
Judea Pearl, Madelyn Glymour, Nicholas P. Jewell, *Causal inference in statistics: a primer*, John Wiley & Sons, 2016

因果推理

从统计建模推断到因果推理

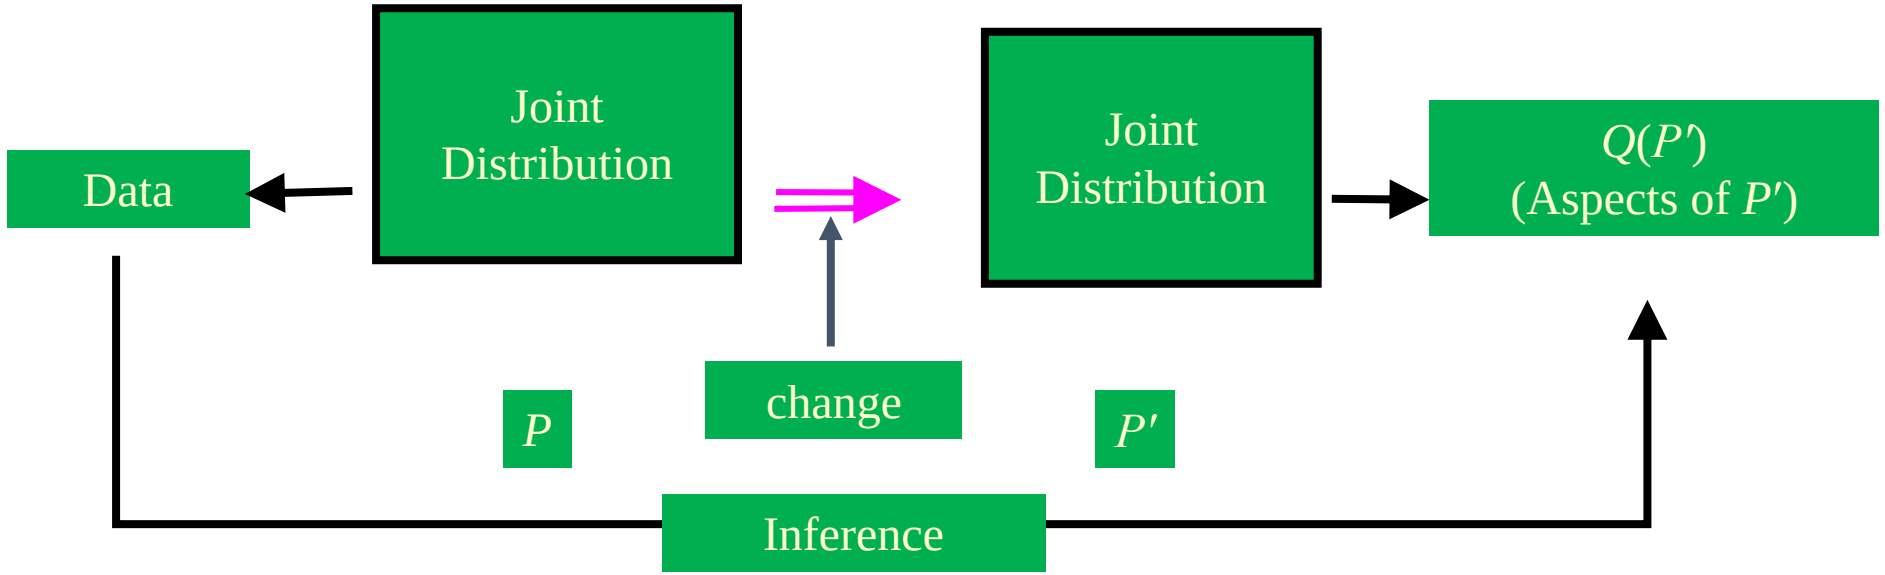

数据分布从 P 变换到 P'

- 如果商品价格涨价一倍，预测销售量P'(sales)的变化
- 如果放弃吸烟，预测癌症P'(cancer) 的概率

因果推理的主要模型

结构因果模型（structural causal model, SCM）：也被称为因果模型（causal model）或Neyman–Rubin因果模型。这一模型最早可追溯于Jerzy Neyman在1923年用波兰语所撰写论文中提出的“潜在结果”（potential outcome）的概念。之后，Donald Rubin发展了“潜在结果”这一概念，并将其和缺失数据的理论联系在一起。

结构因果模型由两组变量集合U和V以及一组函数f组成。其中，f是根据模型中其他变量取值而给V中每一个变量赋值的函数。U中的变量被称为外生变量（exogenous variables），即这些变量处于模型之外，不对其阐述和解释；V中的变量称为内生变量（endogenous variables）。以图中的节点来说明内生变量和外生变量的关系：每一个内生变量都至少是一个外生变量的后代；而每一个外生变量都不是其他外生或内生变量的后代，它们没有祖先，即外生变量都是图中的根节点。如果知道了每一个外生变量的值，就可以使用函数f来计算出每一个内生变量的值。每个结构因果模型M都与一个因果图G相对应。因果图中的节点是结构因果模型中U和V所包括的变量，节点之间的边表示函数f。在M中，若变量X的函数f_x包含了变量Y（X的取值依赖于Y），则在G中有一条从Y到X的有向边。本章主要讨论因果图为有向无环图的结构因果模型。

因果图和贝叶斯网络

- 因果图（causal diagram）：由Judea Pearl于1995年提出。一般而言，因果图是有向无环图（directed acyclic graphs, DAG）。有向无环图指的是一个无回路的有向图，即从图中任意一个节点出发经过任意条边，均无法回到该节点。有向无环图刻画了图中所有节点之间的依赖关系。DAG可用于描述数据的生成机制。这样描述变量联合分布或者数据生成机制的模型，被称为“贝叶斯网络”（Bayesian network）。 不同于一般意义上的因果图，贝叶斯网络并未假设箭头有任何因果意义，这里的箭头仅仅意味着我们知道前向概率，比如P(positive | disease）。

- 贝叶斯网络是由图论和概率论结合而成的描述多元统计关系的模型，它为多个变量间复杂依赖关系的表示提供了统一的框架，具有紧凑有效、简洁直观的特点。

- 由于贝叶斯网络对大规模复杂系统简约而紧凑的表示能力，使其成为人工智能、专家系统、模式识别、数据挖掘和软件测试等领域的研究热点。

因果图模型

结构因果模型中的原因：如果变量X出现在给变量Y赋值的函数中，则X是Y的直接原因(direct cause)。如果X是Y的直接原因或者其他原因，均称X是Y的原因。

因果图中的原因：在因果图中，若变量Y是另一个变量X的孩子，则X是Y的直接原因；若Y是X的后代，则X是Y的潜在原因。

例：假设某一商品销量Z、该商品与其他商品的价格差X以及为该商品促销所支出的广告费Y三个变量所形成的结构因果模型如下表示：

$$U = \{X, Y\}, \qquad V = \{Z\}, \qquad F = \{f_Z\}$$

$$f_Z: Z = 2X + 5Y$$

由于X和Y都出现在函数f_Z中，因此，X和Y都是Z的直接原因。若X和Y有其他祖先，则这些祖先是Z的潜在原因。下图是该结构因果模型所对应的因果图。

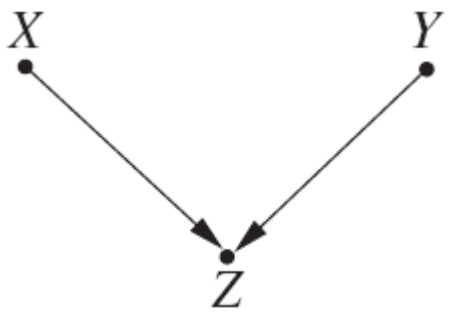

商品销量Z，价格差X和告费Y的因果图

因果图模型

例：当商品销量、价格差和广告费的量化关系无法给出，并含有某些未知因素时，其部分指定的结构因果模型如下：

$$U = \{U_1, U_2, U_3\}, \qquad V = \{X, Y, Z\}, \qquad F = \{f_X, f_Y, f_Z\}$$

$$X = f_X(U_1)$$

$$Y = f_Y(U_2)$$

$$Z = f_Z(X, Y, U_3)$$

其中U_1, U_2, U_3代表某些未知的外生变量，有时又被称为“误差项”（error term）或“忽略因素”（omitted factor）。

因果图中联合概率分布

对于任意的有向无环图模型，模型中d个变量的联合概率分布由每个节点与其父节点之间条件概率$P(child|parents)$的乘积给出：

$$P(x_1, x_2, \cdots, x_d) = \prod_{j=1}^{d} P(x_j | x_{pa(j)})$$

其中，$x_{pa(j)}$表示节点x_j的父节点集合（所有指向x_j的节点）。这里包含了变量之间某种普遍成立的独立性假设。

对于一个简单的链式图$X \to Y \to Z$，其联合概率分布可直接写成：

$$P(X = x, Y = y, Z = z) = P(X = x)P(Y = y|X = x)P(Z = z|Y = y)$$

因果图中联合概率分布

例： 考虑链式图$X \to Y \to Z$，其中X表示气候好，Y表示水果产量高，Z表示水果价格低，给出P(气候好，水果产量高，水果价格低)的联合概率。

解： 使用乘积分解规则，将P(气候好，水果产量高，水果价格低)转换为：
P(气候好) P(水果产量高|气候好) P(水果价格低|水果产量高)

根据常识，假设P(气候好) $= 0.5$，当然也可设置为更低或更高的取值。类似地，在气候好的时候水果应该生长得比较好，产量会比较高，因此假设P(水果产量高|气候好) $= 0.8$。同样，由于市场机制，水果产量高的时候，水果价格会比较低，设P(水果价格低|水果产量高) $= 0.9$。因此计算出P(气候好，水果产量高，水果价格低)$=$ P(气候好) P(水果产量高|气候好) P(水果价格低|水果产量高) $= 0.5 \times 0.8 \times 0.9 = 0.36$。

因果图中联合概率分布

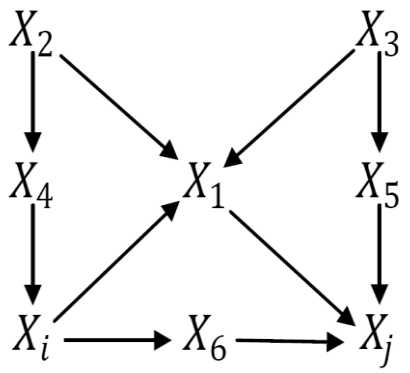

$$P\left(X_1, X_2, X_3, X_4, X_5, X_6, X_i, X_j\right)$$
$$= P(X_2) \times P(X_3) \times P(X_1|X_2, X_3, X_i) \times P(X_4|X_2) \times P(X_5|X_3)$$
$$\times P(X_6|X_i) \times P(X_i|X_4) \times P(X_j|X_1, X_5, X_6)$$

因果图基本结构：链结构

链(chain)：链是因果图的一种基本结构。它包含三个节点两条边，其中一条边由第一个节点指向第二个节点，另一条边由第二个节点指向第三个节点。

例 考虑如下的结构因果模型：

$U = \{U_1, U_2, U_3\}, \qquad V = \{X, Y, Z\}, \qquad F = \{f_X, f_Y, f_Z\}$

$$f_X: X = U_1$$
$$f_Z: Z = 3X + 10 + U_2$$
$$f_Y: Y = 5Z + U_3$$

$$P(X,Y|Z) = \frac{P(X,Y,Z)}{P(Z)} = \frac{P(X)P(Z|X)P(Y|Z)}{P(Z)}$$
$$= P(X|Z)P(Y|Z)$$

即在链式图$X \to Z \to Y$中，X和Y在给定Z时条件独立。其中，上式的第一步使用了条件概率的定义，第二步使用了乘积分解规则，最后一步使用了贝叶斯公式$P(X)P(Z|X) = P(Z)P(X|Z) = P(X,Z)$。

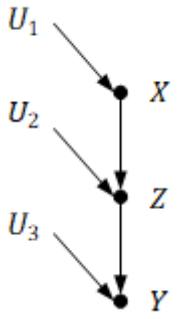

链式因果图

因果图基本结构：链结构

链式图$X \to Z \to Y$中，X和Y在给定Z时条件独立也可以这样理解：在给定Z时，若X的取值发生变化，则为了维持Z的取值不变，U_2的取值会发生变化；而由于Y的取值只依赖于Z和U_3，但Z是给定的，因此Y的取值不会发生变化。也就是说，给定Z时，X的取值不会影响Y的取值，因此给定Z时，Y和X是条件独立的。

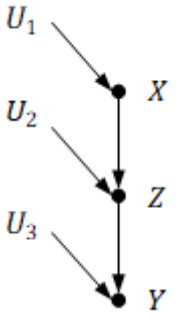

链式因果图

因果图基本结构：链结构

定理 (链中的条件独立性) 对于变量X和Y，若X和Y之间只有一条单向的路径，变量Z是截断(intercept)该路径的集合中的任一变量，则在给定Z时，X和Y条件独立。

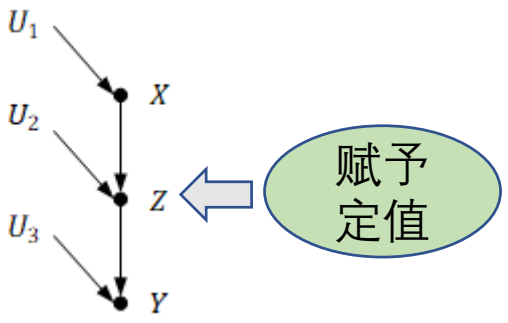

链式因果图

因果图基本结构：分连

分连(fork): 分连也是因果图的一种基本结构。它包含三个节点两条边，两条边分别由第一个节点指向第二个节点和第三个节点。

例 考虑如下的结构因果模型：

$$U = \{U_1, U_2, U_3\}, \qquad V = \{X, Y, Z\},$$

$$F = \{f_X, f_Y, f_Z\}$$

$$f_Z\colon Z = U_1$$

$$f_X\colon X = 3Z + 7 + U_2$$

$$f_Y\colon Y = 6Z + U_3$$

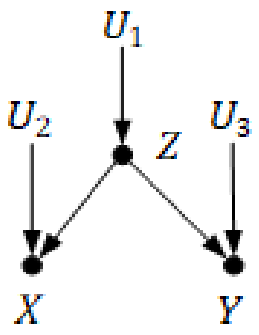

分连因果图

因果图基本结构：分连

在分连结构中，给定Z时，X和Y的联合概率：

$$P(X,Y|Z)=\frac{P(X,Y,Z)}{P(Z)}=\frac{P(Z)P(X|Z)P(Y|Z)}{P(Z)}$$

$$=P(X|Z)P(Y|Z)$$

即在分连图$X\leftarrow Z\rightarrow Y$中，$X$和$Y$在给定$Z$时条件独立。上式的第一步使用了条件概率的定义，第二步使用了乘积分解规则。

在分连图$X\leftarrow Z\rightarrow Y$中，$X$和$Y$在给定$Z$时条件独立可以这样理解：若给定$Z$，$Y$和$X$的取值不会变化，它们的值只会分别随$U_3$和$U_2$变化，因此给定$Z$时，$Y$和$X$是条件独立的。

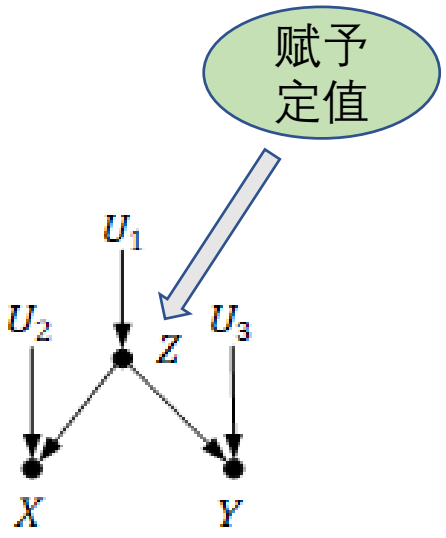

分连因果图

因果图基本结构：分连

定理（分连中的条件独立性）若变量Z是变量X和Y的共同原因，且X到Y只有一条路径，则在给定Z时，X和Y条件独立。

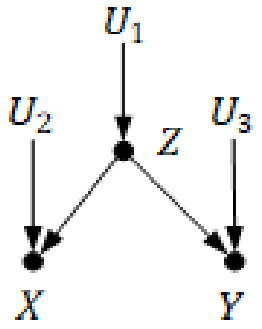

分连因果图

因果图基本结构：汇连

汇连(collider): 汇连(又叫碰撞)也是因果图的一种基本结构。它包含三个节点两条边，

两条边分别由第一个节点和第二个节点指向第三个节点。

例 考虑如下的结构因果模型：

$U = \{U_1, U_2, U_3\}, \qquad V = \{X, Y, Z\},$

$F = \{f_X, f_Y, f_Z\}$

$f_X: X = U_1$

$f_Y: Y = U_2$

$f_Z: Z = X + Y + U_3$

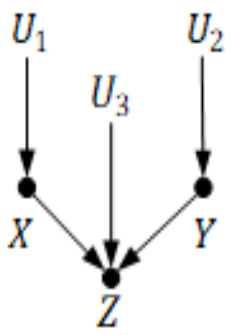

汇连因果图

因果图基本结构：汇连

在汇连结构中，给定Z时，X和Y的联合概率：

$$P(X,Y|Z)=\frac{P(X,Y,Z)}{P(Z)}=\frac{P(X)P(Y)P(Z|X,Y)}{P(Z)}\neq P(X|Z)P(Y|Z)$$

即在汇连图$X\rightarrow Z\leftarrow Y$中，$X$和$Y$在给定$Z$时条件相关。上式的第一步使用了条件概率的定义，第二步使用了乘积分解规则。

在汇连图$X\rightarrow Z\leftarrow Y$中，$X$和$Y$在给定$Z$时条件相关可以这样理解：给定$Z$，当$X$的取值发生变化时，为了保证$Z$的取值不变，$Y$的取值也一定会发生变化，因而给定$Z$时，$Y$和$X$是相关的。设例2.24中的$Z=10$，$U_3=1$，当$X$取值为3时，$Y$的取值为6；当$X$的取值为4时，$Y$的取值为5；当$X$取值为8时，$Y$的取值为1。也就是说，给定$Z$时，$Y$的取值会随$X$的取值变化而变化，因此，给定$Z$时，$Y$和$X$是相关的。

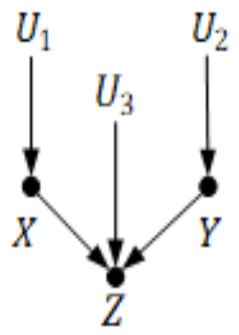

汇连因果图

因果图基本结构：汇连

定理 (汇连中的条件独立性) 若变量Z是变量X和Y的汇连节点，且X到Y只有一条路径，则X和Y相互独立，但在给定Z或Z的后代时，X和Y是相关的。

对于定理中，给定Z的后代，X和Y是相关的，可以这样理解：不妨设Z的某个后代为W，给定W时，则W的祖先也给定，W的祖先给定时，则W的祖先的祖先也给定……因为Z是W的祖先，因此Z也会给定，此时，X和Y是相关的。

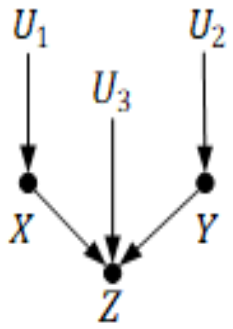

汇连因果图

信息论相关概念

阻塞：一条路径被结点集 F 阻塞，是指在路径上存在一个结点 Z 满足下面三种情形之一：

(1) Z∈ F，并且路径中有一条有向弧指向 Z，另一条有向弧源自 Z；

(2)Z∈ F，并且路径中有两条有向弧源自 Z；

(3) Z 及 Z 的所有后继结点都不在 F 中，并且路径中有两条有向弧指Z。

信息论相关概念

阻塞:

$X = \{X_2\}$和$Y = \{X_3\}$被$Z = \{X_1\}$所分割。路径$X_2 \leftarrow X_1 \rightarrow X_3$被$X_1 \in Z$阻塞；同时路径$X_2 \rightarrow X_4 \leftarrow X_3$也被阻塞,因为$X_4$及它的所有子孙都不在Z中。

然而，X和Y没有被$Z = \{X_1, X_5\}$所分割，因为X_4的子孙X_5在Z中，路径$X_2 \rightarrow X_4 \leftarrow X_3$由于$X_5$的作用而连通。

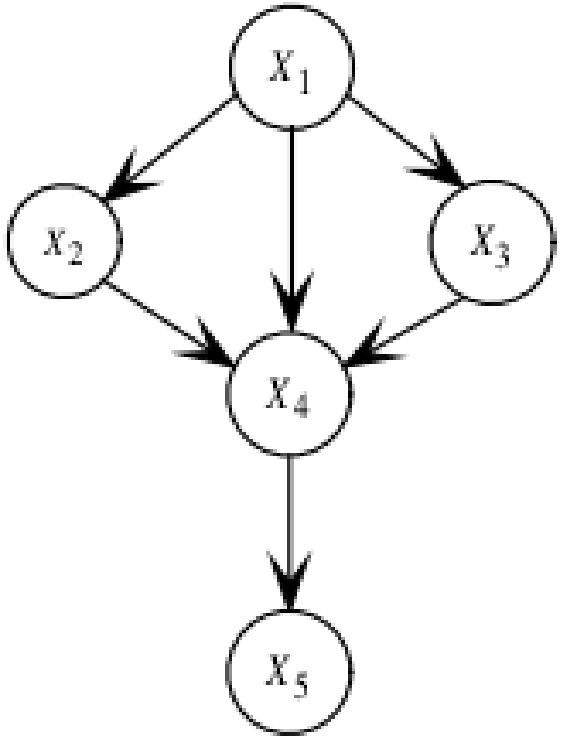

信息论相关概念

d-separation：令 X，Y 和 Z 是一个有向无环图 G 中三个不相交节点的子集，如果在集合 X 和 Y 中所有节点间的所有路径都被集合 Z 所阻塞，则称集合 X 和 Y 被 Z 集合 d-separation，表示为<X,Y|Z>G，也称 Z为 A 和 B 的切割集。否则，称在给定集合 Z 下集合 X 和 Y 图形依赖。

I-map：假设 G 是以随机变量 $Y_1, Y_2, \ldots, Y_n$ 为节点的一个有向无环图，P 是随机变量 $Y_1, Y_2, \ldots, Y_n$的联合概率函数，如果从图 G 中得到的每一个独立性假设(Y_i在给定其父母节点变量的情况下独立于它的非后代节点)在联合概率 P 的计算中都成立，则称 G 是该概率分布 P 的一个独立映射(Independence-map, I-map)。

贝叶斯网络示例 11

$P(H=y)=0.2$ 1

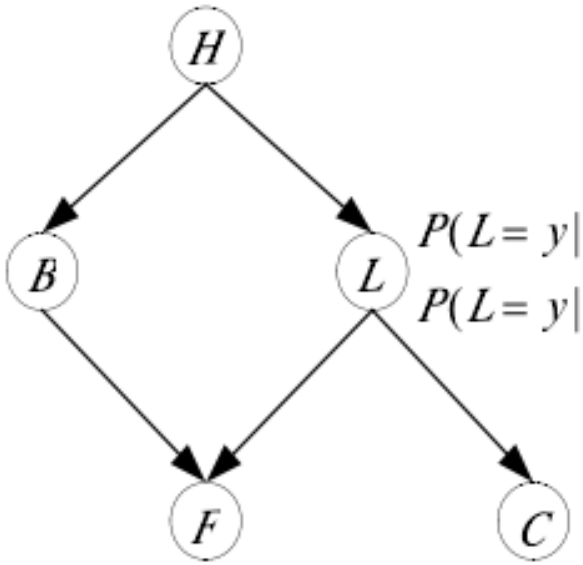

2

$P(B=y \mid H=y)=0.25$

$P(B=y \mid H=n)=0.05$

2

$P(L=y \mid H=y)=0.003$

$P(L=y \mid H=n)=0.00005$

4

$P(F=y \mid B=y, L=y)=0.75$

$P(F=y \mid B=y, L=n)=0.1$

$P(F=y \mid B=n, L=y)=0.5$

$P(F=y \mid B=n, L=n)=0.05$

2

$P(C=y \mid L=y)=0.6$

$P(C=y \mid L=n)=0.02$

贝叶斯网络参数估计

- N个变量的Bayesian Network (BN)：$X = \{x_1, x_2, \ldots, x_n\}$
- 变量x_i有r_i个取值
- 父节点$pa(x_i)$有q_i个取值
- 网络参数：

$$\theta = \{\theta_{ijk} | i = 1, \ldots, n; j = 1, \ldots, q_i; k = 1, \ldots, r_i\}$$

$$\theta_{ijk} = P(x_i = k \mid pa(x_i) = j)$$

$$l(\theta \mid D) = \log L(\theta \mid D) = \log \prod_{t=1}^{m} P(d_t \mid \theta) = \sum_{i=1}^{n} \sum_{j=1}^{q_i} \sum_{k=1}^{r_i} m_{ijk} \log \theta_{ijk}$$

m_{ijk} 是数据 D 中满足 $x_i = k$ 和 $pa(x_i) = j$ 的样本的数量

- 极大似然估计：$\theta^*_{ijk} = m_{ijk} \Big/ \sum_{k=1}^{r_i} m_{ijk}$

极大似然估计

- 某超市销售的糖果有2种口味（*cherry*和*lime*）
- 假设尝到*c*颗*cherry*口味的和*l*颗*lime*口味的
- 记上述观察到的数据为*d*

$Pr(F = cherry)$
θ

$$Pr(d \mid h_\theta) = \theta^c (1-\theta)^l$$

$$\log Pr(d \mid h_\theta) = c \log \theta + l \log(1-\theta)$$

$$d\left(\log Pr(d \mid h_\theta)\right) / d\theta = c/\theta - l/(1-\theta)$$

$$c/\theta - l/(1-\theta) = 0 \;\Rightarrow\; \theta = c/(c+l)$$

S. Russell, P. Norvig. *Artificial Intelligence: A Modern Approach*. 3rd edition, Prentice Hall, 2009.

极大似然估计

- 某超市销售的糖果有2种口味（*cherry*和*lime*），包装纸的颜色分为绿色和红色
- 糖果的口味决定了包装纸的颜色
- 假设尝到c颗*cherry*口味的（其中g_c颗为绿色包装纸，r_c颗为红色包装纸），以及l颗*lime*口味的（其中g_l颗为绿色包装纸，r_l颗为红色包装纸）

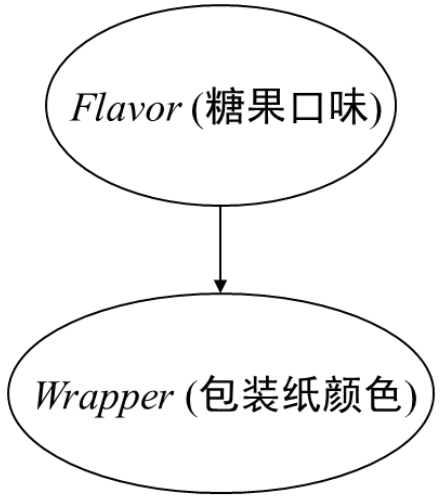

$Pr(F = cherry)$
θ

F	$Pr(W = red \mid F)$
c	θ_1
l	θ_2

$$Pr(d \mid h_{\theta,\theta_1,\theta_2}) = \theta^c \theta_1^{r_c} (1-\theta_1)^{g_c} (1-\theta)^l \theta_2^{r_l} (1-\theta_2)^{g_l}$$

$$c/\theta - l/(1-\theta) = 0 \;\Rightarrow\; \theta = c/(c+l)$$

$$r_c/\theta_1 - g_c/(1-\theta_1) = 0 \;\Rightarrow\; \theta_1 = r_c/(r_c+g_c)$$

$$r_l/\theta_2 - g_l/(1-\theta_2) = 0 \;\Rightarrow\; \theta_2 = r_l/(r_l+g_l)$$

S. Russell, P. Norvig. *Artificial Intelligence: A Modern Approach*. 3rd edition, Prentice Hall, 2009.

贝叶斯网络的应用

- (1) 故障诊断 (diagnose)
- (2) 专家系统 (expert system)
- (3) 规划 (planning)
- (4) 学习 (learning)
- (5) 分类 (classification)

朴素贝叶斯分类器

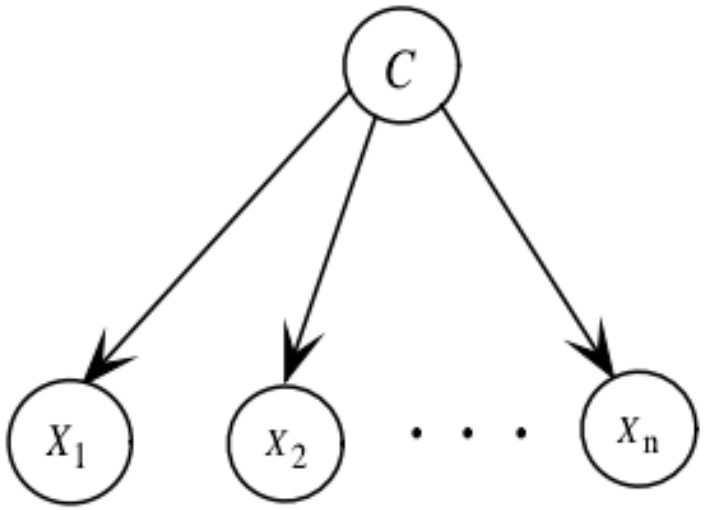

$$C^* = \arg\max P(c|x_1, x_2, \cdots, x_n) = \arg\max \prod_{i=1}^{n} P(x_i|c)P(c)$$

朴素贝叶斯分类器

- 训练数据集： $T=\{(x_1,y_1),(x_2,y_2),\cdots,(x_N,y_N)\}$

- 由X和Y的联合概率分布$P(X,Y)$独立同分布产生

- 朴素贝叶斯通过训练数据集学习联合概率分布$P(X,Y)$
  - 即先验概率分布： $P(Y=c_k),\quad k=1,2,\cdots,K$
  - 及条件概率分布：

$$P(X=x|Y=c_k)=P(X^{(1)}=x^{(1)},\cdots,X^{(n)}=x^{(n)}|Y=c_k),\quad k=1,2,\cdots,K$$

  - 注意：条件概率为指数级别的参数： $K\prod_{j=1}^{n}S_j$ 第j个属性的参数个数Sj

朴素贝叶斯分类器

- 条件独立性假设： $P(X=x|Y=c_k)=P(X^{(1)}=x^{(1)},\cdots,X^{(n)}=x^{(n)}|Y=c_k)$

$$=\prod_{j=1}^{n}P(X^{(j)}=x^{(j)}|Y=c_k)$$

- “朴素”贝叶斯名字由来，牺牲分类准确性。

- 贝叶斯定理： $$P(Y=c_k|X=x)=\frac{P(X=x|Y=c_k)P(Y=c_k)}{\sum_k P(X=x|Y=c_k)P(Y=c_k)}$$

- 代入上式： $$P(Y=c_k|X=x)=\frac{P(Y=c_k)\prod_j P(X^{(j)}=x^{(j)}|Y=c_k)}{\sum_k P(Y=c_k)\prod_j P(X^{(j)}=x^{(j)}|Y=c_k)}$$

朴素贝叶斯分类器

- 朴素贝叶斯分类器可表示为：

$$y = f(x) = \arg\max_{c_k} \frac{P(Y = c_k) \prod_j P(X^{(j)} = x^{(j)} | Y = c_k)}{\sum_k P(Y = c_k) \prod_j P(X^{(j)} = x^{(j)} | Y = c_k)}$$

- 分母对所有c_k都相同：

$$y = \arg\max_{c_k} P(Y = c_k) \prod_j P(X^{(j)} = x^{(j)} | Y = c_k)$$

后验概率最大化的含义

- 朴素贝叶斯法将实例分到后验概率最大的类中，等价于期望风险最小化
- 假设选择0-1损失函数：$f(X)$为决策函数

$$L(Y, f(X)) = \begin{cases} 1, & Y \neq f(X) \\ 0, & Y = f(X) \end{cases}$$

- 期望风险函数：$R_{\exp}(f) = E[L(Y, f(X))]$
- 取条件期望：$R_{\exp}(f) = E_X \sum_{k=1}^{K} [L(c_k, f(X))] P(c_k|X)$

后验概率最大化的含义

- 只需对X=x逐个极小化，得：

$$
\begin{aligned}
f(x) &= \arg\min_{y\in\mathcal{Y}} \sum_{k=1}^{K} L(c_k, y) P(c_k|X=x) \\
&= \arg\min_{y\in\mathcal{Y}} \sum_{k=1}^{K} P(y \neq c_k|X=x) \\
&= \arg\min_{y\in\mathcal{Y}} (1 - P(y = c_k|X=x)) \\
&= \arg\max_{y\in\mathcal{Y}} P(y = c_k|X=x)
\end{aligned}
$$

- 推导出后验概率最大化准则：$f(x) = \arg\max_{c_k} P(c_k|X=x)$

朴素贝叶斯分类器的参数估计

- 应用极大似然估计法估计相应的概率
- 先验概率$P(Y=c_k)$的极大似然估计是：$P(Y=c_k)=\dfrac{\sum_{i=1}^{N} I(y_i=c_k)}{N}, \quad k=1,2,\cdots,K$

- 设第j个特征$x^{(j)}$可能取值的集合为：$\{a_{j1},a_{j2},\cdots,a_{jS_j}\}$
- 条件概率的极大似然估计：

$$P(X^{(j)}=a_{jl}|Y=c_k)=\frac{\sum_{i=1}^{N} I(x_i^{(j)}=a_{jl},y_i=c_k)}{\sum_{i=1}^{N} I(y_i=c_k)}$$

$$j=1,2,\cdots,n; \quad l=1,2,\cdots,S_j; \quad k=1,2,\cdots,K$$

朴素贝叶斯分类器的参数估计

- 学习与分类算法Naïve Bayes Algorithm
- 输入：
  - 训练数据集 $T=\{(x_1,y_1),(x_2,y_2),\cdots,(x_N,y_N)\}$
  - 第*i*个样本的第*j*个特征为 $x_i^{(j)}$ $\quad x_i=(x_i^{(1)},x_i^{(2)},\cdots,x_i^{(n)})^{\mathrm{T}}$
  - 第*j*个特征可能取的第*l*个值为 a_{jl} $\quad x_i^{(j)}\in\{a_{j1},a_{j2},\cdots,a_{jS_j}\}$
- 输出：
  - *x*的分类 $y_i\in\{c_1,c_2,\cdots,c_K\}$

朴素贝叶斯分类器的参数估计

- 步骤
  - 1、计算先验概率和条件概率

$$P(Y=c_k)=\frac{\sum_{i=1}^{N} I(y_i=c_k)}{N}, \quad k=1,2,\cdots,K$$

$$P(X^{(j)}=a_{jl}|Y=c_k)=\frac{\sum_{i=1}^{N} I(x_i^{(j)}=a_{jl}, y_i=c_k)}{\sum_{i=1}^{N} I(y_i=c_k)}$$

$$j=1,2,\cdots,n; \quad l=1,2,\cdots,S_j; \quad k=1,2,\cdots,K$$

朴素贝叶斯分类器的参数估计

- 步骤
  - 2、对于给定的实例 $x=(x^{(1)},x^{(2)},\cdots,x^{(n)})^{\mathrm{T}}$

    计算 $P(Y=c_k)\prod_{j=1}^{n}P(X^{(j)}=x^{(j)}|Y=c_k),\quad k=1,2,\cdots,K$

  - 3、确定*x*的类别 $y=\arg\max_{c_k}P(Y=c_k)\prod_{j=1}^{n}P(X^{(j)}=x^{(j)}|Y=c_k)$

示例

Day	Outlook	Temperature	Humidity	Wind	PlayTennis
1	Sunny	Hot	High	Weak	No
2	Sunny	Hot	High	Strong	No
3	Overcast	Hot	High	Weak	Yes
4	Rain	Mild	High	Weak	Yes
5	Rain	Cool	Normal	Weak	Yes
6	Rain	Cool	Normal	Strong	No
7	Overcast	Cool	Normal	Strong	Yes
8	Sunny	Mild	High	Weak	No
9	Sunny	Cool	Normal	Weak	Yes
10	Rain	Mild	Normal	Weak	Yes
11	Sunny	Mild	Normal	Strong	Yes
12	Overcast	Mild	High	Strong	Yes
13	Overcast	Hot	Normal	Weak	Yes
14	Rain	Mild	High	Strong	No

示例

- 测试

<Outlook=sunny, Temperature=cool, Humidity=high, Wind=strong>

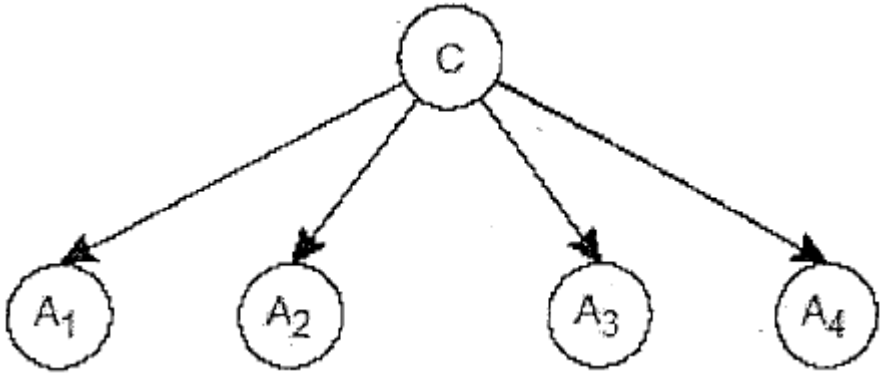

$$c(x) = \underset{c \in \{yes, no\}}{\arg\max}\, P(c)P(sunny \mid c)P(cool \mid c)P(high \mid c)P(strong \mid c)$$

示例

$P(yes)=(9+1)/(14+2)=10/16$

$P(sunny \mid yes)=(2+1)/(9+3)=3/12$

$P(cool \mid yes)=(3+1)/(9+3)=4/12$

$P(high \mid yes)=(3+1)/(9+2)=4/11$

$P(strong \mid yes)= (3+1)/(9+2)=4/11$

$P(no)=(5+1)/(14+2)=6/16$

$P(sunny \mid no)=(3+1)/(5+3)=4/8$

$P(cool \mid no)=(1+1)/(5+3)=2/8$

$P(high \mid no)=(4+1)/(5+2)=5/7$

$P(strong \mid no)=(3+1)/(5+2)=4/7$

$$P(yes)P(sunny|yes)P(cool|yes)P(high|yes)P(strong|yes)=0.0069$$

$$P(no)P(sunny|no)P(cool|no)P(high|no)P(strong|no)=0.0191$$

朴素贝叶斯分类器的缺陷

- 考虑几个问题:
- 1、如果属性之间不相互独立?
- 2、如果属性A和属性B都很重要，但是相关?
- 3、如果属性A，属性B之间独立，但是在属性C下有关?
- 4、属性之间的条件概率究竟有多少个?
- 5、条件概率谬论?

半朴素贝叶斯分类器

- SNBC： Semi-Naive Bayesian Classifier
  - SNBC在模型构建过程中，依照一定的标准将关联程度较大的特征属性合并在一起组合成新属性。
  - SNBC的各个组合属性之间相对于类别属性也是相互独立。
  - SNBC除了结构上的差别之外，计算推导过程与朴素贝叶斯相同。

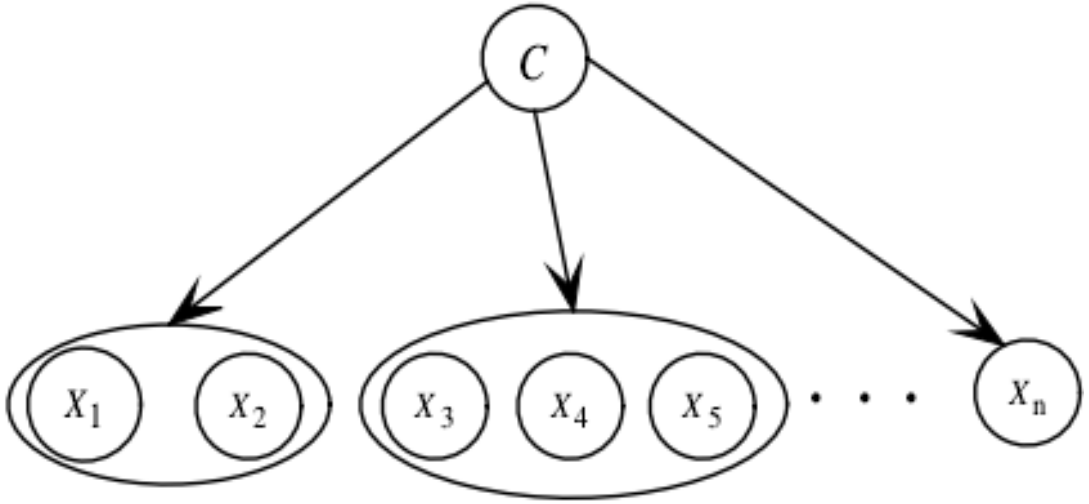

选择贝叶斯分类器

- SBC: Selective Bayesian Classifier
- SBC设计目标是为了提高朴素贝叶斯在属性冗余情况下的分类精度。
- SBC只使用属性集的子集作为决策过程中的属性结点，即选择贝叶斯分类器选择初始特征的子集作为属性结点。
- SBC通过搜索特征空间，去掉特征间具有较强依赖关系的属性。
- 前向（空集到全集），后向（全集到空集）
- 可能的搜索子集2^m

信息论相关概念

- 属性的相互独立性?
- 如何测量?

信息增益（回顾）

- 设有随机变量(X,Y),其联合概率分布为:

$$P(X=x_i, Y=y_j)=p_{ij}\ ,\quad i=1,2,\cdots,n\ ;\quad j=1,2,\cdots,m$$

- 条件熵H(Y|X)：表示在已知随机变量X的条件下随机变量Y的不确定性，定义为X给定条件下Y的条件概率分布的熵对X的数学期望:

$$H(Y\mid X)=\sum_{i=1}^{n}p_i H(Y\mid X=x_i)$$

信息增益（回顾）

- 定义 (信息增益)：特征A对训练数据集D的信息增益，g(D,A), 定义为集合D的经验熵H(D)与特征A给定条件下D的经验条件熵H(D|A)之差，即

$$g(D,A)=H(D)-H(D|A)$$

- 信息增益(Information gain)表示得知特征X的信息而使得类Y的信息的不确定性减少的程度
- 一般地，熵H(Y)与条件熵H(Y|X)之差称为互信息(mutual information)
- 决策树学习中的信息增益等价于训练数据集中类与特征的互信息

信息论相关概念

- 设信源X为离散随机变量，则用来度量X的不确定性的信息熵H(X)为

$$H(X) = -\sum_{X} P(x) \log P(x)$$

- 设(X,Y)均为离散随机变量，用来度量二元随机变量的不确定性联合信息熵H(X,Y)为

$$H(X,Y) = -\sum_{X} \sum_{Y} P(x,y) \log P(x,y)$$

信息论相关概念

- 条件信息熵H(X|Y)用来度量在收到随机变量Y提供的信息后，随机变量X仍然存在的不确定性

$$H(X|Y) = -\sum_{X}\sum_{Y} P(x,y)\log P(x|y)$$

- 互信息I(X;Y)用来描述随机变量Y提供的关于X的信息量的大小

$$I(X;Y) = H(X) - H(X|Y) = \sum_{X}\sum_{Y} P(x,y)\log\frac{P(x,y)}{P(x)P(y)}$$

信息论相关概念

- 在已知Y的前提下，随机变量X和Z之间的条件互信息定义为

$$
\begin{aligned}
I(X;Z|Y) &= \sum_{X}\sum_{Y}\sum_{Z} P(x,y,z)\log\frac{P(x,y,z)P(y)}{P(x,y)P(z,y)} \\
&= \sum_{X}\sum_{Y}\sum_{Z} P(x,y,z)\log\frac{P(x,z|y)}{P(x|y)P(z|y)}
\end{aligned}
$$

信息论相关概念

- 条件独立：对概率模式 M，A，B 和 C 是 U 的三个互不相交的变量子集，如果对 $\forall x \in A$，$\forall y \in B$和$\forall z \in C$都有 $p(x|y,z)= p(x|z)$，其中 $p(y,z)>0$，称给定 C 时 A 和 B 条件独立，记为 $I(A,C,B)_M$。
- 或：$p(x,y|z)=p(x|z)p(y|z)$

贝叶斯网络结构学习

- BN 结构学习就是在给定一个数据样本集合 D 的前提下，寻找一个与训练样本集D匹配最好的网络结构，而搜索最优的网络结构是一个 NP 难问题，因此，从数据中学习贝叶斯网络结构一直是研究的热点。
- 基于评分搜索的方法
- Robinson 等证明了包含n个节点可能的 BN 结构数目

$$f(n)=\sum_{i=1}^{n}(-1)^{i+1}\cdot(n!/i!(n-i)!)\cdot 2^{i(n-i)}\cdot f(n-i)$$

  - K2 评分（又称CH评分），BD评分，MDL（Minimum Description Length）评分，BIC（Bayesian Information Criterion）评分，AIC（Akaike Information Criterion）评分

基于信息理论的评分函数

- 基于信息理论的评分函数主要是利用编码理论和信息论中的最小描述长度（Minimum Description Length，MDL）原理来实现的;
- 其基本思想源自对数据的存储。假设D是一组给定的实例数据，如果要对其进行保存，为了节省存储空间，一般采用某种模型对其进行编码压缩，然后再保存压缩后的数据;
- 为了在需要的时候可以完全恢复这些实例数据，要求对所使用的模型进行保存；因此，需要保存的数据长度等于压缩后的数据长度加上模型的描述长度，该长度称为总的描述长度。

基于信息理论的评分函数

- MDL评分准则趋向于寻找一个结构较简单的网络，实现网络精度与复杂度之间的均衡。
- 利用参数个数作为网络结构复杂度的惩罚函数

$$C(G)=\frac{1}{2}\log m\sum_{i=1}^{n}(r_i-1)q_i.$$

- 采用海明码表示压缩后的数据长度，即就是关于数据D和模型的对数似然

$$LL_D(G)=\sum_{i=1}^{n}\sum_{j=1}^{q_i}\sum_{k=1}^{r_i}m_{ijk}\log(\frac{m_{ijk}}{m_{ij*}}).$$

- 得MDL得分

$$F_{MDL}(G\mid D)=\sum_{i=1}^{n}\sum_{j=1}^{q_i}\sum_{k=1}^{r_i}m_{ijk}\log(\frac{m_{ijk}}{m_{ij*}})-\frac{1}{2}\log m\sum_{i=1}^{n}(r_i-1)q_i.$$

基于信息理论的评分函数

- 简化:

$$F_{AIC}(G \mid D) = \sum_{i=1}^{n} \sum_{j=1}^{q_i} \sum_{k=1}^{r_i} m_{ijk} \log\left(\frac{m_{ijk}}{m_{ij*}}\right) - \sum_{i=1}^{n} (r_i - 1) q_i$$

树增广朴素贝叶斯分类器

- 树增广朴素贝叶斯分类器(TAN: Tree Augmented Naive Bayes)
  - 在属性之间增添连接弧，以消除朴素贝叶斯分类器关于条件独立的假设，称为扩展弧。
  - 从结点X_i到X_j的扩展弧表示属性X_j对分类的影响也取决于X_i的取值。
  - 可能存在这样的情况：待分类样本的属性值x_i和x_j对分类的影响都不大，$P(x_i|c)$和$P(x_j|\mathrm{c})$的值比较低，但是$P(x_j|x_i,c)$的值却很高，这时朴素贝叶斯分类器会过度降低样本属于类c概率，而扩展的朴素贝叶斯分类器却可以避免这一点。

树增广朴素贝叶斯分类器

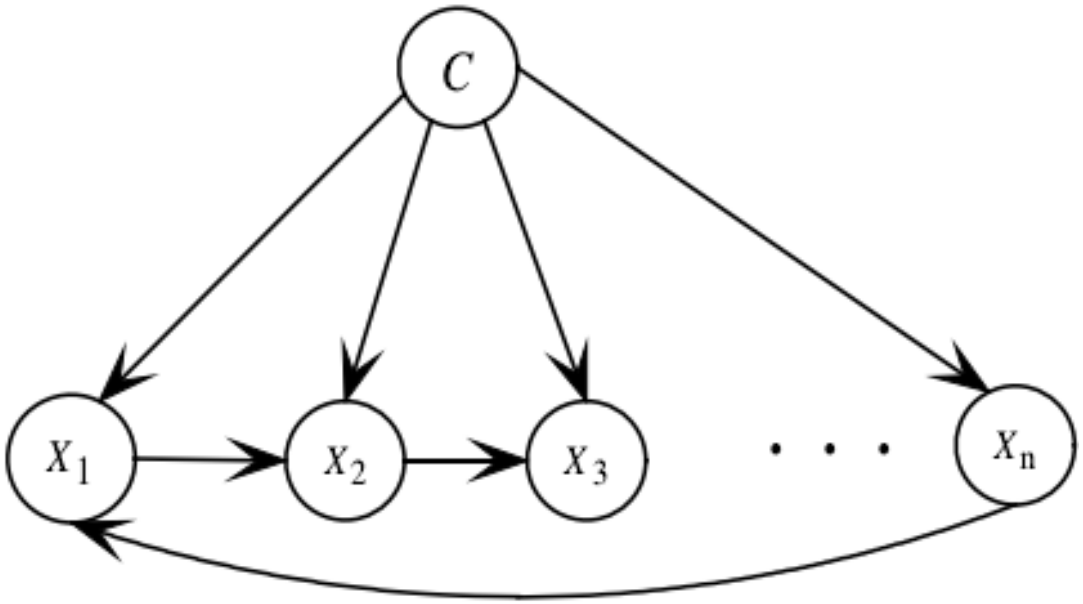

树增广朴素贝叶斯分类器

- TAN的构造过程:
- 步骤1. 通过训练集计算属性对之间的条件互信息$I(X_i,X_j|C)$ $(i \neq j)$。
- 步骤2. 建立一个以$X_1, X_2, \cdots, X_n$为结点的加权完全无向图，结点X_i, X_j之间的权重为$I(X_i,X_j|C)$ $(i \neq j)$。
- 步骤3. 利用求最大权生成树算法，建立该无向图最大权重跨度树。首先把边按权重由大到小排序，之后遵照被选择的边不能构成回路的原则，按照边的权重由大到小的顺序选择边，这样由所选择的边构成的树便是最大权重跨度树。

树增广朴素贝叶斯分类器

- 步骤4. 指定一个属性结点作为根结点，将所有边的方向设置成由根结点指向外，把无向图转换成有向图。
- 步骤5. 加入类结点C，并添加从C指向每个属性结点X_i的弧。

平均一依赖估测器

- 平均一依赖估测器(Averaged One Dependence Estimators，简记为AODE)的学习算法。
- AODE首先针对每一个属性结点学习一个“特殊”的树扩展的朴素贝叶斯分类器。之所以特殊，是因为它直接把该属性结点当成是其他所有属性结点的父亲结点。然后把这些树扩展的朴素贝叶斯分类器进行平均。

平均一依赖估测器

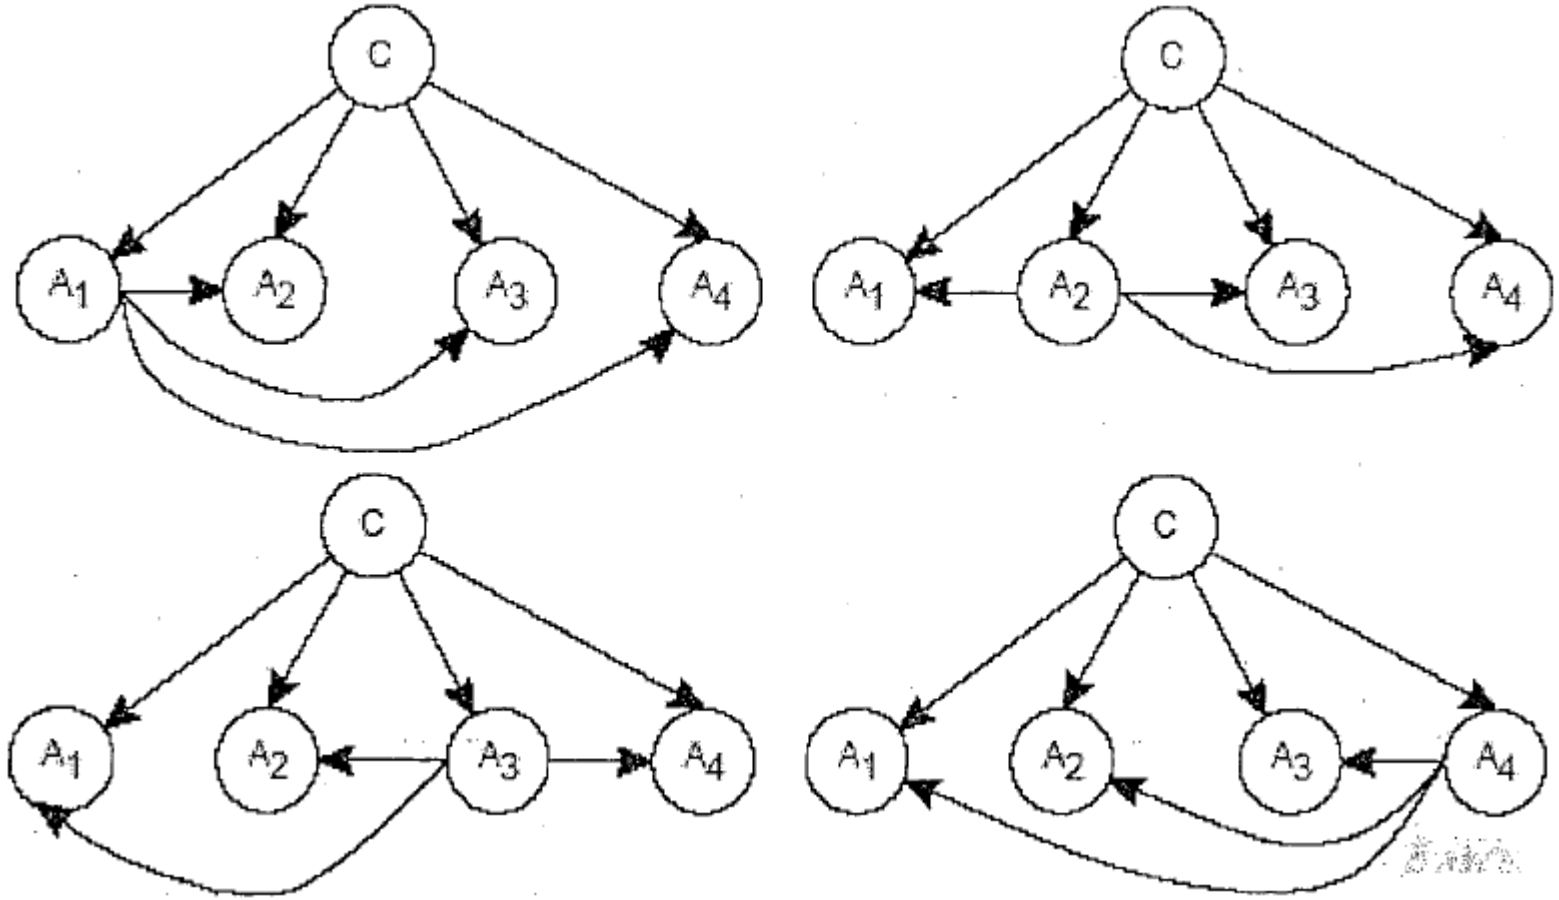

平均一依赖估测器

$$c(x) = \arg\max_{c \in C} \frac{\sum_{i=1 \wedge F(a_i) \geq 30}^{m} P(a_i, c) \prod_{j=1 \wedge j \neq i}^{m} P(a_j \mid a_i, c)}{numParent}$$

- 在AODE模型中，所有的树扩展的朴素贝叶斯分类器对最终分类的贡献是一样的，这似乎不太合理。

加权平均一依赖估测器

- 加权平均一依赖估测器(Weightily Averaged One Dependence Estimators，简记为WAODE)

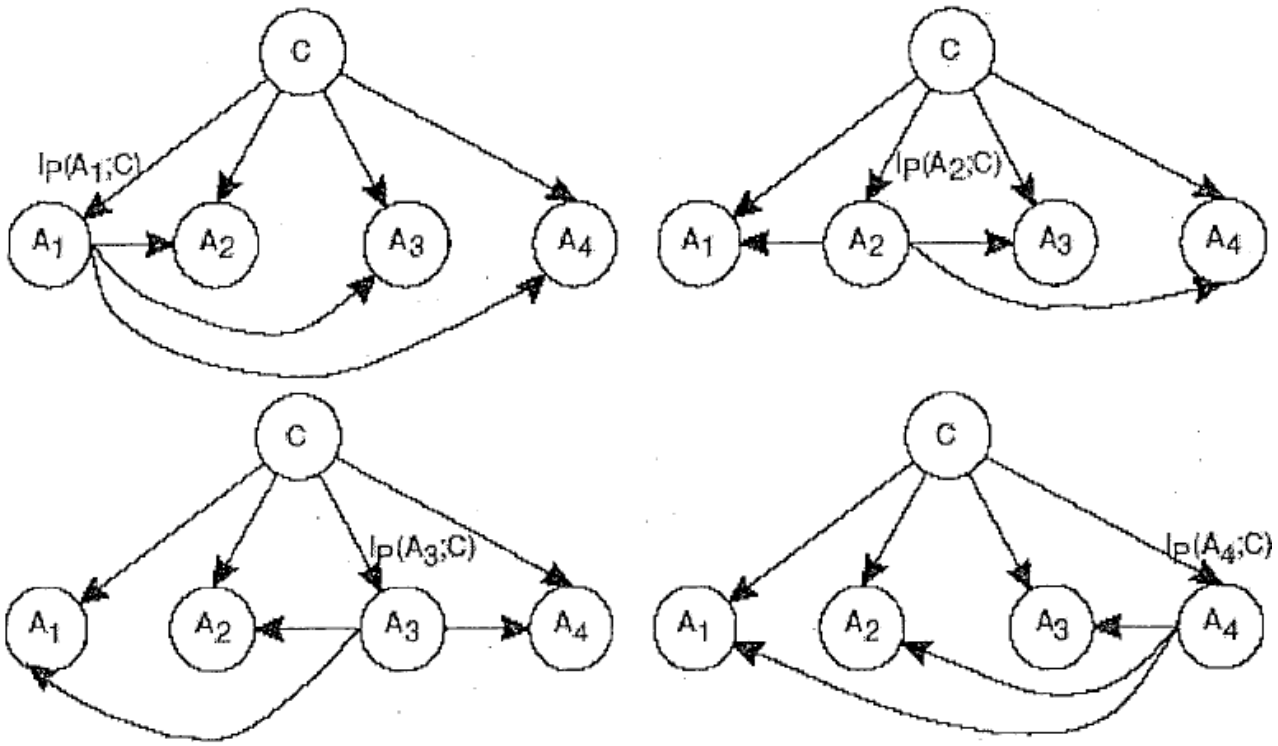

加权平均一依赖估测器

- 加权平均一依赖估测器(Weightily Averaged One Dependence Estimators，简记为WAODE)

$$c(x) = \arg\max_{c \in C} \frac{\sum_{i=1}^{m} W_i P(a_i, c) \prod_{j=1 \wedge j \neq i}^{m} P(a_j \mid a_i, c)}{\sum_{i=1}^{m} W_i}$$

$$W_i = I_P(A_i; C) = \sum_{a_i, c} P(a_i, c) \log \frac{P(a_i, c)}{P(a_i) P(c)}$$

- Q&A?