第三章
最大熵模型

饶洋辉
副教授，计算机学院

课件来源：李航. 统计学习方法. 清华大学深圳研究生院袁春教授讲解材料

最大熵模型

- 最大熵模型（Maximum Entropy Model）由最大熵原理推导实现。
- 最大熵原理:
- 学习概率模型时，在所有可能的概率模型(分布)中，熵最大的模型是最好的模型，表述为在满足约束条件的模型集合中选取熵最大的模型。
- 假设离散随机变量X的概率分布是$P(X)$，则X的
- 熵:

$$H(P) = -\sum_{x} P(x) \log P(x)$$

- 且:

$$0 \leqslant H(P) \leqslant \log |X|$$

- $|X|$是X的取值个数，X为均匀分布时右边等号成立。

示例

- 假设随机变量X有5个取值$\{A,B,C,D,E\}$，估计各个值的概率。
- 解：满足 $P(A)+P(B)+P(C)+P(D)+P(E)=1$
- 等概率估计：$P(A) = P(B) = P(C) = P(D) = P(E) = \frac{1}{5}$
- 加入一些先验：$P(A) + P(B) = \frac{3}{10}$

$$P(A) + P(B) + P(C) + P(D) + P(E) = 1$$

- 于是：

$$P(A) = P(B) = \frac{3}{20}$$

$$P(C) = P(D) = P(E) = \frac{7}{30}$$

最大熵模型

- X和Y分别是输入和输出的集合，模型表示的是对于给定的输入X，以条件概率$P(Y|X)$输出Y。
- 给定数据集：$T=\{(x_1,y_1),(x_2,y_2),\cdots,(x_N,y_N)\}$
- 联合分布$P(X, Y)$的经验分布，边缘分布$P(X)$的经验分布：

$$\tilde{P}(X,Y) \Rightarrow \tilde{P}(X=x,Y=y)=\frac{\nu(X=x,Y=y)}{N}$$

$$\tilde{P}(X) \Rightarrow \tilde{P}(X=x)=\frac{\nu(X=x)}{N}$$

- 特征函数：

$$f(x,y)=\begin{cases}1, & x\text{与}y\text{满足某一事实}\\ 0, & \text{否则}\end{cases}$$

最大熵模型

- 特征函数$f(x,y)$关于经验分布 $\tilde{P}(X,Y)$ 的期望值:

$$E_{\tilde{P}}(f)=\sum_{x,y}\tilde{P}(x,y)f(x,y)$$

- 特征函数$f(x,y)$关于模型$P(Y|X)$与经验分布 $\tilde{P}(X)$ 的期望值:

$$E_{P}(f)=\sum_{x,y}\tilde{P}(x)P(y|x)f(x,y)$$

- 如果模型能够获取训练数据中的信息，那么就可以假设这两个期望值相等，即

$$E_P(f)=E_{\tilde{P}}(f) \Rightarrow \sum_{x,y}\tilde{P}(x)P(y|x)f(x,y)=\sum_{x,y}\tilde{P}(x,y)f(x,y)$$

- 假设有n个特征函数：$f_i(x,y)$，$i=1,2,\cdots,n$

最大熵模型

- 定义:
- 假设满足所有约束条件的模型集合为:

$$\mathcal{C} \equiv \{P \in \mathcal{P} | E_P(f_i) = E_{\tilde{P}}(f_i), \quad i = 1, 2, \cdots, n\}$$

- 定义在条件概率分布$P(Y|X)$上的条件熵:

$$H(P) = -\sum_{x,y} \tilde{P}(x) P(y|x) \log P(y|x)$$

- 则模型集合C中条件熵$H(P)$最大的模型称为最大熵模型

最大熵模型的学习

- 最大熵模型的学习可以形式化为约束最优化问题。
- 对于给定的数据集以及特征函数：$f_i(x,y)$
- 最大熵模型的学习等价于约束最优化问题:

$$
\begin{aligned}
\max_{P\in\mathbf{C}} \quad & H(P) = -\sum_{x,y} \tilde{P}(x)P(y|x)\log P(y|x) \\
\text{s.t.} \quad & E_P(f_i) = E_{\tilde{P}}(f_i), \quad i = 1, 2, \cdots, n \\
& \sum_y P(y|x) = 1
\end{aligned}
$$

$$
\begin{aligned}
\min_{P\in\mathbf{C}} \quad & -H(P) = \sum_{x,y} \tilde{P}(x)P(y|x)\log P(y|x) \\
\text{s.t.} \quad & E_P(f_i) - E_{\tilde{P}}(f_i) = 0, \quad i = 1, 2, \cdots, n \\
& \sum_y P(y|x) = 1
\end{aligned}
$$

最大熵模型的学习

- 这里，将约束最优化的原始问题转换为无约束最优化的对偶问题，通过求解对偶问题求解原始问题:
- 引进拉格朗日乘子，定义拉格朗日函数:

$$L(P,w) \equiv -H(P) + w_0\left(1-\sum_y P(y|x)\right) + \sum_{i=1}^{n} w_i(E_{\tilde{P}}(f_i) - E_P(f_i))$$

$$= \sum_{x,y} \tilde{P}(x)P(y|x)\log P(y|x) + w_0\left(1-\sum_y P(y|x)\right) +$$

$$\sum_{i=1}^{n} w_i\left(\sum_{x,y}\tilde{P}(x,y)f_i(x,y) - \sum_{x,y}\tilde{P}(x)P(y|x)f_i(x,y)\right)$$

- 最优化原始问题到对偶问题: $\min_{P\in\mathbf{C}} \max_w L(P,w) \Rightarrow \max_w \min_{P\in\mathbf{C}} L(P,w)$

最大熵模型的学习

- 最优化原始问题到对偶问题:

$$\min_{P\in\mathbf{C}} \max_{w} L(P,w) \quad \Rightarrow \quad \max_{w} \min_{P\in\mathbf{C}} L(P,w)$$

- $L(P,w)$是P的凸函数，解的等价性。
- 先求极小化问题: $\min_{P\in\mathbf{C}} L(P,w)$ ，它是w的函数:

$$\Psi(w) = \min_{P\in\mathbf{C}} L(P,w) = L(P_w,w)$$

$$P_w = \arg\min_{P\in\mathbf{C}} L(P,w) = P_w(y|x)$$

最大熵模型的学习

- 求$L(P,w)$对$P(y|x)$的偏导数：

$$\frac{\partial L(P,w)}{\partial P(y|x)} = \sum_{x,y} \tilde{P}(x)\left(\log P(y|x)+1\right) - \sum_{y} w_0 - \sum_{x,y}\left(\tilde{P}(x)\sum_{i=1}^{n} w_i f_i(x,y)\right)$$

$$= \sum_{x,y} \tilde{P}(x)\left(\log P(y|x)+1-w_0-\sum_{i=1}^{n} w_i f_i(x,y)\right)$$

- 得：

$$P(y|x) = \exp\left(\sum_{i=1}^{n} w_i f_i(x,y) + w_0 - 1\right) = \frac{\exp\left(\sum_{i=1}^{n} w_i f_i(x,y)\right)}{\exp(1-w_0)}$$

最大熵模型的学习

- 由: $\sum_y P(y|x) = 1$

- 得: $P_w(y|x) = \frac{1}{Z_w(x)} \exp\left(\sum_{i=1}^{n} w_i f_i(x,y)\right)$

规范化因子: $Z_w(x) = \sum_y \exp\left(\sum_{i=1}^{n} w_i f_i(x,y)\right)$

模型 $P_w = P_w(y|x)$ 就是最大熵模型

求解对偶问题外部的极大化问题:

$$\max_w \Psi(w) \qquad w^* = \arg\max_w \Psi(w) \qquad P^* = P_{w^*} = P_{w^*}(y|x)$$

示例

- 原例子中的最大熵模型:

$$
\begin{aligned}
\min \quad & -H(P) = \sum_{i=1}^{5} P(y_i) \log P(y_i) \\
\text{s.t.} \quad & P(y_1) + P(y_2) = \tilde{P}(y_1) + \tilde{P}(y_2) = \frac{3}{10} \\
& \sum_{i=1}^{5} P(y_i) = \sum_{i=1}^{5} \tilde{P}(y_i) = 1
\end{aligned}
$$

$$
L(P, w) = \sum_{i=1}^{5} P(y_i) \log P(y_i) + w_1 \left(P(y_1) + P(y_2) - \frac{3}{10} \right) + w_0 \left(\sum_{i=1}^{5} P(y_i) - 1 \right)
$$

$$
\max_{w} \min_{P} L(P, w)
$$

示例

$$\frac{\partial L(P,w)}{\partial P(y_1)} = 1 + \log P(y_1) + w_1 + w_0$$

$$\frac{\partial L(P,w)}{\partial P(y_2)} = 1 + \log P(y_2) + w_1 + w_0$$

$$\frac{\partial L(P,w)}{\partial P(y_3)} = 1 + \log P(y_3) + w_0$$

$$\frac{\partial L(P,w)}{\partial P(y_4)} = 1 + \log P(y_4) + w_0$$

$$\frac{\partial L(P,w)}{\partial P(y_5)} = 1 + \log P(y_5) + w_0$$

解得：

$$P(y_1) = P(y_2) = \mathrm{e}^{-w_1 - w_0 - 1}$$

$$P(y_3) = P(y_4) = P(y_5) = \mathrm{e}^{-w_0 - 1}$$

示例

$$\min_{P} L(P, w) = L(P_w, w) = -2\mathrm{e}^{-w_1-w_0-1} - 3\mathrm{e}^{-w_0-1} - \frac{3}{10}w_1 - w_0$$

- 得:

$$\max_{w} L(P_w, w) = -2\mathrm{e}^{-w_1-w_0-1} - 3\mathrm{e}^{-w_0-1} - \frac{3}{10}w_1 - w_0$$

- 对w_i求偏导并令为0:

$$\mathrm{e}^{-w_1-w_0-1} = \frac{3}{20}$$

$$\mathrm{e}^{-w_0-1} = \frac{7}{30}$$

$$\Rightarrow$$

$$P(y_1) = P(y_2) = \frac{3}{20}$$

$$P(y_3) = P(y_4) = P(y_5) = \frac{7}{30}$$

模型学习的最优化算法

- 最大熵模型学习归结为以似然函数为目标函数的最优化问题，通常通过迭代算法求解，它是光滑的凸函数，因此多种最优化的方法都适用。

- 常用的方法有：
  - 改进的迭代尺度法
  - 梯度下降法
  - 牛顿法
  - 拟牛顿法

示例

- 词和情感对组成的集合：

$$\varphi = \{(w_1, e_1), (w_2, e_1), (w_2, e_2), (w_3, e_2)\}$$

短文本	短文本的词	情感标签
t_1	$w_{t_1} = \{w_1, w_2\}$	e_1
t_2	$w_{t_2} = \{w_2, w_3\}$	e_2

- 测试文本t的$w_t = \{w_1, w_2, w_3\}$
- 定义在条件概率分布$P(\boldsymbol{e}|\boldsymbol{w})$上的条件熵：$H(P) = -\sum_{w_j, e_k} \tilde{p}(w_j) p(e_k \mid w_j) \log_2 p(e_k \mid w_j)$
- 通过伯努利模型来定义特征函数：

$$f_i(w_j, e_k) = \begin{cases} 1 & w_j \in \boldsymbol{w}, e_k \in \boldsymbol{e}, (w_j, e_k) \in \boldsymbol{\varphi} \\ 0 & otherwise, \end{cases}$$

- 给定训练数据集，联合分布$P(\boldsymbol{w}, \boldsymbol{e})$的经验分布：$\tilde{p}(w_j, e_k) \propto count(w_j, e_k)$
- 边缘分布$P(\boldsymbol{w})$的经验分布：$\tilde{p}(w_j) \propto count(w_j)$

示例

- 特征函数$f(\boldsymbol{w},\boldsymbol{e})$关于经验分布 $\tilde{p}(w_j,e_k)$ 的期望值:

$$\tilde{E}(f)=\sum_{w_j,e_k}\tilde{p}(w_j,e_k)f(w_j,e_k)$$

- 特征函数$f(\boldsymbol{w},\boldsymbol{e})$关于模型$P(\boldsymbol{e}|\boldsymbol{w})$与经验分布 $\tilde{p}(w_j)$ 的期望值:

$$E(f)=\sum_{w_j,e_k}\tilde{p}(w_j)p(e_k\mid w_j)f(w_j,e_k)$$

- 最大熵模型如下: $\max\ H(P)=\sum_{w_j,e_k}\tilde{p}(w_j)p(e_k\mid w_j)\log_2\frac{1}{p(e_k\mid w_j)}$

$$s.t.\qquad E(f)-\tilde{E}(f)=0$$

$$\sum_{e_k}p(e_k\mid w_j)-1=0\quad for\ all\ w$$

- 引进拉格朗日乘子: $p_\lambda(e\mid w)=\frac{1}{Z_\lambda(w)}\exp(\sum_{i=1}^{|\varphi|}\lambda_i f_i(w,e))$

$$Z_\lambda(w)=\sum_e\exp(\sum_{i=1}^{|\varphi|}\lambda_i f_i(w,e))$$

示例

- 通过迭代算法求解每一个参数λ_i的最优值后，基于最大熵模型进行标签预测。回顾训练数据集词和情感对组成的列表：

$$\varphi = \{(w_1, e_1), (w_2, e_1), (w_2, e_2), (w_3, e_2)\}$$

- 通过伯努利模型定义的特征函数：

$$f_1(w_1, e_1) = f_2(w_2, e_1) = f_3(w_2, e_2) = f_4(w_3, e_2) = 1$$

- 测试文本t（$w_t = \{w_1, w_2, w_3\}$）的后验概率分布：

$$p_\lambda(e_1|t) = \frac{1}{Z_\lambda(w)} \exp\left(\lambda_1 f_1(w_1, e_1) + \lambda_2 f_2(w_2, e_1)\right)$$

$$p_\lambda(e_2|t) = \frac{1}{Z_\lambda(w)} \exp\left(\lambda_3 f_3(w_2, e_2) + \lambda_4 f_4(w_3, e_2)\right)$$

- Q&A?