第四章
提升方法

饶洋辉
副教授，计算机学院

课件来源：李航. 统计学习方法. 清华大学深圳研究生院袁春教授讲解材料

Adaboost的起源

- 1984年，Kearns 和 Valiant 提出的强可学习(strongly learnable)和弱可学习(weakly learnable)
  - 在概率近似正确（probably approximately correct, PAC）学习的框架中，一个概念（类），如果存在一个多项式的学习算法能够学习它，并且正确率很高，称这个概念是强可学习的；
  - 一个概念（类），如果存在一个多项式的学习算法能够学习它，学习的正确率仅比随机猜测略好，则称这个概念是弱可学习的。
- 1989年, Schapire 证明：
  - 在PAC学习的框架下，一个概念是强可学习的充分必要条件是这个概念是弱可学习。

Adaboost的起源

- 问题的提出：
- 只要找到一个比随机猜测略好的弱学习算法就可以直接将其提升为强学习算法，而不必直接去找很难获得的强学习算法。

怎样实现弱学习转为强学习

例如：学习算法A在a情况下失效，学习算法B在b情况下失效，那么在a情况下可以用B算法，在b情况下可以用A算法解决。这说明通过某种合适的方式把各种算法组合起来，可以提高准确率。

为实现弱学习互补，面临两个问题：

（1）怎样获得不同的弱分类器？

（2）怎样组合弱分类器？

怎样获得不同的弱分类器

- 使用不同的弱学习算法得到不同的基本学习器
- 使用相同的弱学习算法，但用不同的参数
  - K-Means不同的K，神经网络不同的隐含层…
- 相同输入对象的不同表示凸显事物不同的特征
- 使用不同的训练集
  - 装袋（Bagging）
  - 提升（Boosting）

Bagging

- 也称为自举汇聚法(Bootstrap AGGregatIGN)
  - 从原始数据集选择S次后得到S个新数据集
  - 新数据集和原数据集的大小相等
  - 每个数据集都是通过在原始数据集中有放回地随机选择样本而得到的。
  - S个数据集建好之后，将某个学习算法分别作用于每个数据集就得到S个分类器。
  - 选择分类器投票结果中最多的类别作为最后的分类结果。
  - 改进的Bagging算法，如随机森林等。

- 原数据集： $\{(x_1, y_1), (x_2, y_2), (x_3, y_3), (x_4, y_4)\}$ $u_0 = (1, 1, 1, 1)$
- 采样1： $\{(x_2, y_2), (x_2, y_2), (x_3, y_3), (x_4, y_4)\}$ $u_1 = (0, 2, 1, 1)$
- 采样2： $\{(x_1, y_1), (x_1, y_1), (x_1, y_1), (x_4, y_4)\}$ $u_2 = (3, 0, 0, 1)$

怎样组合弱分类器

- 多专家组合

  一种并行结构，所有的弱分类器都给出各自的预测结果，通过“组合器”把这些预测结果转换为最终结果。如投票（voting）及其变种、混合专家模型

- 多级组合

  一种串行结构，其中下一个分类器只在前一个分类器预测不够准（不够自信）的实例上进行训练或检测。如级联算法（cascading）

Bagging的弊端

- Bagging的可能弊端？

学习器是根据分布大致相同的数据学习的，它们学到的规则可能都是一样的！

- 能否控制权重$\boldsymbol{u}$，让各个子模型学到不同的规则？

Boosting的基本思想：一个一个地训练子模型，在下一次训练的时候，当前**分类错误**的样本的**权重增大**，**分类正确**的样本的**权重减小**。那么下一次训练的时候就可以**更加关注当前分类错误的样本**。

Adaboost的提出

- 1990年， Schapire最先构造出一种多项式级的算法， 即最初的Boosting算法;
- 1993年， Drunker和Schapire第一次将神经网络作为弱学习器，应用Boosting算法解决OCR问题;
- 1995年， Freund和Schapire提出了Adaboost (Adaptive Boosting)算法，效率和原来Boosting算法一样，但是不需要任何关于弱学习器性能的先验知识，可以非常容易地应用到实际问题中。

Adaboost的基本概念

AdaBoost

Adaptive Boosting

A learning algorithm

Building a strong classifier by a lot of weaker ones

Adaboost的基本概念

$$\left.\begin{array}{c} h_1(x) \in \{-1,+1\} \\ h_2(x) \in \{-1,+1\} \\ \vdots \\ h_T(x) \in \{-1,+1\} \end{array}\right\} \quad H_T(x) = sign\left(\sum_{t=1}^{T} \alpha_t h_t(x)\right)$$

Weak classifiers

strong classifier

slightly better than random

Adaboost的基本概念

- 两个问题如何解决：
  - 每一轮如何改变训练数据的权值或概率分布？
  - AdaBoost：提高那些被前一轮弱分类器错误分类样本的权值，降低那些被正确分类样本的权值

  - 如何将弱分类器组合成一个强分类器？
  - AdaBoost：加权多数表决，加大分类误差率小的弱分类器的权值，使其在表决中起较大的作用，减小分类误差率大的弱分类器的权值，使其在表决中起较小的作用。

Adaboost算法

- 输入：二分类的训练数据集 $T=\{(x_1,y_1),(x_2,y_2),\cdots,(x_N,y_N)\}$

  $x_i \in \mathcal{X} \subseteq \mathbf{R}^n$ ， $y_i \in \mathcal{Y}=\{-1,+1\}$
- 输出：最终分类器$G(x)$
- 1、初始化训练数据的起始权值分布

$$D_1=(w_{11},\cdots,w_{1i},\cdots,w_{1N}),\quad w_{1i}=\frac{1}{N},\quad i=1,2,\cdots,N$$

- 控制权重$\boldsymbol{u}$，让各个子模型学到不同的规则

  子模型1：对了8个，错了2个，错误率e为0.2

  放大错误样本的比例：2 × 8 = 16

  缩小正确样本的比例：8 × 2 = 16
- 现在对于子模型1，新的错误率就变为0.5。而一个模型能得出0.5的错误率，等同于直接随机。那么子模型2在使用这个新的数据集来学习的话，学到的东西就能保证和子模型1的是不一样的。

Adaboost算法

- 控制权重$\boldsymbol{u}$，让各个子模型学到不同的规则

$$u\text{-incorrect} \propto 1\text{-}e$$

$$u\text{-correct} \propto e$$

新的e为0.5

- 实际操作中，令$s = \sqrt{\frac{1-e}{e}}$

$$u\text{-incorrect} \leftarrow u\text{-incorrect} \times s$$

$$u\text{-correct} \leftarrow u\text{-correct} \ / \ s$$

Adaboost算法

- 怎么判断每个子模型的票数?

实际操作中，使用$\alpha = \ln(s)$来作为每一个子模型的权重。s为前面介绍的参数$s = \sqrt{\frac{1-e}{e}}$。

$e = 0.5 \quad \rightarrow \quad s = 1 \quad \rightarrow \quad \alpha = 0$

$e = 0.1 \quad \rightarrow \quad s = 3 \quad \rightarrow \quad \alpha = \ln(3)$

$e = 0.9 \quad \rightarrow \quad s = 1/3 \quad \rightarrow \quad \alpha = \ln(1/3) = -\ln(3)$

Adaboost算法

- 2、对m个弱分类器 $m = 1, 2, \ldots, M$

  a、在权值D_m下训练数据集，得到弱分类器

$$G_m(x) : \mathcal{X} \to \{-1, +1\}$$

  b、计算G_m的训练误差

$$e_m = \sum_{i=1}^{N} P(G_m(x_i) \neq y_i) = \sum_{i=1}^{N} w_{mi} I(G_m(x_i) \neq y_i)$$

  c、计算G_m的系数 $\alpha_m = \frac{1}{2} \log \frac{1 - e_m}{e_m}$

  d、更新训练数据集的权值分布 $D_{m+1} = (w_{m+1,1}, \cdots, w_{m+1,i}, \cdots, w_{m+1,N})$

$$w_{m+1,i} = \frac{w_{mi}}{Z_m} \exp(-\alpha_m y_i G_m(x_i)), \quad i = 1, 2, \cdots, N$$

  Z_m是规范化因子 $Z_m = \sum_{i=1}^{N} w_{mi} \exp(-\alpha_m y_i G_m(x_i))$

Adaboost算法

- 3、构建弱分类器的线性组合

$$f(x) = \sum_{m=1}^{M} \alpha_m G_m(x)$$

得到最终分类器:

$$\begin{aligned} G(x) &= \operatorname{sign}(f(x)) \\ &= \operatorname{sign}\left(\sum_{m=1}^{M} \alpha_m G_m(x)\right) \end{aligned}$$

Adaboost算法说明

- 步骤 2.b $e_m = \sum_{i=1}^{N} P(G_m(x_i) \neq y_i) = \sum_{G_m(x_i) \neq y_i} w_{mi}$ $\sum_{i=1}^{N} w_{mi} = 1$

- 步骤 2.c $\alpha_m = \frac{1}{2} \log \frac{1 - e_m}{e_m}$ 当 $e_m \leqslant \frac{1}{2}$ 时，$\alpha_m \geqslant 0$

- 步骤 2.d

$$w_{m+1,i} = \begin{cases} \frac{w_{mi}}{Z_m} \mathrm{e}^{-\alpha_m}, & G_m(x_i) = y_i \\ \frac{w_{mi}}{Z_m} \mathrm{e}^{\alpha_m}, & G_m(x_i) \neq y_i \end{cases}$$

- 误分类的样本权值放大 $\mathrm{e}^{2\alpha_m} = \frac{1 - e_m}{e_m}$

示例

序号	1	2	3	4	5	6	7	8	9	10
x	0	1	2	3	4	5	6	7	8	9
y	1	1	1	-1	-1	-1	1	1	1	-1

- 初始化 $D_1 = (w_{11}, w_{12}, \cdots, w_{110})$

  $$w_{1i} = 0.1, \quad i = 1, 2, \cdots, 10$$

- 对$m = 1$
- a、在权值分布为D_1的数据集上，阈值取2.5，分类误差率最小，基本弱分类器：

$$G_1(x) = \begin{cases} 1, & x < 2.5 \\ -1, & x > 2.5 \end{cases}$$

- b、$G_1(x)$的误差率： $e_1 = P(G_1(x_i) \neq y_i) = 0.3$
- c、$G_1(x)$的系数： $\alpha_1 = \frac{1}{2} \log \frac{1 - e_1}{e_1} = 0.4236$

示例

- d、更新训练数据的权值分布

$$D_2 = (w_{21}, \cdots, w_{2i}, \cdots, w_{210})$$

$$w_{2i} = \frac{w_{1i}}{Z_1} \exp(-\alpha_1 y_i G_1(x_i)), \quad i = 1, 2, \cdots, 10$$

$$D_2 = (0.07143, 0.07143, 0.07143, 0.07143, 0.07143, 0.07143,$$
$$0.16667, 0.16667, 0.16667, 0.07143)$$

$$f_1(x) = 0.4236 G_1(x)$$

- 弱基本分类器$G_1(x)$=sign[$f_1(x)$]在更新的数据集上有3个误分类点

示例

- 对$m = 2$
- a、在权值分布D_2上，阈值$v = 8.5$时，分类误差率最低

$$G_2(x) = \begin{cases} 1, & x < 8.5 \\ -1, & x > 8.5 \end{cases}$$

- b、误差率 $e_2 = 0.2143$
- c、计算 $\alpha_2 = 0.6496$
- d、更新权值分布 $D_3 = (0.0455, 0.0455, 0.0455, 0.1667, 0.1667, 0.1667, 0.1060, 0.1060, 0.1060, 0.0455)$

$$f_2(x) = 0.4236G_1(x) + 0.6496G_2(x)$$

- 分类器$G_2(x)=\text{sign}[f_2(x)]$有三个误分类点

示例

- 对$m = 3$
- a、在权值分布D_3上，阈值$v = 5.5$时，分类误差率最低

$$G_3(x) = \begin{cases} 1, & x > 5.5 \\ -1, & x < 5.5 \end{cases}$$

- b、误差率 $e_3 = 0.1820$
- c、计算 $\alpha_3 = 0.7514$
- d、更新权值分布 $D_4 = (0.125, 0.125, 0.125, 0.102, 0.102, 0.102, 0.065, 0.065, 0.065, 0.125)$

$$f_3(x) = 0.4236G_1(x) + 0.6496G_2(x) + 0.7514G_3(x)$$

- 分类器$G_3(x)$=sign[$f_3(x)$]误分类点为0

$$G(x) = \text{sign}[f_3(x)] = \text{sign}[0.4236G_1(x) + 0.6496G_2(x) + 0.7514G_3(x)]$$

Boosting illustration

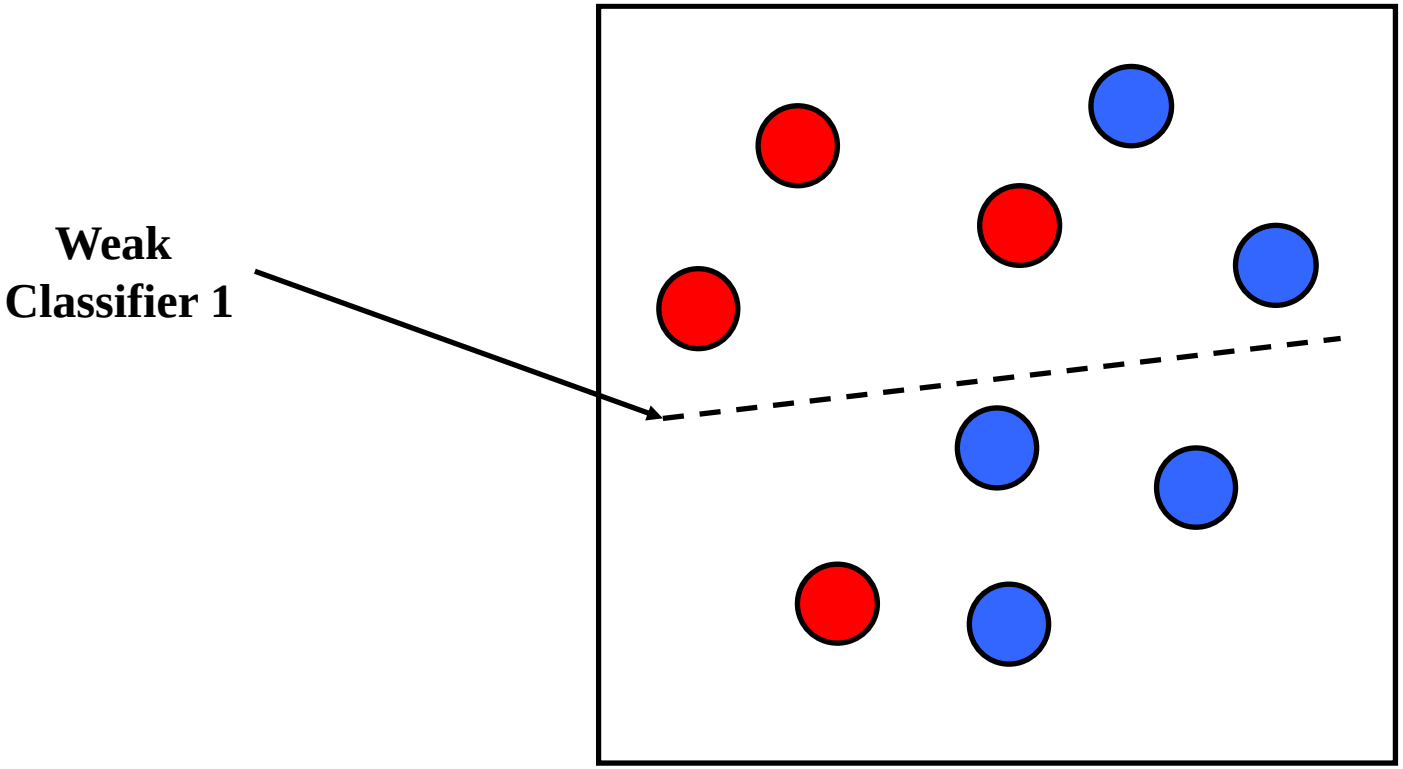

Boosting illustration

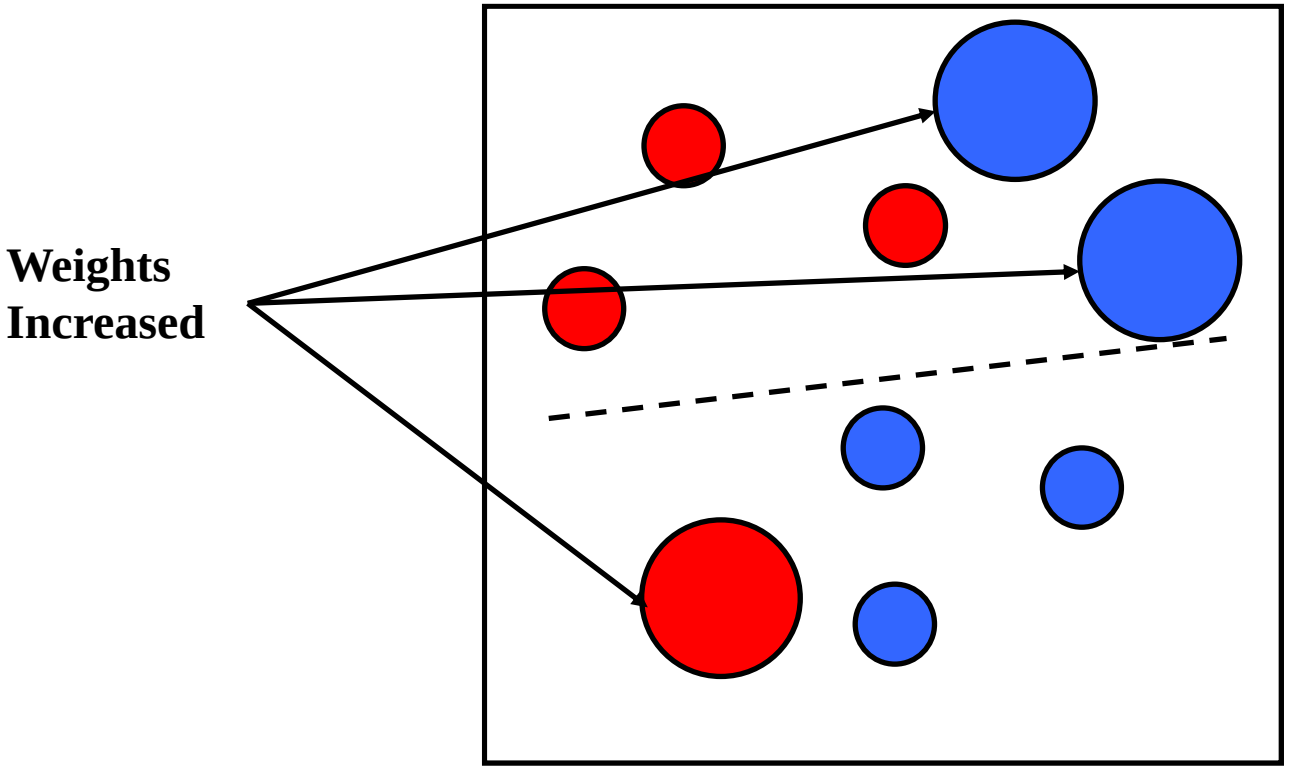

Boosting illustration

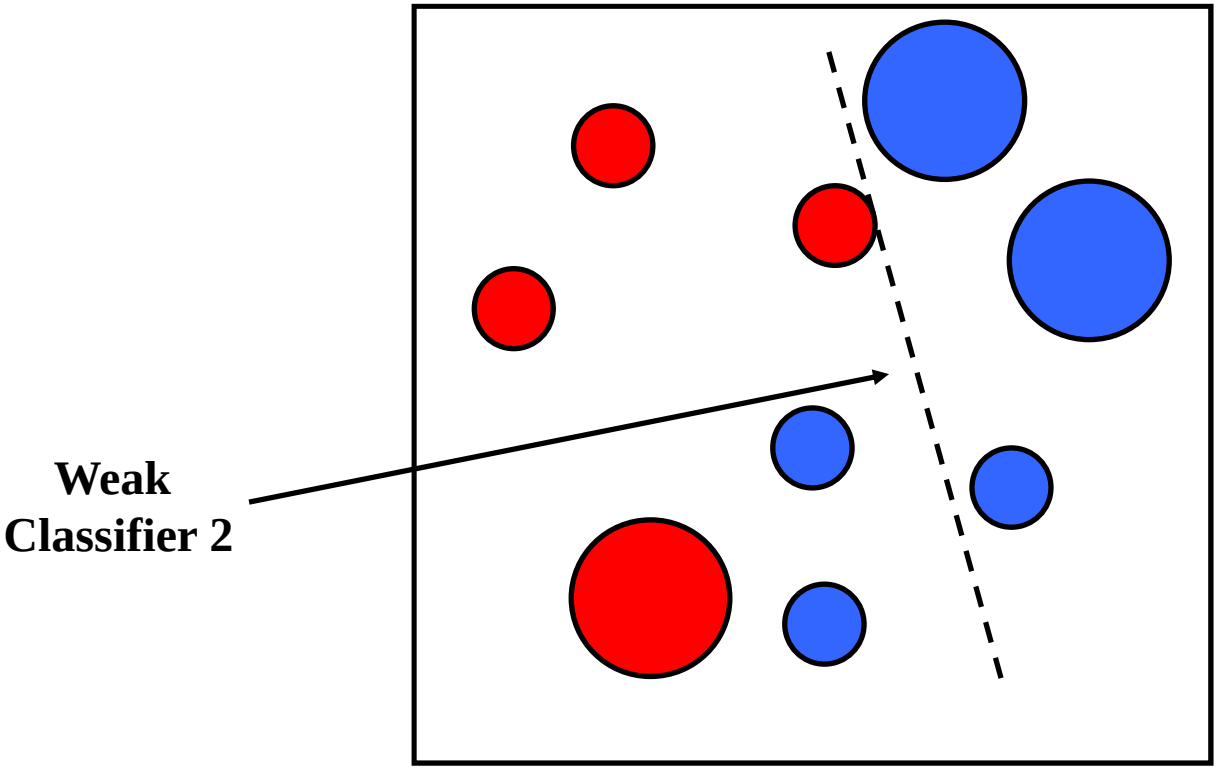

Boosting illustration

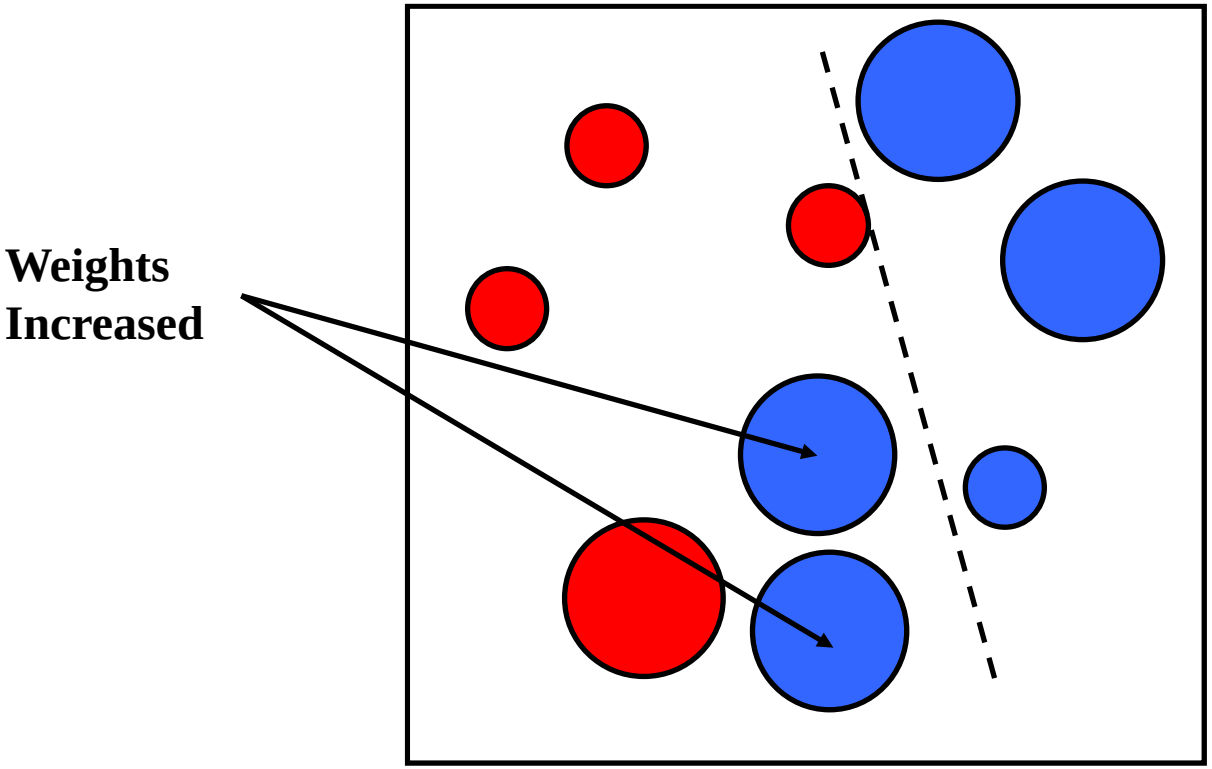

Boosting illustration

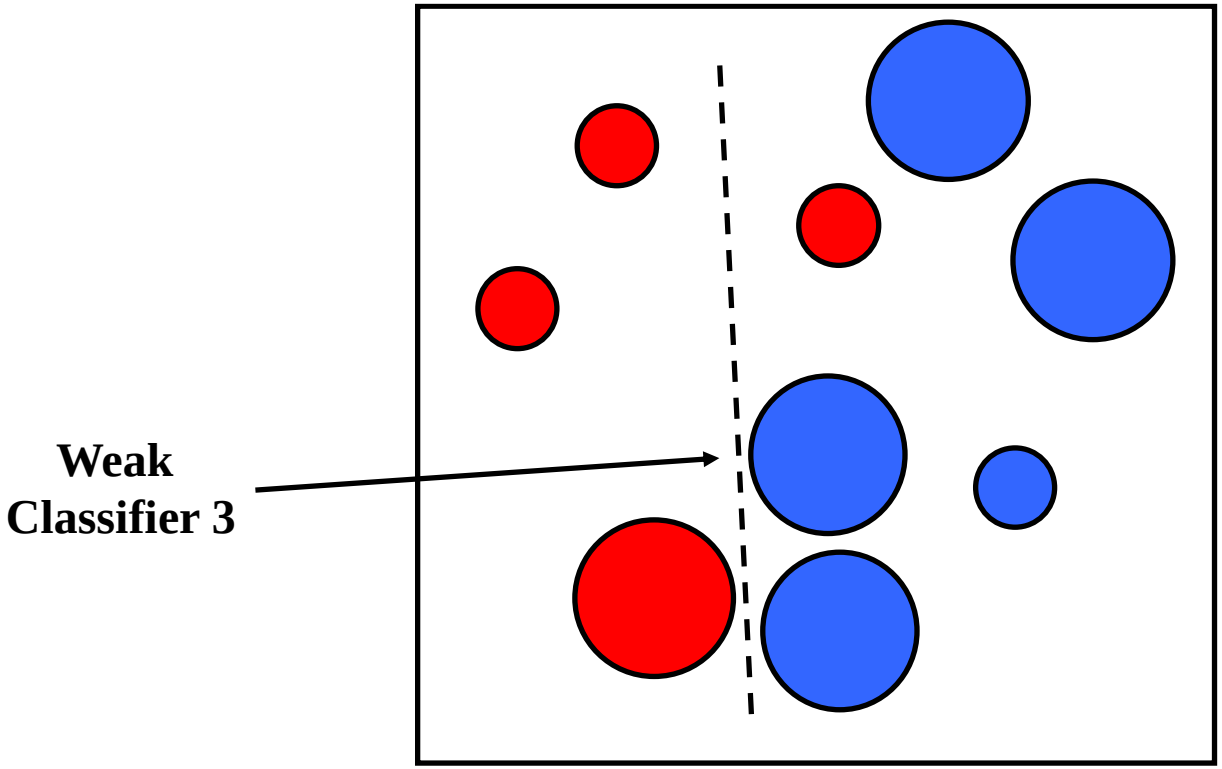

Boosting illustration

Final classifier is a combination of weak classifiers

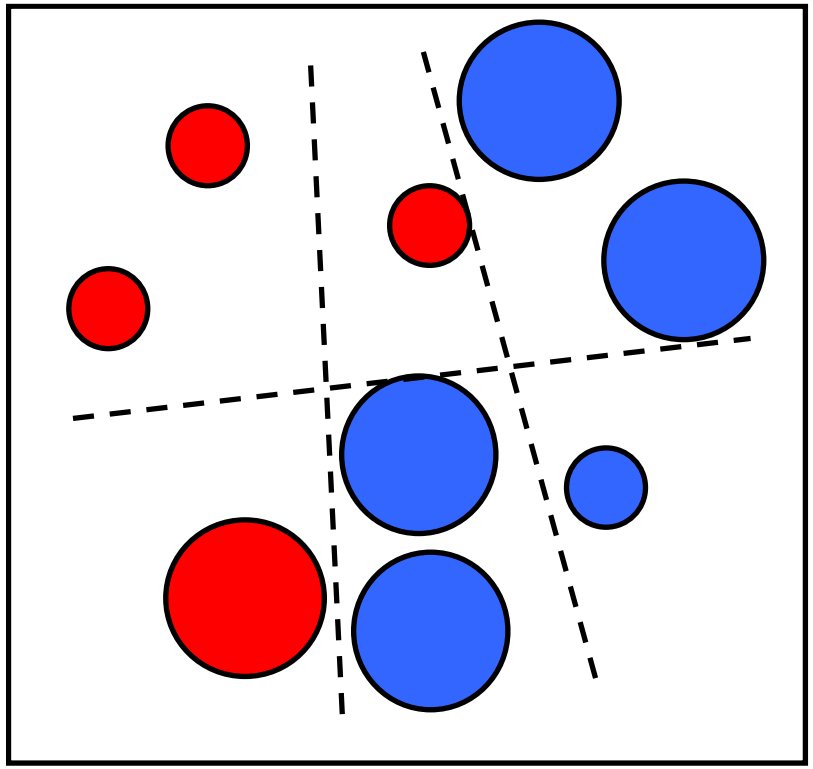

- Q&A?