视频人体行为识别

钟珊珊 (学号: 22214624)
zhongshsh5@mail2.sysu.edu.cn

摘要

视频人体行为识别是计算机视觉领域的一个重要领域，其目标是使用计算机自动识别视频中的活动和场景。这种技术可以用来帮助监测和分析人类行为，并且在许多领域都有广泛的应用，包括安防监控、运动分析、人机交互等。视频人体行为识别系统通常使用深度学习方法来自动提取视频中的特征，并使用这些特征来预测视频中的活动。目前，有许多不同的模型可以用于视频人体行为识别，包括卷积神经网络、循环神经网络（RNN）、残差网络（ResNet）等。在本文中，笔者将从动作识别、姿态估计、面部表情识别三个方面系统地梳理视频人体行为识别的国内外研究现状，并结合自身的研究方向，通过实验探讨注意力机制在视频分类模型中的应用效果。

关键词： 人体行为识别；视频；深度学习；注意力机制

1 研究问题及意义

人体行为识别包括对人的动作、姿态、面部表情等的识别。近年来，随着计算机视觉技术的发展，人体行为识别在视频领域的应用也越来越广泛。视频人体行为识别（或视频分类）的目标是使用计算机自动识别视频中的活动和场景。

视频人体行为识别系统通常使用深度学习方法来自动提取视频中的特征，并使用这些特征来预测视频中的活动。有许多不同的模型可以用于视频人体行为识别，包括卷积神经网络（CNN）[1, 2]、循环神经网络（RNN）[3, 2, 4]、残差网络（ResNet）[5, 6]、Transformer [7] 等。通常，视频人体行为识别可以被表示为一个分类问题，即给定视频的特征，预测其所属的类别。在进行视频人体行为识别之前，通常需要对视频进行预处理，包括裁剪、缩放和转换为适合模型输入的格式。此外，许多视频人体行为识别系统使用人工标记的训练数据来学习识别视频中的活动。例如，使用 CNN 的视频人体行为识别系统可以表示为：对于给定的视频 x，其对应的特征为 $f(x)$，其所属的类别为 y。通过使用 CNN 模型 h，我们可以预测给定视频的类别，即：$\hat{y} = h(f(x))$，其中 $\hat{y}$ 表示预测的类别，h 表示 CNN 模型，f 表示视频特征提取函数。

视频人体行为识别技术在许多领域中都有应用 [8, 9]。在娱乐领域，视频人体行为识别可用于自动标记视频以便于搜索和管理。在运动领域，视频人体行为识别可用于识别运动员的动作和技巧。在安全领域，视频人体行为识别可用于监测公共场所的活动并发现在军事领域，视频人体行为识别可用于识别军事装备和活动。

2 相关研究

目前，人体行为识别的研究依赖于深度学习技术，主要包括动作识别（Action recognition）、姿态估计（Pose estimation）、面部表情识别（Facial expression recognition）[8, 10]。

2.1 动作识别

动作识别指的是识别人在视频中所执行的动作，例如跑步、跳跃、拍打等。动作识别的主要挑战包括两方面。一方面，视频中存在大量混合动作。研究者可以通过使用混合动作表示技术来提高场景中可能存在混合动作的表示，例如，对于包含相似姿势和动作的人类活动视频，Jalal 等人提出了一种使用轮廓和基于骨架的特征的活动识别系统 [11]。Vishwakarma 等人结合了形状和运动信息 [12]。邵等人结合形状和运动信息，并使用时间分割进行动作识别 [13]。另一方面，在动作识别框架中，收集了大量特征以捕获所有可能的事件。这导致冗余数据的存在，使学习过程复杂化。因此，为了加强分类模型的学习任务，应该进行数据降维以去除冗余信息。这些技术可以分为无监督和监督 [14]。无监督降维包括自动编码器 [15] 和减少基础分解（RBD）[16] 等研究，监督降维技术包括线性判别分析 (LDA) 和内核判别分析 (KDA) [17]。

2.2 姿态估计

姿态估计指的是识别人在视频中的姿态信息，包括人的头部、肩部、腰部等的位置和方向。近年来，随着深度学习在图像分类、目标检测、语义分割等等，姿态估计也通过采用深度学习技术取得了快速进步。自上而下的姿态估计方法的两个最重要的组成部分是人体区域候选检测器和单人姿势估计器。大多数研究都集中在基于现有人体探测器的人体部位估计上，例如 Faster R-CNN [18]，Mask R-CNN [19]，FPN [20]。Iqbal 和 Gall [21] 利用基于卷积姿势机的姿势估计器来生成初始姿势。然后应用整数线性规划（ILP）来获得最终的姿势。Fang 等人 [22] 采用空间变压器网络（STN）[23]，非极大抑制（NMS）和沙漏网络，以便在存在不准确的人类边界框的情况下进行姿态估计。

2.3 面部表情识别

面部表情识别指的是识别人在视频中的面部表情，例如笑、生气、惊讶等。面部表情识别 [24, 25] 是计算机视觉和心理学科学中的经典研究课题，已经研究了很多年。大多数早期方法都是基于手工制作的特征 [26]。最近，深度学习极大地推动了面部表情识别的发展 [27, 28, 29]。例如，Weng 等人 [30] 提出了一个多分支网络来捕获面部表情识别的全局和局部特征。Xue 等人 [31, 32] 提出了一种结合了

CNN 和变压器的混合架构，可在多个基准测试上实现最先进的性能，并提出了具有平滑预测的粗到细级联网络（CFC-SP）来提高面部表情识别的性能。一些研究人员 [33, 34] 提出通过注意力机制提取判别特征，这被证明对遮挡是鲁棒的。

3 实验探索

在实验探索部分，笔者使用 UCF101 [35] 和 PyTorch [1] 进行视频人体行为识别的简单实验探索。UCF101 共有来自 101 个动作的 13320 个视频，视频具有不同的时间长度（帧）和不同的 2D 图像大小，最短的是 28 帧。UCF101 可以用于训练视频分类模型，也即视频人体行为识别中的动作识别。笔者选用的基准模型包括 CNN [36]、LSTM [37]、ResNet [5]，模型实现参考 video-classification [2]，通过 8 卡 3080GPU 完成模型训练，以 top 1 准确度作为模型性能的评估指标。

表 1: 不同模型的 top 1 准确度，除 ResNet152-SE-CNN 之外，其他模型的结果来自 video-classification

模型	top 1 acc.
CNN	0.5084
CNN + LSTM	0.5462
ResNet152-CNN + LSTM	0.8568
ResNet152-SE-CNN + LSTM	0.8047

笔者结合自己的研究方向，尝试将注意力机制 [38, 39] 运用于图像分类任务中。具体而言，笔者进一步优化 ResNet152-CNN + LSTM，使用带图像分类中经典的注意力机制 SENet [38] 的 ResNet152，也即 ResNet152-SE 来替代 ResNet152。如表 1所示，增加了注意力机制的 ResNet152-SE-CNN + LSTM 的性能反而降低了。笔者分析认为，可能是因为 ResNet152-CNN + LSTM 中的 ResNet152 调用了 PyTorch 中预训练好的模型，而 ResNet152-SE-CNN + LSTM 中的 ResNet152-SE 为未训练的模型，在初始化的时候不具备优势，因此导致最终的模型性能不够好。

4 总结

在本文中，笔者在研究问题及意义部分介绍了视频人体行为识别这一研究问题及其广泛应用；相关研究部分从动作识别、姿态估计、面部表情识别三个角度详细介绍视频人体行为识别的国内外研究现状，并列举了经典成果和近年的研究成果；在实验探索部分，笔者结合自身的研究方向，在 UCF101 上的视频分类模型中融入注意力机制，探讨了注意力机制在视频人体行为领域的应用效果。实验

[1] https://pytorch.org

[2] https://github.com/HHTseng/video-classification

表明，ResNet152-SE 在视频分类任务上表现不错，但是与最优模型之间存在一定的差距，分析认为可能是因为 ResNet152 是预训练模型，具有一定的初始化优势。通过撰写综述性的本文，笔者对视频领域有了进一步的理解和体会。

在近年来，视频人体行为识别技术取得了显著进展，并在多个基准数据集上取得了最先进的结果 [40, 7, 41]。然而，视频人体行为识别仍然存在一些挑战，包括视频中的运动造成的图像变化、复杂的背景和遮挡物、视频中的多种活动等。为了克服这些挑战，研究人员正在开发新的模型和方法，例如使用多模态数据（如视频和文本）[42]、无监督学习 [43] 等。未来，视频人体行为识别技术可能会进一步改善，并在更多领域中得到应用。例如，它可能会用于进行自动化的体育分析、监控城市活动以及识别工业机器的故障。

参考文献

[1] Kirill Gavrilyuk, Ryan Sanford, Mehrsan Javan, and Cees GM Snoek. Actor-transformers for group activity recognition. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 839–848, 2020.

[2] Mengyuan Liu, Fanyang Meng, Chen Chen, and Songtao Wu. Joint dynamic pose image and space time reversal for human action recognition from videos. In *Proceedings of the AAAI conference on artificial intelligence*, volume 33, pages 8762–8769, 2019.

[3] Md Atiqur Rahman Ahad, Masud Ahmed, Anindya Das Antar, Yasushi Makihara, and Yasushi Yagi. Action recognition using kinematics posture feature on 3d skeleton joint locations. *Pattern Recognition Letters*, 145:216–224, 2021.

[4] Mengshi Qi, Yunhong Wang, Jie Qin, Annan Li, Jiebo Luo, and Luc Van Gool. Stagnet: An attentive semantic rnn for group activity and individual action recognition. *IEEE Transactions on Circuits and Systems for Video Technology*, 30(2):549–565, 2019.

[5] Kaiming He, Xiangyu Zhang, Shaoqing Ren, and Jian Sun. Deep residual learning for image recognition. In *Proceedings of the IEEE conference on computer vision and pattern recognition*, pages 770–778, 2016.

[6] Gyeongsik Moon, Heeseung Kwon, Kyoung Mu Lee, and Minsu Cho. Integralaction: Pose-driven feature integration for robust human action recognition in videos. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 3339–3348, 2021.

[7] Anwaar Ulhaq, Naveed Akhtar, Ganna Pogrebna, and Ajmal Mian. Vision transformers for action recognition: A survey. *arXiv preprint arXiv:2209.05700*, 2022.

[8] Preksha Pareek and Ankit Thakkar. A survey on video-based human action recognition: recent updates, datasets, challenges, and applications. *Artificial Intelligence Review*, 54(3):2259–2322, 2021.

[9] Yu Kong and Yun Fu. Human action recognition and prediction: A survey. *International Journal of Computer Vision*, 130(5):1366–1401, 2022.

[10] Imen Jegham, Anouar Ben Khalifa, Ihsen Alouani, and Mohamed Ali Mahjoub. Vision-based human action recognition: An overview and real world challenges. *Forensic Science International: Digital Investigation*, 32:200901, 2020.

[11] Ahmad Jalal, Yeon-Ho Kim, Yong-Joong Kim, Shaharyar Kamal, and Daijin Kim. Robust human activity recognition from depth video using spatiotemporal multi-fused features. *Pattern recognition*, 61:295–308, 2017.

[12] Dinesh K Vishwakarma, Rajiv Kapoor, and Ashish Dhiman. A proposed unified framework for the recognition of human activity by exploiting the characteristics of action dynamics. *Robotics and Autonomous Systems*, 77:25–38, 2016.

[13] Ling Shao, Ling Ji, Yan Liu, and Jianguo Zhang. Human action segmentation and recognition via motion and shape analysis. *Pattern Recognition Letters*, 33(4):438–445, 2012.

[14] O. Saini and S. Sharma. A review on dimension reduction techniques in data mining. (1), 2018.

[15] A Au, B Km, A Iuh, and A Swb. Action recognition using optimized deep autoencoder and cnn for surveillance data streams of non-stationary environments - sciencedirect. *Future Generation Computer Systems*, 96:386–397, 2019.

[16] Muniandi Arunraj, Andy Srinivasan, and A Vimala Juliet. Online action recognition from rgb-d cameras based on reduced basis decomposition. *Journal of Real-Time Image Processing*, 2018.

[17] Z. A. Khan and W. Sohn. Abnormal human activity recognition system based on r-transform and kernel discriminant technique for elderly home care. *IEEE Transactions on Consumer Electronics*, 57(4):1843–1850, 2011.

[18] Cewu Lu, Ranjay Krishna, Michael Bernstein, and Li Fei-Fei. Visual relationship detection with language priors. *Springer International Publishing*, 2016.

[19] K. He, G. Gkioxari, P. Dollar, and R. Girshick. Mask r-cnn. *IEEE*, (2), 2020.

[20] T. Y. Lin, P. Dollar, R. Girshick, K. He, B. Hariharan, and S. Belongie. Feature pyramid networks for object detection. *IEEE Computer Society*, 2017.

[21] Umar Iqbal and Juergen Gall. Multi-person pose estimation with local joint-to-person associations. *Springer International Publishing*, 2016.

[22] H. S. Fang, S. Xie, Y. W. Tai, and C. Lu. Rmpe: Regional multi-person pose estimation. *IEEE*, 2017.

[23] M. Jaderberg, K. Simonyan, A. Zisserman, and K. Kavukcuoglu. Spatial transformer networks. *MIT Press*, 2015.

[24] A. Mollahosseini, B. Hasani, and M. H. Mahoor. Affectnet: A database for facial expression, valence, and arousal computing in the wild. *IEEE Transactions on Affective Computing*, pages 1–1, 1949.

[25] Y. Jin, T. Zheng, C. Gao, and G. Xu. A multi-modal and multi-task learning method for action unit and expression recognition. 2021.

[26] G. Guo and C. R. Dyer. Learning from examples in the small sample case: face expression recognition. *IEEE Press*, 2005.

[27] A. H. Farzaneh and X. Qi. Facial expression recognition in the wild via deep attentive center loss. In *Workshop on Applications of Computer Vision*, 2021.

[28] J. She, Y. Hu, H. Shi, J. Wang, Q. Shen, and T. Mei. Dive into ambiguity: Latent distribution mining and pairwise uncertainty estimation for facial expression recognition. 2021.

[29] W. Zhang, F. Qiu, S. Wang, H. Zeng, Z. Zhang, R. An, B. Ma, and Y. Ding. Transformer-based multimodal information fusion for facial expression analysis. *arXiv e-prints*, 2022.

[30] Jun Weng, Yang Yang, Zichang Tan, and Zhen Lei. Attentive hybrid feature with two-step fusion for facial expression recognition. In *2020 25th International Conference on Pattern Recognition (ICPR)*, pages 6410–6416. IEEE, 2021.

[31] F. Xue, Z. Tan, Y. Zhu, Z. Ma, and G. Guo. Coarse-to-fine cascaded networks with smooth predicting for video facial expression recognition. 2022.

[32] Fanglei Xue, Qiangchang Wang, and Guodong Guo. Transfer: Learning relation-aware facial expression representations with transformers. In *Proceedings of the IEEE/CVF International Conference on Computer Vision*, pages 3601–3610, 2021.

[33] Jing Li, Kan Jin, Dalin Zhou, Naoyuki Kubota, and Zhaojie Ju. Attention mechanism-based cnn for facial expression recognition. *Neurocomputing*, 411:340–350, 2020.

[34] Yong Li, Jiabei Zeng, Shiguang Shan, and Xilin Chen. Occlusion aware facial expression recognition using cnn with attention mechanism. *IEEE Transactions on Image Processing*, 28(5):2439–2450, 2018.

[35] K. Soomro, A Roshan Zamir, and M. Shah. Ucf101: A dataset of 101 human actions classes from videos in the wild. *arXiv e-prints*, 2012.

[36] Yann LeCun, Léon Bottou, Yoshua Bengio, and Patrick Haffner. Gradient-based learning applied to document recognition. *Proceedings of the IEEE*, 86(11):2278–2324, 1998.

[37] Sepp Hochreiter and Jürgen Schmidhuber. Long short-term memory. *Neural computation*, 9(8):1735–1780, 1997.

[38] Jie Hu, Li Shen, and Gang Sun. Squeeze-and-excitation networks. In *Proceedings of the IEEE conference on computer vision and pattern recognition*, pages 7132–7141, 2018.

[39] Zhongzhan Huang, Senwei Liang, Mingfu Liang, and Haizhao Yang. Dianet: Dense-and-implicit attention network. In *Proceedings of the AAAI Conference on Artificial Intelligence*, volume 34, pages 4206–4214, 2020.

[40] Yuecong Xu, Jianfei Yang, Haozhi Cao, Keyu Wu, Min Wu, and Zhenghua Chen. Source-free video domain adaptation by learning temporal consistency for action recognition. In *European Conference on Computer Vision*, pages 147–164. Springer, 2022.

[41] Mahdi Biparva, David Fernández-Llorca, Rubén Izquierdo Gonzalo, and John K Tsotsos. Video action recognition for lane-change classification and prediction of surrounding vehicles. *IEEE Transactions on Intelligent Vehicles*, 7(3):569–578, 2022.

[42] Saghir Alfasly, Jian Lu, Chen Xu, and Yuru Zou. Learnable irrelevant modality dropout for multimodal action recognition on modality-specific annotated videos. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 20208–20217, 2022.

[43] Victor G Turrisi da Costa, Giacomo Zara, Paolo Rota, Thiago Oliveira-Santos, Nicu Sebe, Vittorio Murino, and Elisa Ricci. Unsupervised domain adaptation for video transformers in action recognition. In *2022 26th International Conference on Pattern Recognition (ICPR)*, pages 1258–1265. IEEE, 2022.

A 代码说明

ResNet152-SE-CNN + LSTM 的代码与本文档一起提交，代码文件夹的结构和文件功能如下所示：

```
.
 functions.py              # 模型
 resnet_se.py              # 基于注意力机制 SENet 的 ResNet
 UCF101_ResNetSECRNN.py    # 训练和测试模型
```

运行代码只需要按照 video-classification [3]的指南准备数据，并执行指令：

```
python UCF101_ResNetSECRNN.py
```

[3] https://github.com/HHTseng/video-classification