基于深度学习的草图数据理解

钟珊珊

(中山大学 计算机学院,广州 广东 510006)
E-mail: zhongshsh5@mail2.sysu.edu.cn

摘 要: 本文针对基于深度学习的草图数据理解这一课题，详细介绍了该课题的基本内容，并对该课题的经典算法和研究现状进行了详细的陈述。在经典算法部分，本文对陈述了 CNN、RNN、RBM 三种草图数据理解的经典算法。在研究现状部分，本文介绍了表征学习、识别、分割与聚类这四种草图数据理解的主要技术，并从草图数据理解的应用角度进行了总结。从相关研究调研上看，本文认为草图数据理解的应用可以总结为草图分类、草图生成、草图标注、草图检索四个方面。
关键词: 草图;数据理解;深度学习

Sketch Understanding Based on Deep Learning

ZHONG Shan-Shan

(School of Computer Science and Engineering, Sun Yat-Sen University, Guangzhou 510006, China)

Abstract: We introduce the basic content of the topic of sketch understanding based on deep learning, and detail the classic algorithms and research status of the topic. In the section of classic algorithms, we present classic algorithms for sketch understanding, such as CNN, RNN, and RBM. In the section of research status, we introduce four main techniques for sketch understanding: representation learning, recognition, segmentation, and clustering, and summarize them from the perspective of applications of sketch understanding. Based on the research review, we believe that the applications of sketch understanding can be summarized into four aspects: sketch classification, sketch generation, sketch annotation, and sketch retrieval.
Key words: sketch; data understanding; deep learning

1 引言

草图（sketch）是一种简化的图像，通常由几何图形、线条和文本组成，表示某种概念、思想或物品[1]。草图是人类常用的表示图形的方式，在很多领域都有广泛的应用。草图数据理解的研究对于提高人工智能的图像识别能力和人机交互能力有重要意义。例如，可以使用草图数据理解技术来开发智能画图工具，帮助用户自动绘制出精美的图画；也可以使用草图数据理解技术来开发智能设计工具，帮助用户快速设计出工业产品的图纸。另外，草图数据理解的研究也有助于提高人工智能的自然语言理解能力。例如，可以使用草图数据理解技术来开发智能聊天机器人，帮助用户通过草图与机器人进行交流。草图数据理解的研究对于提高人工智能在图像识别、人机交互和自然语言理解方面的能力，以及为人类提供更加方便和高效的工具都具有重要意义。

在计算机领域中，草图数据一般指的是线条或图形的集合，指通过手绘或者其他方式创建的简单图像数据。深度学习领域的草图数据理解研究的目的是使用人工智能技术来处理和理解草图数据。基于深度学习的草图研究内容主要包括三个模块[1]。在数据准备上，基于深度学习的草图研究需要大量的草图数据进行训练和测试，研究者可以使用现有的草图数据集，也可以自己采集草图数据。相关研究一般从像素草图合成、矢量草图合成、像素草图矢量化等方面着手，思考如何获取草图数据。在数据建模上，研究者一般从草图数据识别、分割与聚类、表征学习等方面优化模型设计，使得模型更好地理解草图数据。在数据应用上，基于深度学

1 参考自高成英老师的课程 PPT

习的草图建模常常被应用于草图上色、自然图像合成等方面。这些模块中的各个环节都需要经过反复的实验和调试才能得到较好的结果。

本文广泛地调研了基于深度学习的草图数据理解的最新研究进展，并阐述了自身对该研究内容的理解和思考。

2 经典算法

通常情况下，基于深度学习的草图数据集包含大量的手绘或者类似手绘的图像数据，这些数据可以用来训练深度学习模型，从而让模型学会识别和分类各种图像特征。一种常见的建模草图数据的方法是使用卷积神经网络 (CNN) [2]来处理图像数据，并使用循环神经网络 (RNN) [3]来处理序列数据。将这两种网络结合起来，就可以得到一种称为“番茄网络”的模型，用于处理草图数据。番茄网络通常包含一个卷积层，用于提取图像的特征，以及一个 RNN 层，用于处理时间序列数据。另一种方法是使用受限玻尔兹曼机 (RBM)[4] 来建模草图数据。 RBM 可以有效地学习草图数据的潜在表示，并且可以通过采样来生成新的草图数据。

CNN 是一种深度学习模型，它通过对输入数据进行卷积操作来学习特征。卷积层的计算可以表示为：

$$f_{\{i,j\}} = \sum_{\{k=1\}}^{K}\sum_{\{m=1\}}^{M}\sum_{\{n=1\}}^{N} w_{\{k,m,n\}} \cdot x_{\{i+m-1,j+n-1,k\}} + b_k \tag{1}$$

其中，$f_{\{i,j\}}$是卷积层输出的第 i 行第 j 列的值，x 是输入数据，w 是权重矩阵，b 是偏置向量，K 是输入数据的通道数，M 和 N 是卷积核的大小。

RNN 是一种用于处理序列数据的深度学习模型。它通过在时间步 t 处的隐藏状态h_t与上一时间步的隐藏状态$h_{\{t-1\}}$的信息进行转移来处理序列数据。RNN 层的计算可以表示为：

$$h_t = \sigma\left(W_{\{hh\}}h_{\{t-1\}} + W_{\{xh\}}x_t + b_h\right) \tag{2}$$

其中，h_t是隐藏状态，x_t是输入数据， $W_{\{hh\}}$和$W_{\{xh\}}$分别是隐藏状态和输入数据对应的参数矩阵。

RBM 是一种用于学习隐含变量的深度学习模型。它的基本结构由两个节点层组成，一个观察层和一个隐含层。观察层的节点对应于输入数据，隐含层的节点对应于隐含变量。RBM 的计算可以表示为：

$$P(v|h) = \prod_{\{i=1\}}^{n} P(v_i|h) = \prod_{\{i=1\}}^{n} \frac{1}{1 + e^{\left\{-\left(b_i + \sum_{\{j=1\}}^{m} w_{\{i,j\}}h_j\right)\right\}}} \tag{3}$$

$$P(h|v) = \prod_{\{j=1\}}^{m} P\left(h_j|v\right) = \prod_{\{j=1\}}^{m} \frac{1}{1 + e^{\left\{-\left(c_j + \sum_{\{i=1\}}^{n} w_{\{i,j\}}v_i\right)\right\}}} \tag{4}$$

其中，v 和 h 分别表示观察层和隐含层的状态，w 是权重矩阵，b 和 c 分别是观察层和隐含层的偏置向量。

总的来说，基于深度学习的草图数据理解可以使用多种方法进行建模，这些方法的数学表示各不相同，我们可以根据具体的应用场景来选择合适的方法。

3 研究现状

研究者一般从草图数据表征学习、识别、分割与聚类等方面优化模型设计，使得模型更好地理解草图数据。

基于深度学习的草图数据表征学习是指使用深度学习方法来学习草图数据的表示方法。Xu P 等人[5]首次解决了徒手草图的自监督表示学习问题。这在很大程度上解决了草图社区面临的一个常见问题——难以获得带注释的监督数据。Xu Z 等人[6]探索使用多尺度随机卷积的输出作为新图像或在训练期间将它们与原始图像混合，提出的方法可以持续提高域泛化基准的性能，并且在草图域和 ImageNet-Sketch 的挑战性场景中，提出的方法远远优于最先进的方法。Han H 等人[7]提出了一种有效的纹身搜索方法，该方法能够通过多任务学习在单个 CNN 中共同学习纹身检测和紧凑表示。表征学习的目的是帮助模型更好地理解草图数据，是草图数据理解的基础。

基于深度学习的草图数据识别是指使用深度学习方法来处理草图数据，识别草图中的概念、思想或物品。Xu P 等人[8]设计了一种图神经网络（GNN）即多图转换器（MGT）用于从多个图学习草图的表示，同时捕获

全局和局部几何笔画结构以及时间信息。Zhang X 等人[9]提出了一种名为 Hybrid CNN 的新架构，它由描述外观信息的 A-Net 和描述形状信息 S-Net 组成。Wan W 等人[10]提出了一种基于迁移学习的新型人脸草图识别方法，设计出一个三通道卷积神经网络架构，其中采用三重损失来学习判别特征并减少类内变化。Zhang H 等人[11]的用研究目的是解决特征提取过程中没有额外监督的固定计算模式问题，提出了一种由两个组件组成的架构来动态发现物体地标并学习判别性结构表示：一个代表性的地标发现模块，用于定位对象上的关键点，以及一个类别感知表示学习模块，用于开发特定于类别的特征。Wan J 等人[12]提出了一种角度驱动的反馈恢复网络（ADFRNet），它首先检测草图的不完美部分，然后将它们细化为高质量的图像，以提高草图识别的性能。草图数据识别技术主要应用在草图信息提取、草图分类、草图美化等方面。

基于深度学习的草图数据分割是指使用深度学习方法来将草图数据划分为若干个部分。这种方法可以帮助我们更好地理解草图数据，并有助于我们进行进一步的分析和处理。为了预测每个节点的标签，SketchGNN[13]使用图卷积和静态-动态分支网络架构来提取三个级别的特征，即点级、笔画级和草图级。SPFusionNet[14]通过融合图像和点集模式来捕捉草图的特征，其中图像模态组件 SketchNet 学习分层抽象的 ro-bust 特征，并利用多级表示来生成像素级特征图，而点集模态组件 SPointNet 捕获采样点集的局部和全局上下文以生成逐点特征图。SPFusionNet 通过融合网络组件聚合这些特征图，以生成草图分割结果。SketchSeg[15]是一个由 10000 个像素标记草图组成的大型数据集。MCPNet 为多列点的 CNN，用于解决草图中缺乏颜色和纹理问题，直接以采样点为输入，以降低计算成本，并采用不同滤波器尺寸的多列来更好地捕获草图的结构。SketchSegNet+[16]是基于递归神经网络（RNN）的端到端学习网络，被用于将一系列笔画转换为一系列语义标签。草图数据分割本质上为多分类技术，通过对草图中的不同结构进行分析，加以分类，从而优化深度模型对特征稀疏、抽象的草图的理解。

草图数据聚类是指将草图数据分成若干个类别，使得同一类别中的草图数据相似度较高，而不同类别中的草图数据相似度较低。Huang S 等人[17]提出了一种基于稀疏子空间聚类的大规模方法，该方法可以有效地处理大型高光谱图像，同时在草图亚空间聚类上展现出不错的效果。Wang L 等人[18]提出一种基于多聚类的草图图像检索重排名的无监督方法。Rahmani M 等人[19]探讨并分析了大型部分观测图的无监督聚类，并提出了一个可扩展且可证明的随机框架，用于从随机块模型生成的聚类图。草图数据聚类的相关研究相对于草图的其他相关领域要少一些，但这并不意味着草图数据聚类不重要。草图数据聚类同样可以帮助我们对草图数据进行分组和分类，有助于我们进行进一步的分析和处理。相对于草图数据分割技术，草图数据聚类技术是一种无监督的分类方法，在具体应用上更为灵活简便，但在数据分类上存在一定的随机性和不可控的缺点。

通过调研草图数据理解的不同技术的相关研究，我们可以从草图数据理解的应用角度总结草图数据理解的主要应用场景：（1）草图分类，用于识别草图中的概念、思想或物品。主要通过 CNN 等方式实现草图分类的数据理解和建模。（2）草图生成。主要通过使用生成对抗网络（GAN）[20]来生成草图，或者使用 RNN 来生成草图的文本描述。（3）草图标注，用于自动标注草图中的对象和关系。主要通过聚类和分割等无监督和有监督方式来标注草图中的人物和动作、不同的组成。（4）草图检索，用于在草图数据库中检索相似的草图。一般而言，可以通过深度网络进行草图特征提取，然后使用这些特征进行检索。这些研究为我们提供了许多有用的信息，帮助我们更好地理解草图数据，并开发出更准确、更有效的草图处理方法。此外，还有许多其他的基于深度学习的草图数据研究，例如草图编辑[21]、草图转换[22]等。这些研究也为我们提供了有用的信息，有助于我们更好地使用草图进行沟通和协作。

4 总结

在本文中，我针对基于深度学习的草图数据理解这一课题，详细介绍了该课题的基本内容，并对该课题的经典算法和研究现状进行了详细的陈述。经典算法部分对草图数据理解的经典算法 CNN、RNN、RBM 进行了陈述。研究现状部分介绍了表征学习、识别、分割与聚类这四个草图数据理解的主要技术，并从草图数据理解的应用角度进行了总结。从相关研究调研上看，我将草图数据理解的应用总结为草图分类、草图生成、

草图标注、草图检索四个方面。

撰写本文加深了我对草图数据理解领域的认识，广泛调研和学习基于深度学习的草图数据理解的理论知识对我的研究方向具有很好的启迪作用。

References:

[1] 张宪林. 基于草图的图像检索关键技术研究[D]. 北京邮电大学, 2019.

[2] Lecun Y， Boser B， Denker J , et al. Backpropagation Applied to Handwritten Zip Code Recognition[J]. Neural Computation, 1989, 1(4):541-551.

[3] Schmidhuber, J. (1991). The power of weight-sharing. In Advances in neural information processing systems (pp. 527-534).

[4] HINTON, G.E., OSINDERO, S., TEH, Y.W. A fast learning algorithm for deep belief nets. Neural Computation, 2006, 18(7): 1527-1554.

[5] Xu P, Song Z, Yin Q, et al. Deep self-supervised representation learning for free-hand sketch[J]. IEEE Transactions on Circuits and Systems for Video Technology, 2020, 31(4): 1503-1513.

[6] Xu Z, Liu D, Yang J, et al. Robust and generalizable visual representation learning via random convolutions[J]. arXiv preprint arXiv:2007.13003, 2020.

[7] Han H, Li J, Jain A K, et al. Tattoo image search at scale: Joint detection and compact representation learning[J]. IEEE transactions on pattern analysis and machine intelligence, 2019, 41(10): 2333-2348.

[8] Xu P, Joshi C K, Bresson X. Multigraph transformer for free-hand sketch recognition[J]. IEEE Transactions on Neural Networks and Learning Systems, 2021.

[9] Zhang X, Huang Y, Zou Q, et al. A hybrid convolutional neural network for sketch recognition[J]. Pattern Recognition Letters, 2020, 130: 73-82.

[10] Wan W, Gao Y, Lee H J. Transfer deep feature learning for face sketch recognition[J]. Neural Computing and Applications, 2019, 31(12): 9175-9184.

[11] Zhang H, She P, Liu Y, et al. Learning structural representations via dynamic object landmarks discovery for sketch recognition and retrieval[J]. IEEE Transactions on Image Processing, 2019, 28(9): 4486-4499.

[12] Wan J, Zhang K, Li H, et al. Angular-Driven Feedback Restoration Networks for Imperfect Sketch Recognition[J]. IEEE Transactions on Image Processing, 2021, 30: 5085-5095.

[13] Yang L, Zhuang J, Fu H, et al. Sketchgnn: Semantic sketch segmentation with graph neural networks[J]. ACM Transactions on Graphics (TOG), 2021, 40(3): 1-13.

[14] Wang F, Lin S, Wu H, et al. Spfusionnet: Sketch segmentation using multi-modal data fusion[C]//2019 IEEE International Conference on Multimedia and Expo (ICME). IEEE, 2019: 1654-1659.

[15] Wang F, Lin S, Li H, et al. Multi-column point-CNN for sketch segmentation[J]. Neurocomputing, 2020, 392: 50-59.

[16] Qi Y, Tan Z H. SketchSegNet+: An end-to-end learning of RNN for multi-class sketch semantic segmentation[J]. Ieee Access, 2019, 7: 102717-102726.

[17] Huang S, Zhang H, Du Q, et al. Sketch-based subspace clustering of hyperspectral images[J]. Remote Sensing, 2020, 12(5): 775.

[18] Wang L, Qian X, Zhang X, et al. Sketch-based image retrieval with multi-clustering re-ranking[J]. IEEE Transactions on Circuits and Systems for Video Technology, 2019, 30(12): 4929-4943.

[19] Rahmani M, Beckus A, Karimian A, et al. Scalable and robust community detection with randomized sketching[J]. IEEE Transactions on Signal Processing, 2020, 68: 962-977.

[20] Wang S Y, Bau D, Zhu J Y. Sketch your own gan[C]//Proceedings of the IEEE/CVF International Conference on Computer Vision. 2021: 14050-14060.

[21] Jo Y, Park J. Sc-fegan: Face editing generative adversarial network with user's sketch and color[C]//Proceedings of the IEEE/CVF international conference on computer vision. 2019: 1745-1753.

[22] Tanaka M, Asano T, Higashino C. Isometric conversion of mechanical sketches into 3D models[J]. Comput-Aided Des Appl, 2020, 18(4): 772-785.