计算可视媒体之二

视频处理技术

任课教师： 王若梅教授
isswrm@mail.sysu.edu.cn

学习目标：

- 掌握视频媒体的基本概念、研究问题及应用前景。
- 学习视频数据处理的基本算法。

考核内容：

研究论文：围绕视频处理的相关技术进行写作。

综述性（题目，摘要，关键字，研究问题及其意义，国内外研究现状，成果举例）

第一章 视频数据处理

1.1 视频

内容随时间变化的一组动态图像(25或30帧/秒)，所以视频又叫作运动图像或活动图像。

具有时间上的连续性和延续性，具有强烈的真实性。

➢视频的应用

- 视频数量飞速增长，视频用户规模逐年扩大
- 视频体量浩大，种类繁多，内容异构、多模态
  面对丰富的视频，我们除了欣赏、参与，还.....

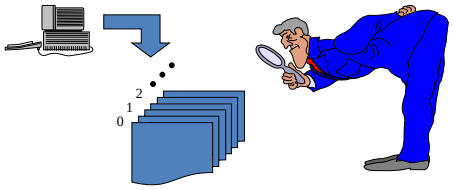

1.2 视频数据的组成

视频数据的组成是视觉通道加上语音通道，也就是视频和音频组成的综合媒体。包含视觉信息(视频画面)、文本信息(视频字幕)、音频信息(视频声音)。

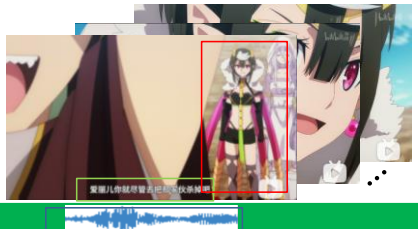

视频帧：文本，图像（人，物，…）

音频文件：声音（文本）

有多少不同的帧？有哪些文字？

视频拆分成视频帧文件和音频文件

✓ 视 频 帧

视频由成千上万的帧组成，视频数据流中 t 时刻的图像帧和 t+1 时刻的图像帧在视觉特征和内容上差别不大。

✓ 音频文件

获取音频文件：从视频文件中分离出音频轨道，并生成指定的音频文件。

FFMPEG是跨平台的开源免费视频、音频流方案，可兼容Linux和Windows操作系统。FFMPEG能够快速实现视频格式转换、切割、合并、音视频分离等操作，在配置好环境后可以直接在命令行调用，也可以用PHP或Python脚本来调用FFMPEG指令，FFMPEG指令格式清晰易读，能大大提高开发效率。

通过python调用：

FFMPEG的指令结构为：

ffmpeg [[options][-i input_file]] …{[options] output_file}，

其中options表示操作参数。

直接在命令行调用：

ffmpeg [[options][-i input_file]] ...{[options] output_file}

◆音频提取示例

- 实现目的：输入一个视频，输出一个WAV格式的音频文件。

News.mp4

News.wav

提取出来的文件

- 实现方法：使用命令行工具FFmpeg直接在命令行执行，也可以在代码中调用该命令。
- 实现过程：

```
#将视频转换成音频wav
def vedio_to_audio(path):
    name = path.split(".")[0]
    newpath = name+".wav"
    call(["ffmpeg", "-i", path, newpath])
    return newpath
```

✓语音识别

- 语音识别技术是指让机器通过识别和理解过程把语音信号转变为相应的文本或命令。语音识别技术主要包括特征提取技术、模式匹配准则及模型训练技术三个方面，属于自然语言处理的范畴。

- 实现目的：将所有音频按顺序转换成文本。

很多互联网公司都已经有较好的语音识别技术，如：百度、谷哥、科大讯飞等。

科大讯飞作为中国最大的智能语音技术提供商，在智能语音技术领域有着长期的研究积累，并在中文语音合成、语音识别、口语评测等多项技术上拥有国际领先的成果。

产业方向

- 语音平台产业方向
- 通信增值产业方向
- 嵌入式产业方向
- 教育产业方向
- 行业软件和系统集成产业方向

- 语音合成技术
- 语音识别技术
- 语音评测技术
- 面对面翻译
- 文字扫描识别
- 方言识别

例如针对科大讯飞开放的语音听写接口，该接口用于60秒内的语音听写，将音频转换为文本信息的技术，支持实时返回识别结果，达到一边上传音频，一边获取识别文本的效果。将生成的音频文件进行60s的分割处理，生成若干指定的音频文件。

News.wav

生成的音频文件

实现过程：

```
#切片函数，参数分别是音频
def cut_audio(audio,cut_path):
    if not os.path.exists(cut_path):
        os.makedirs(cut_path)
    sound = AudioSegment.from_wav(audio)
    audio = audio.to_audio(audio)
    flag = 0
    while size - flag*30 > 30:
        flag = flag + 1
        out_name = cut_path+"/"+str(flag)+".wav"
        call(["ffmpeg", "-ss", time_format(flag-1)+30], "-i",audio, "-c","copy","-f","30",out_name])

    flag = flag + 1
    out_name = cut_path+"/"+str(flag)+".wav"
    call(["ffmpeg", "-ss", time_format(flag-1)+30], "-i",audio, "-c","copy","-s",str(size - (flag-1)*30),out_name])
```

音频格式转换

- 实现目的：将wav音频全部转换成16k、16bit 、单声道、pcm格式。

- 实现过程：

```
#将wav_path文件夹里的wav音频全部转为 16k 16bit 单声道 pcm格式
def wav_to_pcm(wav_path,pcm_path):
    if not os.path.exists(pcm_path):
        os.makedirs(pcm_path)
    input_files = glob.glob(wav_path+"/*.wav")
    length = len(input_files)
    for i in range(length):
        file = wav_path +"/"+str(i-1)+".wav"
        call(["ffmpeg", "-y", "-i", file, "-acodec", "pcm_s16le", "-f", "s16le", "-ac", "1", "-ar", "16000", pcm_path+"/"+str(i-1)+".pcm"])
```

- 实现效果：

```
00:00:18  00:00:33  各位观众晚上好晚上好今天是12月3号星期二农历十一月初八欢迎收看新闻联播节目今天节目的主要
内容有习近平举行仪式欢迎萨尔瓦多总统访华并同萨尔瓦多总统会谈
00:00:33  00:00:37  习近平会见出席2015从都国际论坛外方嘉宾
00:00:37  00:00:42  国务院举行荣誉授予仪式李克强总理参加仪式
00:00:42  00:00:45  李克强会见萨尔瓦多总统
00:00:45  00:00:51  纪念澳门特别行政区基本法实施20周年座谈会在京举行乔晓阳发表讲话
00:00:51  00:00:58  汪洋主持召开全国政协第30次主席会议韩正会见亚洲开发银行行长
00:00:59  00:01:04  中央军委召集关于加强新时代军队高速铁干部工作的座见
00:01:04  00:01:13  曹海各界人士送两岸方以人权为名干预香港事务于涉中国内政坚定支持中央政府对美反制措施
00:01:13  00:01:19  美国两巨关税大棒称对法国巴西阿根廷商品加征关税
00:01:19  00:01:21  接下来请看详细报道
00:01:24  00:01:36  国家主席习近平3号在人民大会堂北大厅举行仪式欢迎萨尔瓦多共和国总统纳伊布阿曼多布克尔廉特
斯对我国进行国事访问
```

- 实现方法：调用科大讯飞的语音识别API来处理音频。
- 实现过程：科大讯飞的官网有提供demo，将其稍加修改即可。

1.3 视频结构的分析

视频数据的特点：

（1）海量性。视频数据所包含的数据量比结构化的数据大七个数量级，若不考虑压缩，如果按照常规的视频标准播放，即 30 帧/秒，则 1 秒的数据量约为 30 M， 600 M 的硬盘只能存储 20 秒的动态图像。

（2）多样性。相比于文字、图像等形式，视频所表现出来的内容更多样，一是底层的特征，比如颜色特征、纹理特征等；二是高层抽象描述上的语义信息。

（3）复杂性。视频是非结构化的数据流，结构非常复杂。视频不同于一维的文本、二维的图像，视频数据是包含时间属性和空间属性的三维数据。因此，数据的表达和建立合适的模型就显得尤为困难。

- 帧（Frame）：视频数据的最小单元，是一副静止的单幅影像画面，相当于电影胶片上的每一格镜头。在时间轴上帧表现为一格或一个标记。
- 视频可以看做是一个连续静态图像的序列，其中的每一幅静态图像称为一帧。

- 镜头（Shot）：是摄像机所记录下来的一段连续的帧序列，代表一个场景中在时间上和空间上连续的动作。
- 任何一段视频数据流都是由许多镜头组成的，镜头是视频数据的基本组成单元。
  - 如，在拍摄“飞机起飞”这组镜头时，画面的色彩和纹理等图像特征将保持不变。
  - 由于在同一组镜头中，属于同一组镜头的图像帧之间的特征保持稳定。
    - 如果相邻图像帧之间的特征发生了明显变化，则认为发生了镜头变化，需要对视频进行切分。

镜头分类示例

- 长镜头(LS)： 显示场景的全貌
- 中镜头(MS)：表现人物的动作，如谈话等
- 短镜头(CU)：近距离刻画人物的表情

长镜头 中镜头 短镜头

- 场景（Scene）：语义上相关和时间上相邻的若干镜头组成了一个场景，场景是视频所蕴涵的高层抽象概念和语义表达，如“学校运动会”这个场景可以由“运动员入场”、“运动员比赛”和“观众呐喊”等镜头组成。

- 视频序列（Video）：由许多场景组成，叙述一个完整的故事结构。
- 相同的场景经过聚类后形成视频序列
- 视频的最高语义就是视频序列

视频的结构

书	⟷	视频	若干镜头或场景的集合
章	⟷	场景	语义上相关,时间上相近的若干镜头
节	⟷	镜头	在时间和空间上连续数帧的集合
页	⟷	帧	基本组成单位独立的图象

视频是非结构化数据流，其结构较复杂，这样就不能很好的实现对视频的管理、组织和检索等功能，因此需要将其转为结构化的数据，提取出所包含的各种特征。

视频内容丰富，但是若无人工添加有效的视频内容标识，视频数据具有无结构性。视频的无结构性表现在，其最大颗粒度是整个视频文件，最小颗粒度是单个视频帧，中间没有任何过渡层次的抽象，这种无结构性意味着用户想要定位到自己感兴趣的内容需要线性地浏览冗长的视频文件。用户经常通过快进或者快退的方式查找其所需要的视频片段，这种方式不但效率低下，而且容易错过很多重要内容，用户体验较差。

1.4 视频结构化处理

随着计算机网络和多媒体技术的蓬勃发展，互联网中视频的种类和数量都正以前所未有的速度快速增加。然而，由于视频数据种类繁多、内容冗长、结构复杂等特点，直接访问无索引的视频数据相对困难。

为了解决用户定位视频内容困难的问题，一种简单的解决办法是通过人工标注的方式为视频添加内容标识，引导用户快速定位。然而人工标注视频内容的过程不但费时而且成本昂贵，面对当今数量不断暴增的视频，这种方式显然是不现实的。视频内容难以定位的问题主要是因为视频数据的无结构性造成的，如果视频数据能像文本数据一样有结构化的目录和索引，用户便能以非线性的方式高效查找想要的视频内容。因此，合理有效地组织视频内容、对视频内容进行结构化处理是解决问题的关键。

视频结构化：是将视频文件层次化的分解为语义单元并为其建立关联关系的过程。其目标是将复杂抽象的视频数据转换成计算机容易处理的格式，从而便于进一步提取、分析视频内容。

通过内容结构化可以在不同的细节层次上对视频进行索引和总结，从而达到快速访问视频内容的目的。

视频内容结构化是视频内容分析的基石，它能将复杂抽象的视频流转化为结构化数据，使得视频内容可索引、易处理。

视频内容具有多通道性，视觉通道的图像信息固然直观重要，但是音频通道的语音信息同样蕴含丰富的视频语义，对视频内容结构化处理具有重要的指导意义。

从视频视觉线索上出发，其涉及镜头分割，关键帧检测，场景边界检测等研究领域；从视频语音线索上出发，其涉及语音识别，文本主题边界检测等研究领域。

1.4.1镜头分割

频视觉通道是由一系列连续变化的帧画面组成的，这些图像是视频视觉内容的直观呈现，对探索视频语义边界具有重要价值。然而这些视频帧视觉特征具有极大的重复性，时长为一秒的视频数据通常包含25到40帧画面，那么时长为一小时的视频数据包含超过7万张以上的帧画面，如果直接分析这些数量巨大，重复度极高的视频帧画面，不仅耗时，而且很难挖掘到有价值的信息。

镜头分割（镜头边界检测）是根据视频帧视觉内容的差异，将内容发生转变的帧画面划分为不同的镜头，相同镜头只保留一帧作为代表帧，过滤掉绝大多数冗余的视频帧。其原理主要是基于视频帧序列，比较帧之间底层特征间的差异，将发生剧烈变化的视频帧划分为不同的镜头。

- 镜头边界是视频相邻两帧出现了某种意义的变化，即镜头边界反映了视频内容的不连续性。

镜头分割算法

经典的方法有像素比较法、基于颜色直方图的方法、基于轮廓检测的方法等。进一步改进产生了许多效果更好的方法（改变了对特征的处理方式，如基于块的方法、各种压缩域中的方法等），有的方法则不从图像直观特征（亮度、颜色、纹理等）入手而改用一些抽象的特征，如矩不变量法、运动矢量法等。最后，对于渐变镜头边界两侧相邻帧的差距不甚明显的情况，还出现了双阈值法、基于统计模型的方法等方法，改善了对渐变镜头边界的检测。

深度学习相结合：使用各种神经网络自主学习语义信息。如果训练样本充分恰当，训练得到的模型往往有十分优良的性能，速度很快、检出率高。

镜头边界检测一般来说是由特征提取、计算相似性和镜头边界判断三部分组成。镜头边界检测的侧重点在于对帧选取合理的特征并进行提取，然后找到合适的镜头边界判断方法。为了确定镜头转换的边界，可以通过设置合理的阈值来判断是否检测到了镜头转换所涉及的图像帧。若帧间差大于阈值，就可以认为是镜头发生了的转变。

（1）镜头分割：像素比较法

像素比较法也称作像素亮度匹配法,其思想是计算相邻两帧对应像素的亮度差值，然后对得到的许多差值做处理（例如，求其平均值、方差、或计算差值大于某个阈值的像素的个数等），将处理后的到的值与一阈值比较。若大于此阈值，则认为发生了镜头转换，即此处为镜头的边界。

从原理看，由于计算了每个像素的亮度值，因此该方法对噪声极为敏感；同时计算差值时，要求相邻两帧的像素之间对应，因此也不能应付过强的镜头运动；最后，阈值的选择也是一个复杂的工作。这种方法虽然缺陷很多，但使用较早，原理简单。

这种方法难以区分小区域中的大变换或者大区域中的小变化，对与渐变的镜头也无法处理。

（2）镜头分割：颜色直方图法

颜色直方图法相对于像素比较法，不再逐像素地比较相邻两帧的差别，而是比较这两帧的直方图的区别。一般的方法是将两帧的直方图作差，然后进行处理（例如求其一个范数）。若得到的值大于某一阈值，则认为这里是镜头的边界。

基于颜色直方图的方法对镜头运动，如旋转、平移有鲁棒性，同时也相对更抗噪声具有，若采用归一化方法，还可使颜色直方图具有对尺度变换的不变性。相对于像素比较法，其缺点是忽略了空间信息,两幅完全不同的图片可能有极相似的颜色直方图。

简单的直方图差

$$d(f,f')=\left|\sum_{j=0}^{N}H(f,j)-H(f',j)\right|$$

（3）镜头分割：压缩域差法

- 不对图像解压，而是直接用JPEG压缩图像帧的DCT系数作为帧相似度衡量的标准。
- 省去解压步骤，直接从原始视频数据流中提取特征，从而加快检测速度。
- 每个压缩域系数保留了原始图像帧中或图像帧间最重要特征，所以压缩域系数可以有效分析视频数据。

（4）镜头分割：轮廓检测法

两个不同的镜头间一般有不同的轮廓，新旧轮廓间一般距离较远。基于轮廓检测的方法利用这样的原理，提取相邻两帧的物体轮廓，然后计算两帧之间轮廓位移的最大值，将该值与一阈值比较，若大于阈值，则认为此处为镜头的边界。

此方法的显著优点是可抗噪声，在视频画面边缘简单的情况下效果很好，但不能很好的处理边缘复杂的情况，容易发生误验。

（5）镜头分割：基于统计的方法

基于机器学习的统计模型方法将镜头检测作为分类任务，采用SVM 等有监督学习和模糊c-均值聚类等无监督学习。即先得到视频帧的特征表示,然后用分类器进行分类。聚类算法消除了镜头边界检测对阈值的依赖性。

（6）镜头分割：基于深度学习的方法

随着人工智能的发展，基于深度学习的方法逐渐受到重视。利用深度学习提取帧的图像特征，在镜头的边界检测上得到了许多突破性的进展。根据使用不同的神经网络，得到的模型特点和性能也不同。使用深度学习的方法，虽然训练较慢，但只要数据合适、大量，得到的模型性能往往能令人满意，检出率高、错误率低、应用范围广，超过传统的各种方法。

小　结

- 镜头边缘检测算法的实质：
  - 如何找到一种或几种良好的视频图像特征，通过判断相邻图像帧之间的特征是否发生剧烈变化，来完成视频镜头边缘检测任务。
  - 定义和选取特征
    - 图像视觉特征，结合文字、听觉特征
  - 设计算法判断特征变化
    - 选取阈值

1.4.2 关键帧提取

- 视频数据流中的图像帧之间存在时间和空间冗余度
- 可以从视频中找一些代表性的帧(即关键帧)，用这些少量的帧来代表冗长的视频数据流，使用户看过关键帧后，就能知道了解整个视频数据流所蕴涵的内容，再通过提取这些帧的底层信息来建立索引，方便用户对视频内容查询。

- 关键帧：关键帧是镜头的代表，也是视频检索的重要依据，关键帧要能够反映镜头中的主要运动和变化。
- 一幅能描述镜头主要内容的帧。根据内容复杂度，一个镜头可以有一个或多个关键帧。
- 关键帧的作用类似于文本检索中的关键词。用关键帧来代表镜头，使得对视频镜头可用图像的技术进行检索

关键帧提取的意义

- 减少视频帧间存在的大量冗余信息内容
- 更凝炼地表达一段视频中包含的信息，便于对视频内容建立索引、管理。

减少冗余信息

- 视频由成千上万的帧组成，视频数据流中t时刻的图像帧和t+1时刻的图像帧在视觉特征和内容上差别不大。
- 人们从由成千上万存在冗余的图像帧提取出"关键图像帧"，而且使用这些关键图像帧表示视频，会更加简洁。这是在视频内容分析中提取视频关键帧的原因之一。

快速全面了解视频的内容

- 对于只想了解大致视频内容的用户而言，他们并不愿意花很多时间观看每一帧。
- 提取关键帧可以极大地节约用户的欣赏时间。用户通过关键帧，能了解整个视频数据流所蕴含的内容。
- 在通过提取关键帧的底层信息来建立索引，方便用户对视频内容的查询。

关键帧提取遵循3个原则：

①能够反映视频、场景或镜头的主要事件。
②数据量应尽量小。
③计算不宜太过复杂，在避免选取的关键帧不发生漏选的基础上尽量不要出现冗余关键帧的现象。

关键帧提取的基本方法

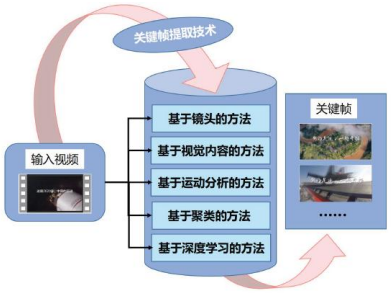

✓ 基于抽样的方法

- **思想**：基于抽样的方法是一种比较简单的方法，这种方法一般通过随机的抽取几帧、或者规定间隔抽取关键帧、或者规定每个镜头提取的帧数然后等间隔抽取。
- **优点**：这种方法的优点是简单快速。
- **缺点**：这种方法具有明显的缺点即不能够有效的表达视频的内容。当镜头很短时可能只能抽取到一个关键帧，这可能导致一些重要信息丢失，而对于一些比较长的视频镜头片断，可能会有很多相似的关键帧被提取出来，这样关键帧提取的目的没有达到。

✓ 基于镜头边界法

- 一段视频被分割成若干镜头后，一种最直接、最简单的关键帧提取方法就是将每个镜头的首帧、中间帧以及末帧作为镜头的关键帧。
- **缺点**：以镜头首帧或尾帧或首帧加尾帧为关键帧，这种方法虽简单，但它不考虑当前视觉内容的复杂性，并且限制了镜头关键帧的个数，使长短不同和内容不同的视频镜头有相同个数关键帧，这样做并不合理，事实上首帧或尾帧往往并非关键帧，不能精确地代表镜头信息。

✓ 基于颜色特征法

- **思想**：将镜头当前帧与最后一个判断为关键帧的图像进行比较，如有较多特征发生改变，则当前帧为新的一个关键帧。

  在实际中，可以将视频镜头第一帧作为关键帧，然后比较后面视频帧图像与关键帧的图像特征是否发生了较大变化，逐渐得到后续关键帧。

基于颜色特征法

- **优点**：按照这个方法，对于不同的视频镜头，可以提取出数目不同的关键帧，而且每个帧之间的颜色差别较大。
- **缺点**：对摄像机的运动（如摄像机镜头拉伸造成焦距的变化及摄像机镜头平移的转变）很不敏感，无法量化地表示运动信息的变化，会造成关键帧提取不稳健。

✓ 基于光流的运动分析

- 上述方法都没有考虑运动特征。
- 通过光流分析来计算镜头中的运动量，在运动量取局部最小值处选取关键帧，它反映了视频数据中的一个“静止”特点，视频中通过摄像机在一个新的位置上停留或通过人物的某一运动的短暂停留来强调其重要性。

✓ 基于聚类的关键帧提取

- 聚类方法在人工智能、模式识别和语音识别等领域中有着很广泛的应用，也可以使用聚类方法来提取镜头关键帧。
- **实现步骤**：
- 第一步：设某个镜头S_i包含n个图像帧，可以表示为$S_i=\{Fi_1, \ldots, Fi_n\}$，其中$Fi_1$为首帧，$Fi_n$为尾帧。如果相邻两帧之间的相似度定义是这相邻两帧颜色直方图的相似度（也即是直方图特征差别），预定义一个阈值δ控制聚类的密度。

基于聚类的关键帧提取

- 第二步：计算当前帧Fi_i与现存某个聚类质心间的相似度，如果该值小于δ，则该帧与该聚类之间距离较大，因此，Fi_i不能加入该聚类中。如Fi_i与所有现存聚类质心相似度均小于δ，则Fi_i形成一个新的聚类，Fi_i为新聚类的质心；否则将该帧加入到与之相似度最大的聚类中，使该帧与这个聚类的质心之间的距离最小。

基于聚类的关键帧提取

- 第三步：通过上面方法将镜头S_i所包含的n个图像帧，分别归类到不同聚类后，就可以选择关键帧：从每个聚类中抽取离聚类质心最近的帧作为这个聚类的代表帧，所有聚类的代表帧就构成了镜头S_i的关键帧。
- 假设镜头S_i形成了*cluster*个聚类，那么就可以从镜头S_i中提取*cluster*个关键帧。

基于聚类的关键帧提取

- **特点**：该聚类算法由阈值δ控制，δ越大，形成的聚类数目越多，镜头S_i划分越细，选择的关键帧也越多；反之，δ越小，所形成的聚类个数越少，镜头S_i划分越粗。

基于聚类的关键帧提取

优点：该方法不仅计算效率高，它还能有效地获取视频镜头的显著视觉内容。

聚类算法基本上是一个非监督过程，用户只要提供聚类参数δ，那么聚类与关键帧提取等过程就可以自动完成，不需要人工干预，因此效率较高。

缺点：聚类算法最大的限制是聚类参数δ是否恰当，从上面对动作片与生活片视频关键帧提取可以知道，对于不同的应用，聚类参数δ的设置就差别较大，因此一个普遍的聚类参数δ获取是相当困难的。