第二章 视频文本信息处理

2.1 获取候选词

视频处理中涉及到大量的文本信息（视频的音频文本信息，视频字幕信息等），需要分别对它们进行预处理，从而分别得到候选词（分词）集合。分词是自然语言处理（NLP）的重要步骤，分词就是将句子、段落、文章这种长文本，分解为以字词为单位的数据结构，方便后续的处理分析工作。主要通过分句、分词、去停用词等操作，最后得到候选词。

- 句子：生活就像海洋，只有意志坚强的人才能到达彼岸。
- 分词：生活\就像\海洋，只有\意志\坚强\的\人\才能\到达\彼岸。

✓ 为什么要进行分词？

1、将复杂问题转化为数学问题

机器学习之所以看上去可以解决很多复杂的问题，是因为它把这些问题都转化为了数学问题。而 NLP 也是相同的思路，文本都是一些「非结构化数据」，我们需要先将这些数据转化为「结构化数据」，结构化数据就可以转化为数学问题了，而分词就是转化的第一步。

2、词是一个比较合适的粒度

词是表达完整含义的最小单位。字的粒度太小，无法表达完整含义，比如“鼠”可以是“老鼠”，也可以是“鼠标”。而句子的粒度太大，承载的信息量多，很难复用。

3、分词是进行关键词提取的必要步骤

关键词提取算法都需要对文本进行分词后才能进行处理。

✓ 中英文分词的三个典型区别

1、分词方式不同，中文更难

英文有天然的空格作为分隔符，但是中文没有。所以如何切分是一个难点，再加上中文里一词多意的情况非常多，导致很容易出现歧义。

2、英文单词有多种形态

英文单词存在丰富的变形变换。为了应对这些复杂的变换，英文NLP相比中文存在一些独特的处理步骤，称为词形还原（Lemmatization）和词干提取（Stemming）。中文则不需要。

-词性还原：does，done，doing，did 需要通过词性还原恢复成 do。

-词干提取：cities，children，teeth 这些词，需要转换为 city，child，tooth”这些基本形态

3、中文分词需要考虑粒度问题

例如「中国科学技术大学」就有很多种分法：

- 中国科学技术大学
- 中国\科学技术\大学
- 中国\科学\技术\大学

粒度越大，表达的意思就越准确，但是承载的信息量也会过多。所以中文需要不同的场景和要求选择不同的粒度。这个在英文中是没有的。

✓ 中文分词的三大难点

1、没有统一的标准

目前中文分词没有统一的标准，也没有公认的规范。不同的公司和组织各有各的方法和规则。

2、歧义词如何切分

例如「兵乓球拍卖完了」就有2种分词方式表达了2种不同的含义：

- 兵乓球\拍卖\完了
- 兵乓球拍\卖\完了

3、新词的识别

信息爆炸的时代，三天两头就会冒出来一堆新词，如何快速的识别出这些新词是一大难点。比如去年的「新冠病毒」，就需要快速识别。

2.2 三种典型的分词方法

基于词典匹配的分词方法：将待分词的中文文本根据一定规则切分和调整，然后跟词典中的词语进行匹配，匹配成功则按照词典的词分词，匹配失败通过调整或者重新选择，如此反复循环即可。代表方法有基于正向最大匹配和基于逆向最大匹配及双向匹配法。

✓ 优点：速度快，成本低

✓ 缺点：适应性不强，不同领域效果差异大

基于统计的分词方法：这类目前常用的算法是HMM、CRF、SVM等算法，比如stanford、Hanlp分词工具是基于CRF算法。以CRF为例，基本思路是对汉字进行标注训练，不仅考虑了词语出现的频率，还考虑上下文，具备较好的学习能力，因此其对歧义词和未登录词的识别都具有良好的效果。

- 优点：成本较高，速度较慢
- 缺点：适应性较强

基于深度学习的分词方法：例如有人员尝试使用双向LSTM+CRF实现分词器，其本质上是序列标注，所以有通用性，命名实体识别等都可以使用该模型，其分词器字符准确率可高达97.5%。

常见的分词器都是使用机器学习算法和词典相结合，一方面能够提高分词准确率，另一方面能够改善领域适应性。

开源分词工具：利用现有的工具进行分词处理。

2.3 关键词提取

文本关键词提取

问题背景：伴随着信息时代的到来，数据量呈现出指数级增长，我们从过去的信息匮乏的时代，进入到了一个信息过载的时代，人们无法快速准确地从纷繁复杂的数据中获取自己想要的信息。

解决方案：
（1）**文本关键词**
（2）文章摘要
（3）视频缩略图
…

信息过载主要表现为：
1、受传者对信息反映的速度远远低于信息传播的速度；
2、大众媒介中的信息量大大高于受众所能消费、承受或需要的信息量；
3、大量无关的没用的冗余的数据信息严重干扰了受众对相关有用信息的准确性的选择。

关键词是能够表达文档中心内容的词语，是用户获取信息的简化词汇，常用于计算机系统标引论文内容特征、信息检索、系统汇集以供读者检阅。

关键词提取是文本挖掘领域的一个分支，是对文本信息进行高度凝练的一种有效手段，通过3-5个词语准确概括文本的主题，帮助读者快速理解文本信息。是文本检索、文档比较、摘要生成、文档分类和聚类等文本挖掘研究的基础性工作。

提取关键词就是要提取“核心信息”，提取恰当的词语来表达中心内容。关键词一般是名词、动词、形容词，不会是虚词。关键词一定是语段中出现的原词。

关键词提取算法主要有两类：无监督关键词提取方法和有监督关键词提取方法。无监督方法不需要人工标注训练集合的过程，因此更加快捷，但由于无法有效综合利用多种信息对候选关键词排序，所以效果无法与有监督方法媲美；而有监督方法可以通过训练学习调节多种信息对于判断关键词的影响程度，因此效果更优，有监督的文本关键词提取算法需要高昂的人工成本，因此现有的文本关键词提取主要采用适用性较强的无监督关键词提取。

无监督关键词抽取算法可以分为三大类，基于**统计特征**的关键词抽取、基于**词图模型**的关键词抽取和**基于主题模型**的关键词抽取。

基于统计特征的关键词提取算法的思想是利用文档中词语的统计信息抽取文档的关键词；

基于词图模型的关键词提取首先要构建文档的语言网络图，然后对语言进行网络图分析，在这个图上寻找具有重要作用的词或者短语，这些短语就是文档的关键词；

基于主题关键词提取算法主要利用的是主题模型中关于主题分布的性质进行关键词提取。

2.4 基于TF-IDF的文本关键词抽取方法

TF-IDF是一种统计方法，用以评估一字词对于一个文件集或一个语料库中的其中一份文件的重要程度。 TFIDF算法是建立在这样一个假设之上的：如果某个词或短语在一篇文章中出现的频率TF高，并且在其他文章中很少出现，则认为此词或者短语具有很好的类别区分能力，适合用来分类 。IDF的主要思想是：如果包含词条t的文档越少，也就是*n*越小，IDF越大，则说明词条t具有很好的类别区分能力。

TF-IDF关键词抽取算法的思想是利用文档中词语的统计信息抽取文档的关键词。通常将文本经过预处理得到候选词语的集合，然后采用特征值量化的方式从候选集合中得到关键词。基于统计特征的关键词抽取方法的关键是采用什么样的特征值量化指标的方式。

基于统计特征的关键词抽取方法的关键是采用什么样的特征值量化指标的方式。

1、基于词权重的特征量化：基于词权重的特征量化主要包括词性、词频、逆向文档频率、相对词频、词长等。
2、基于词的文档位置的特征量化：这种特征量化方式是根据文章不同位置的句子对文档的重要性不同的假设来进行的。通常，文章的前N个词、后N个词、段首、段尾、标题、引言等位置的词具有代表性，这些词作为关键词可以表达整个的主题。
3、基于词的关联信息的特征量化：词的关联信息是指词与词、词与文档的关联程度信息。

基于统计特征的关键词提取算法通过上面的一些特征量化指标将关键词进行排序，获取Top *k*个词作为关键词。基于统计特征的关键词的重点在于特征量化指标的计算，不同的量化指标得到的记过也不尽相同。同时，不同的量化指标作为也有其各自的优缺点，在实际应用中，通常是采用不同的量化指标相结合的方式得到Top *k*个词作为关键词。

词频（Term Frequency，TF）

指某一给定词语在当前文件中出现的频率。由于同一个词语在长文件中可能比短文件有更高的词频，因此根据文件的长度，需要对给定词语进行归一化，即用给定词语的次数除以当前文件的总词数。

逆向文件频率（Inverse Document Frequency，IDF）

这是一个词语普遍重要性的度量。即如果一个词语只在很少的文件中出现，表示更能代表文件的主旨，它的权重也就越大；如果一个词在大量文件中都出现，表示不清楚代表什么内容，它的权重就应该小。

$$\text{词频（TF）}=\frac{\text{词w在文档中出现的次数}}{\text{文档的总词数}}$$

$$\text{逆文档频率（IDF）}=\log\left(\frac{\text{语料库的文档总数}}{\text{包含词w的文档数+1}}\right)$$

TF-IDF=TF*IDF

TF-IDF是对文本所有候选关键词进行加权处理，根据权值对关键词进行排序。假设D_n为测试语料的大小，该算法的关键词抽取步骤如下所示：

（1） 对于给定的文本*D*进行分词、词性标注和去除停用词等数据预处理操作。本分采用结巴分词，最终得到*n*个候选关键词，即$D=[t_1,t_2,\ldots,t_n]$；

（2） 计算词语t_i 在文本*D*中的词频；

（3） 计算词语t_i在整个语料的IDF=log (D_n /(D_t +1))， D_t为语料库中词语t_i出现的文档个数；

（4） 计算得到词语t_i的TF-IDF=TF*IDF，并重复（2）-（4）得到所有候选关键词的TF-IDF数值；

（5） 对候选关键词计算结果进行倒序排列，得到排名前Top *N*个词汇作为文本关键词。

TF-IDF的优点是实现简单，相对容易理解。但是，TFIDF算法提取关键词的缺点也很明显，严重依赖语料库，需要选取质量较高且和所处理文本相符的语料库进行训练。另外，对于IDF来说，它本身是一种试图抑制噪声的加权，本身倾向于文本中频率小的词，这使得TF-IDF算法的精度不高。TF-IDF算法还有一个缺点就是不能反应词的位置信息，在对关键词进行提取的时候，词的位置信息，例如文本的标题、文本的首句和尾句等含有较重要的信息，应该赋予较高的权重。

TF-IDF应用

（1）搜索引擎；（2）关键词提取；（3）文本相似性；（4）文本摘要

2.5 基于TextRank的文本关键词抽取方法

基于词图模型的关键词抽取首先要构建文档的语言网络图，然后对语言进行网络图分析，在这个图上寻找具有重要作用的词或者短语，这些短语就是文档的关键词。语言网络图中节点基本上都是词。

在语言网络图的构建过程中，都是以预处理过后的词作为节点，词与词之间的关系作为边。语言网络图中，边与边之间的权重一般用词之间的关联度来表示。在使用语言网络图获得关键词的时候，需要评估各个节点的重要性，然后根据重要性将节点进行排序，选取Top k个节点所代表的词作为关键词。

节点的重要性计算方法有以下几种方法：**综合特征法，系统科学法，随机游走法。**

✓ 基于PageRank的文本关键词抽取方法

PageRank算法是Google的创始人拉里·佩奇和谢尔盖·布林于1998年在斯坦福大学读研究生期间发明的，是用于根据网页间相互的超链接来计算网页重要性的技术，主要用于对在线搜索结果中的网页进行排序。

基本思想：如果我们要计算网页A的PageRank值（以下简称PR值），那么我们需要知道有哪些网页链接到网页A，也就是要首先得到网页A的入链，然后通过入链给网页A的投票来计算网页A的PR值。这样设计可以保证达到这样一个效果：当某些高质量的网页指向网页A的时候，那么网页A的PR值会因为这些高质量的投票而变大，而网页A被较少网页指向或被一些PR值较低的网页指向的时候，A的PR值也不会很大，这样可以合理地反映一个网页的质量水平。

$$S(V_i) = (1-d) + d * \sum_{j \in In(V_i)} \frac{1}{|Out(V_j)|} S(V_j)$$

$$S(V_i) = (1-d) + d * \sum_{j \in In(V_i)} \frac{1}{|Out(V_j)|} S(V_j)$$

该公式中，V_i表示某个网页，V_j表示链接到V_i的网页（即V_i的入链），$S(V_i)$表示网页V_i的PR值，$In(V_i)$表示网页V_i的所有入链的集合,$Out(V_j)$表示网页V_j的对外链接集合，d表示阻尼系数，所有加入了一个阻尼系数来确保每个网页都有一个大于0的PR值，根据实验的结果，在0.85的阻尼系数下，大约100多次迭代PR值就能收敛到一个稳定的值，而当阻尼系数接近1时，需要的迭代次数会陡然增加很多，且排序不稳定。

根据上述公式计算出每个网页的PR值，在不断迭代趋于平稳的时候，停止迭代运算，得到最终结果。

从公式中可以看到这是一个迭代公式，所以存在“先有鸡还是先有蛋”的问题，对于这个问题，解决办法是给每一个节点一个初始值，一般是$1/N$，N即N个网页。

假设 $S(V_A)=S(V_B)=S(V_C)=S(V_D)=S(V_E)=\frac{1}{5}$

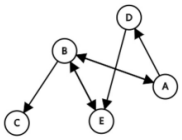

第一轮：

$$S(V_A) = \sum_{j \in In(V_A)} \frac{1}{|Out(V_j)|} S(V_j) = \left(\frac{1}{|Out(V_B)|} S(V_B)\right) = \left(\frac{1}{3} * S(V_B)\right) = \frac{1}{3} * \frac{1}{5} = 0.067$$

矩阵表示下的计算方式：邻接矩阵

$$G = \begin{bmatrix} 0 & 1 & 0 & 0 & 0 \\ 1 & 0 & 0 & 0 & 1 \\ 0 & 1 & 0 & 0 & 0 \\ 1 & 0 & 0 & 0 & 0 \\ 0 & 1 & 0 & 1 & 0 \end{bmatrix}$$

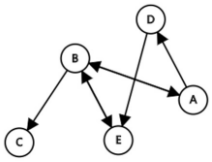

我们可以计算出概率转移矩阵：第i行表示进入到第i个节点的概率分布，而第j列，表示第j个节点的出节点概率分布。

$$W = \begin{bmatrix} 0 & 1/3 & 0 & 0 & 0 \\ 1/2 & 0 & 0 & 0 & 1 \\ 0 & 1/3 & 0 & 0 & 0 \\ 1/2 & 0 & 0 & 0 & 0 \\ 0 & 1/3 & 0 & 1 & 0 \end{bmatrix}$$

我们可以用一个5维列向量S表示5个节点的概率初始值,也就是一个随机向量。

$$(S)^0 = (1/5 \quad 1/5 \quad 1/5 \quad 1/5 \quad 1/5)^T$$

则有：

$$(S)^n = W(S)^{n-1}$$

$$\boxed{(S)^n = [W(S)^{n-1}, 1]\begin{bmatrix} d \\ 1-d \end{bmatrix}}$$

我们利用矩阵运算来进行前面的迭代公式计算

$$(S)^1 = (0.067 \quad 0.3 \quad 0.067 \quad 0.1 \quad 0.267)^T$$

$$(S)^{100} = (2.04*10^{-8} \quad 4.84*10^{-8} \quad 2.04*10^{-8} \quad 1.11*10^{-8} \quad 3.44*10^{-8})^T$$

$$(S)^1 = (0.207 \quad 0.405 \quad 0.207 \quad 0.235 \quad 0.377)^T$$

$$(S)^{100} = (0.405 \quad 0.898 \quad 0.405 \quad 0.322 \quad 0.678)^T$$

✓ 基于TextRank的文本关键词抽取方法

TextRank算法是Mihalcea和Tarau于2004年在研究自动摘要提取过程中所提出来的，在PageRank算法的思路上做了改进。该算法把文本拆分成词汇作为网络节点，组成词汇网络图模型，将词语间的相似关系看成是一种推荐或投票关系，使其可以计算每一个词语的重要性。

在这个任务中，词就是Graph中的节点，而词与词之间的边，则利用“共现”关系来确定。所谓“共现”，就是共同出现，**即在一个给定大小的滑动窗口内的词，**认为是共同出现的，而这些单词间也就存在着边。

“淡黄的长裙，蓬松的头发 牵着我的手看最新展出的油画”

分词后：

淡黄 长裙 蓬松 头发
牵 我 手 看 最新 展出 油画

给定窗口为2，依次滑动

淡黄 长裙
长裙 蓬松
蓬松 头发
牵 我
我 手

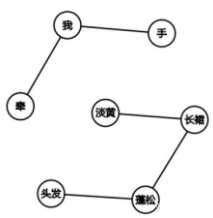

不难发现，相对于PageRank里的无权有向图，这里建立的是无权无向图。

$$WS(V_i) = (1-d) + d * \sum_{V_j \in In(V_i)} \frac{w_{ji}}{\sum_{V_k \in Out(V_j)} w_{jk}} WS(V_j)$$

可以看出，该公式仅仅比PageRank多了一个权重项W_{ji}，用来表示两个节点之间的边连接有不同的重要程度。一般来说W_{ji}的值为文章中第j个单词和第i个单词在一定窗口大小的共现次数。

基于TextRank的文本关键词抽取方法

（1） 对文本*D*进行分词、词性标注和去除停用词等数据预处理操作。 最终得到*n*个候选关键词，即$D=[t_1,t_2,\ldots,t_n]$；
（2） 构建候选关键词图*G*=(*V*,*E*)，其中*V*为节点集（由候选关键词组成），并采用共现关系构造任两点之间的边，两个节点之间仅当它们对应的词汇在长度为*K*的窗口中共现则存在边，*K*表示窗口大小即最多共现*K*个词汇；
（3） 根据公式迭代计算各节点的权重，直至收敛；
（4） 对节点权重进行倒序排列，得到排名前Top *N*个词汇作为文本关键词。

2.6 LDA 主题模型

- 主题就是一个概念、一个方面。它表现为一系列相关的词语。
- 如果用数学来描述一下的话，主题就是词汇表上词语的条件概率分布。与主题关系越密切的词语，它的条件概率越大，反之则越小。
- 通俗来说，一个主题就好像一个“桶”，它装了若干出现概率较高的词语。这些词语和这个主题有很强的相关性，或者说，正是这些词语共同定义了这个主题。

为什么要引入主题模型？

- 文档之间是否相关往往不只决定于字面上的词语重复，还取决于文字背后的语义关联。对语义关联的挖掘，可以让我们的搜索更加智能化。主题模型是对文字隐含主题进行建模的方法。它克服了传统信息检索中文档相似度计算方法的缺点，并且能够在海量互联网数据中自动寻找出文字间的语义主题。
- 在传统信息检索领域里，实际上已经有了很多衡量文档相似性的方法，比如经典的VSM模型。然而这些方法往往基于一个基本假设：文档之间重复的词语越多越可能相似。这一点在实际中并不尽然。很多时候相关程度取决于背后的语义联系，而非表面的词语重复。

隐含狄利克雷分布（Latent Dirichlet Allocation，LDA），是一种主题模型（topic model），是一种无监督学习算法。它可以将文档集中每篇文档的主题按照概率分布的形式给出。LDA是一种典型的词袋模型，即它认为一篇文档是由一组词构成的一个集合，词与词之间没有顺序以及先后的关系。一篇文档可以包含多个主题，文档中每一个词都由其中的一个主题生成。

它能够发现文档-词语之间所蕴含的潜在语义关系（即主题）——将文档看成一组主题的混合分布，而主题又是词语的概率分布——从而将高维度的“文档-词语”向量空间映射到低维度的“文档-主题”和“主题-词语”空间，有效提高了文本信息处理的性能。

LDA是一种典型的词袋模型，即它认为一篇文档是由一组词构成的一个集合，词与词之间没有顺序以及先后的关系。一篇文档可以包含多个主题，文档中每一个词都由其中的一个主题生成。

主题模型的优点？

1、它可以衡量文档之间的语义相似性。对于一篇文档，我们求出来的主题分布可以看作是对它的一个抽象表示。对于概率分布，我们可以通过一些距离公式来计算出两篇文档的语义距离，从而得到它们之间的相似度。

2、它可以解决多义词的问题。“苹果”可能是水果，也可能指苹果公司。通过我们求出来的“词语－主题”概率分布，我们就可以知道“苹果”都属于哪些主题，就可以通过主题的匹配来计算它与其他文字之间的相似度。

3、它可以排除文档中噪音的影响。一般来说，文档中的噪音往往处于次要主题中，我们可以把它们忽略掉，只保持文档中最主要的主题。

4、它是无监督的，完全自动化的。我们只需要提供训练文档，它就可以自动训练出各种概率，无需任何人工标注过程。

5、它是跟语言无关的。任何语言只要能够对它进行分词，就可以进行训练，得到它的主题分布。

- 主题模型LDA（latent dirichlet allocation）的应用还是很广泛的，在检索、图像分类、文本分类、用户评论的主题词抽取，做feature、降维等。例如可以用主题维度来表示原来的字典维度，大大的降低了文本表示的维度。通过一些聚类等的思想，将一些细粒度的特征组合到一个新的空间上去，例如主题空间。

2.7 有监督关键词提取方法

有监督关键词提取方法：将关键词抽取过程视为二分类问题，先提取出候选词，然后对于每个候选词划定标签，要么是关键词，要么不是关键词，然后训练关键词抽取分类器。当新来一篇文档时，提取出所有的候选词，然后利用训练好的关键词提取分类器，对各个候选词进行分类，最终将标签为关键词的候选词作为关键词。

该方法包括了SVM、朴素贝叶斯等有监督学习方法，以及K-means等无监督学习方法。在此类方法中，模型的好坏取决于特征提取，而深度学习正是特征提取的一种有效方式。

2.6.1 Word2Vec词聚类的文本关键词抽取方法

Word2Vec词聚类文本关键词抽取方法的主要思路是对于用**词向量**表示的文本词语，通过K-Means算法对文章中的词进行聚类，选择聚类中心作为文章的一个主要关键词，计算其他词与聚类中心的距离即相似度，选择top N个距离聚类中心最近的词作为文本关键词，而这个词间相似度可用Word2Vec生成的向量计算得到。

- 诸如学习等有监督算法需要的输入类型是**数值型数据**（即本身至少有一定含义的数字），而文本（自然语言）与图像、音频等较为底层的信号型数值数据不同，语言是为了表达具体的事物、抽象的观念及各种概念之间的联系的人类思维产物，抽象程度较高，无法像信号（音视频等）一样被直接使用。
- 为了将算法应用到文本处理领域，需要选择一定的方法将文本转化为数值型数据。字符的编码（如Unicode）**本身并无含义**，只是建立了计算机存储单元与字符的映射关系，并不反应语言本身所代表的抽象对象。由此引出了各种词信息的处理方法，这里将展示的就是将词迁移（嵌入）到向量空间的词向量方法。

➢ 词向量的意义

- 词向量是一种寻找**向量空间**中词的表示的方法，即通过构建机器学习的网络将词嵌入到词向量空间中。
- 为什么词向量是一个合格的文本 - 数值型数据转换方法：在向量空间中，距离并不仅仅能用于“同义词”这种语义上较低阶的相似性计算，还可以完成诸如

  v(“King”) - v(“Man”) + v(“Woman”) = v(“Queen”)

  v(“biggest”) - v(“big”) + v(“small”) = v(“smaller”)

这样简单的**算术运算**，得到“France is to Paris as Germany is to Berlin”、“Paris - France + Italy = Rome”这种类型的结论。因而，词向量通过空间关系表达了与词本身抽象含义、关系有关的信息，一定程度上满足了对数值型数据的需求.

➢ Word2Vec的提出

- 2013年，Google的Tomas Mikolov、Kai Chen、Greg Corrado、Jeffrey Dean等人在Efficient Estimation of Word Representations in Vector Space中提出了Word2Vec算法，从该篇开山论文的题目即可看出，Word2Vec选择词向量作为词的数据化表示。
- Mikolov等人选择了**词相似性测试**作为嵌入效果的评价指标，基于Word2Vec生成的词向量对词法句法、语义等问题进行回答并测试其准确率，测试的结果为转化后数据的可用性提供了背书。同时，这一方法在当时的算力条件下可以在一天之内完成约包含16亿词汇的超大数据集的词向量学习构建，**算法效率较高**，这是如今NLP任务需要面对的语料规模越来越巨大的情况下一个算法需要的重要品质。

➢ Word2Vec的前身——NNLM

- NNLM（Neural network based language model）是早些时候提出的NLP算法，其搭建了神经网络模型来完成对应的任务。其中，**词向量大致是在第一层中习得**，此后便将其用于后续模型的训练，也即词向量的构建仅仅需要NNLM的一部分而不是整个网络模型。
- NNLM的投影层、隐藏层、输出层使得算法复杂度达到Q=N×D+N×D×H+H×V，其中N为输入词（通常为上下文词）数量，D为投影维度，H为隐藏层尺寸，V为字典（词库）大小。使用二叉树编码将最大的系数V对数化后，复杂度的新主要项N×D×H依然很大。

➢ Word2Vec算法模型

- 为了**高效、专一**完成词向量嵌入任务，Word2Vec通过对NNLM的提取部分进行分离、扩展以及消除hidden layers达到了嵌入词向量的高效方法，设计了下述两种不同思路的模型。

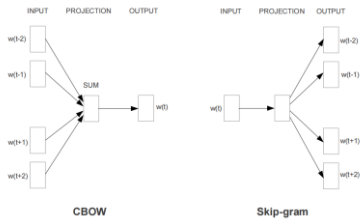

➢ CBOW（Continuous Bag of Words）

- *“The CBOW architecture predicts the current word based on the context.”*
- BOW指不考虑词的顺序而简单地使用窗口以将前后单词均加入计算的词袋模型，C则蕴含了这种训练框架下，模型会隐含地将文本的上下文信息包含（通过多个词的相互作用），而不是仅仅考虑窗口内的信息与关系。
- NNLM等模型的高复杂度很大程度上是非线性的隐藏层导致的。由于面临的语料库、隐藏层规模等很大，CBOW采取了精度换速度的策略：移除隐藏层，将投影层多合一，即参数共享（仅一个投影矩阵，多个input的投影结果取平均），这一修改产生的模型表现的任务形式是**输入周围单词，对当前单词进行推测**，而时间复杂度则优化到了Q=N×D+D×log2(V)这一量级。

➢ Skip - gram

- *"The Skip - gram predicts surrounding words given the current word."*
- **与CBOW的方向相反**，Skip - gram使用连续投影层构建的模型，**基于输入的“当前单词”预测特定窗口内的前后词语。**
- 训练时随机选择一个数R∈[1,C]作为实际距离，C为前或后的最大距离，以当前词为输入，前后各R个词的Softmax概率作为输出（标签）。速度大致为Q=C×(D+D×log2(V))。

➢ 基于Word2Vec的关键词抽取

- 获得了词的数据化表示（且是高效的表示）后的工作便相对trivial，一种思路是采用**K - means**对从候选词抽取的词向量（其实也就代表了候选词本身）进行**聚类**以评估候选词的重要性，从而完成关键词提取的任务。
- 这一方法的假设即是：文本由大量不同词组成，而这些词通常属于**少数几个不同类别**，关键词便可理解为代表这些不同类别的主要词，即通过K个关键词分别反映文本中K类词的**主要特征**。这同时也蕴含了对**相似度较高的关键词进行取舍**、剔除的过程。

➢ K - means

- 聚类算法旨在数据中发现数据对象之间的关系，将数据进行分组，使得**组内的相似性尽可能的大，组间的相似性尽可能的小。**

1. K - means首先根据需要设定需要获得的类个数（即K），并在向量空间中随机指派K个聚类中心。
2. 将所有词向量各自聚类（分配其对应的中心点）至其距离最近的聚类中心。
3. 由于初始中心是随机指派的，未必很好地反映了实际的或足够好的位置，因而通过平均（mean(s)）的方式对K个中心点进行重新计算（调整优化中心位置），而后回到第（2）步进行迭代。

- 通过上述步骤不断迭代对作为dataset的文章中的词进行聚类，聚类完成后选择聚类中心作为文章的一个主要关键词，计算其他词与聚类中心的距离即相似度，选择topK个距离聚类中心最近的词作为文本关键词，而这个词间相似度可用Word2Vec生成的向量计算得到（如通过欧氏距离）。

Word2Vec词聚类文本关键词抽取方法流程

（1） 对于给定的文本D进行分词，得到n个候选关键词，即$D=[t_1,t_2,\ldots,t_n]$；
（2） 遍历候选关键词，从词向量文件中抽取候选关键词的词向量表示，即$WV=[v_1, v_2, \ldots, v_m]$；
（3） 对候选关键词进行K-Means聚类，得到各个类别的聚类中心；
（4） 计算各类别下，组内词语与聚类中心的距离（欧几里得距离），按聚类大小进行升序排序；
（5） 对候选关键词计算结果得到排名前Top N个词汇作为文本关键词。
步骤（3）中需要人为给定聚类的个数，步骤（4）中计算各词语与聚类中心的距离，常见的方法有欧式距离和曼哈顿距离，例如欧式距离计算公式如下：

$$d = \sqrt{(x_1 - x_2)^2 + (y_1 - y_2)^2 + (z_1 - z_2)^2}$$

总　结

1，作为基于词嵌入的词向量模型，word2vec模型不仅训练高效，同时获得的词向量的质量也非常好，能够捕捉到词与词之间的语义关系，能够克服基于TF-IDF的关键词提取算法无法挖掘文本中的真实语义信息的缺点，将word2vec融入到聚类算法和TextRank算法能够获得效果非常好的文本关键词提取算法，简单高效。

2，随着深度学习的发展，基于深度学习预训练模型的词向量模型例如Bert，GPT等模型展现出比word2vec更加优越的性能，能够更好的挖掘文本中的高层语义信息，因此目前也得到了越来越广泛的关注，所以，文本关键词提取算法也随之得到了进一步的改进。