第三章 教育类视频信息处理

3.1 研究背景与意义

多媒体和网络传输技术的快速发展对在线教育的广泛普及起了巨大地推动作用。尤其是近年来大规模在线开放课程的快速兴起，吸引了成千上万的学习者加入到虚拟学习社区中来。教育类视频作为开放教育资源的重要组成部分，已经成为数字化学习领域知识传播的重要媒介之一。

教育类视频不仅体量浩大、种类繁多，而且其信息还呈现出了多通道、多模态和异构等特点。如何有效地提取、挖掘和应用教育类视频多模态数据已经成为信息检索和多媒体内容分析领域一个重要的研究问题。

教育类视频

作为开放教育资源的重要组成部分，教育类视频已经成为数字化学习领域知识传播的重要媒介之一。慕课的快速崛起极大丰富了教育类视频的种类和数量。

制约因素

- 缺少完备的标注信息
- 教育视频时间长
- 播放形式单一
- 数据量大
- 检索效率低

为了克服上述因素给学习者在查找和浏览视频时带来的不便，目前很多研究者正在从不同的技术角度为提升用户信息获取效率提供有效的解决方案。其中，基于内容的视频分析方法引起了多媒体领域学者的广泛关注并取得了丰硕的研究成果。

然而，将这些方法直接用于教育类视频是仍然表现出很大的局限性和不足。

教育类视频特性

1 类型的多样性

2 信息的多模态性

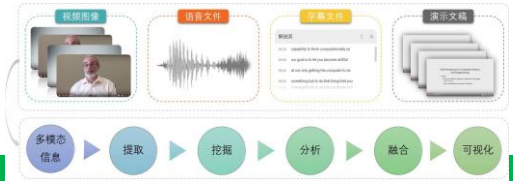

➢ 研 究 点

第一，从理论的角度来说，需要设计针对教育类视频多通道、多模态信息提取和处理框架，即解决从视频哪些通道提取和挖掘哪些信息的问题，这也是对视频进行后续处理和分析的前提和基础。

第二，教育类视频多通道多模态等特点使得传统的基于单一通道的内容结构化方法不能十分有效地帮助用户快速了解和分析视频内容。教育类视频内容的特殊性也需要对传统的内容结构化语义单元重新进行划分，从而更好地贴合用户信息获取时的实际需求。

第三，信息的呈现形式也是影响用户视频浏览效率和信息查找体验的重要因素之一，它一定程度上决定着用户能否从大量的信息中快速发现帮助其做出相关性判断的线索。

最后，从用户的角度来说，需要有效的视频检索和浏览工具来满足其在不同阶段的信息查找需求。在视频检索阶段，用户希望搜索引擎能准确匹配到与查询语句相关的结果；在视频检索结果浏览阶段，用户希望能在没有观看视频的前提下从检索结果列表中快速了解视频内容并作出相关性判断；在单个视频浏览阶段，用户希望能够快速获取视频的主要内容并迅速地定位到感兴趣的内容片段。

3.2 幻灯片提取

幻灯片作为一种高效的演示工具被广泛地应用于教育、商业以及培训等领域。在教育类视频制作过程中，讲述人逐渐摒弃手写板等传统的教学辅助工具，转而将文字、图片、表格等教学素材嵌入到幻灯片中并形成演示文稿，从而更加生动地展示课程内容。这些幻灯片中所包含的信息不仅可以为用户浏览和定位视频内容提供直观的视觉线索，而且在为视频生成内容索引和摘要等方面也起着十分重要的作用。

图像类型

I. 画面全部为幻灯片内容的图像
II. 画面全部为非幻灯片内容的图像
III. 幻灯片位于画面局部区域的图像

I类型（Shot of Slide，SoS）　II类型（Shot of Non-Slide，SoNS）　III类型

3.2.1 镜头边界检测

镜头边界检测算法中，有基于单一的帧间差分度量方法。通过计算相邻帧间的像素差异并设置一个相对较小的全局阈值来检测镜头的变化。

使用这种方式来检测教育类视频镜头边界存在着一定的缺陷，即阈值设定的过高容易导致无法捕获部分幻灯片的切换，而阈值设定的过低又会导致算法对噪声过于敏感而影响检测的准确性。

图像类型

I. 画面全部为幻灯片内容的图像
II. 画面全部为非幻灯片内容的图像
III. 幻灯片位于画面局部区域的图像

I类型SoS　II类型SoNS　III类型

在第一阶段，首先使用基于颜色直方图的帧间差分度量方法来检测**I类型幻灯片镜头**和**II类型、III类型**幻灯片镜头之间的边界。

该方法假设同一镜头内的图像有着十分相似的直方图分布，而当镜头发生切换时，不同镜头的帧间直方图差分则较为显著。具体就是建立相邻帧的直方图，然后进行直方图的相似性匹配。

图像类型

I. 画面全部为幻灯片内容的图像
II. 画面全部为非幻灯片内容的图像
III. 幻灯片位于画面局部区域的图像

I类型SoS　II类型SoNS　III类型

第二阶段，由于不同的幻灯片内容可能也会有着相似的直方图分布，仅使用基于直方图的帧差度量方法**可能无法成功检测到幻灯片切换的边界。**采用基于Canny边缘的帧间差分度量方法来检测幻灯片的切换边界。

图象的边缘是指图象局部区域亮度变化显著的部分，该区域的灰度剖面一般可以看作是一个阶跃，既从一个灰度值在很小的缓冲区域内急剧变化到另一个灰度相差较大的灰度值。图象的边缘部分集中了图象的大部分信息，图象边缘的确定与提取对于整个图象场景的识别与理解是非常重要的，同时也是图象分割所依赖的重要特征，边缘检测主要是图象的灰度变化的度量、检测和定位。

实现图像的边缘检测，就是要用离散化梯度逼近函数根据二维灰度矩阵梯度向量来寻找图像灰度矩阵的灰度跃变位置，然后在图像中将这些位置的点连起来就构成了所谓的图像边缘（图像边缘在这里是一个统称，包括了二维图像上的边缘、角点、纹理等基元图）。

在边缘检测中的主要步骤：

1）**滤波**：边缘检测的算法主要是基于图像强度的一阶和二阶导数，但导数通常对噪声很敏感，因此必须采用滤波器来改善与噪声有关的边缘检测器的性能。**常见的滤波方法主要有高斯滤波，即采用离散化的高斯函数产生一组归一化的高斯核**（具体见“高斯滤波原理及其编程离散化实现方法”一文），然后基于高斯核函数对图像灰度矩阵的每一点进行加权求和（具体程序实现见下文）。

2）**增强**：增强边缘的基础是确定图像各点邻域强度的变化值。增强算法可以将图像灰度点邻域强度值有显著变化的点凸显出来。**在具体实现时，可通过计算梯度幅值来确定。**

3）**检测**：经过增强的图像，往往邻域中有很多点的梯度值比较大，而在特定的应用中，这些点并不是我们要找的边缘点，所以应该采用某种方法来对这些点进行取舍。**实际工程中，常用的方法是通过阈值化方法来检测。**

Canny边缘检测算法原理

Canny边缘检是在在1986年提出来的，仍然是图像边缘检测算法中最经典、先进的算法之一。从表面效果上来讲，Canny算法是对其他算子效果的进一步细化和更加准确的定位。

Canny算法基于三个基本目标：

- 低错误率。所有边缘都应被找到，且没有伪响应。
- 边缘点应该被很好地定位。已定位的边缘必须尽可能接近真实边缘。
- 单一的边缘点响应。这意味在仅存一个单一边缘点的位置，检测器不应指出多个像素边缘。

因此Canny的步骤如下：

1.对输入图像进行高斯平滑，降低错误率。

2.计算梯度幅度和方向来估计每一点处的边缘强度与方向。

3.根据梯度方向，对梯度幅值进行非极大值抑制。

4.用双阈值处理和连接边缘。

基于Canny边缘的镜头边界检测算法的主要思想是通过检测图像中的边缘并比较对应区域的边缘像素变化数量来度量帧间差分。这种方法与基于直方图的帧间差分度量方法相比不容易受到光照、色彩变化等的影响，但是对物体的移动、内容的增减较为敏感，因此更适用于检测幻灯片内容的变化。

具体实现是使用Canny边缘检测算法将帧转化为二值边缘图像，将该图像划分成小块，计算与相邻帧边缘图像对应的块的像素值之差，以此来判断两个帧是否存在边界。

双阶段镜头边界检测策略

基于颜色直方图的帧间差分度量

- 计算两个直方图分布的距离来度量帧间差分

基于canny边缘的帧间差分度量

- 比较对应区域的边缘像素变化数量来度量帧间差分
- 使用canny边缘检测算法将帧转化为二值边缘图像

3.2.2 镜头分类

镜头分类的目的是将检测到的镜头分为幻灯片和非幻灯片两种不同类型的镜头。

通常情况下，同一个视频中的幻灯片有着十分相似的背景以及字体配色方案等；而来自不同视频的幻灯片的视觉元素却千差万别，因此很难使用大量非同源的静态图像来训练一个通用的分类器。

- 训练样例收集规则

1 镜头长度 | 2 镜头稳定性 | 3 人脸特征 | 4 文本特征

- 镜头稳定性特征：演讲者在切换到新的一张幻灯片之后，通常会将其保留一段时间并介绍上面的内容，然后再切换到下一张幻灯片。因此，幻灯片镜头中所包含的图像一般不会有太显著的变化。而记录演讲者或听众的镜头由于人的活动其所包含的图片内容会出现一定的差异。利用这一特点，就可以通过度量视频镜头的稳定性来区分两类镜头。

- 人脸特征：面部特征也是一个用于区别非幻灯片镜头和幻灯片镜头的重要特征。这是基于一个事实，即大部分的幻灯片图像上检测不到面部特征，而非幻灯片镜头中由于有人的活动因而更可能被检测到人脸。我们可以利用开源的面部行为分析工具来检测镜头关键帧中的面部特征。

- 文本特征：文本时幻灯片上最为常见的一种视觉元素。如果镜头图像上包含了大量的可被识别的字符，则其更可能属于幻灯片镜头。可以采用光学字符识别工具来检测视频图像上的文本信息。

假设$\mathcal{T}_{i,k}$为从镜头S_i上提取到的并经过过滤后的单词集合，镜头S_i的文本特征值被定义为：

$$f_t(S_i) = \sum_{1 \le k \le |S_i|} |\mathcal{T}_{i,k}| / |S_i|.$$

得到上述特征后，可以定义以下四个规则从视频中收集训练数据

规则一，镜头的长度是否大于阈值θ_l。由于时长太短的镜头不利于度量其稳定性，进而可能增加收集到错误样例的风险。因此在选择训练数据时，本文只考虑长度满足该规则的镜头。

规则二，镜头稳定性特征值是否低于阈值θ_s。帧间差分较小的镜头为幻灯片镜头的概率较大；反之，则可能为记录讲述人、听众等活动的非幻灯片镜头。

规则三，镜头被检测到人脸的可信度是否高于阈值θ_f。包含非静止状态人脸的镜头更可能为非幻灯片镜头，而幻灯片镜头中一般不包含移动状态的人脸特征。

规则四，镜头关键帧画面被检测到的平均文字数量是否大于θ_t。这里设置阈值θ_t的原因在于，从非幻灯片镜头的图像上同样可能会检测到文字。只要当有效的字符数量大于该阈值时才考虑将其判别为幻灯片图像。

训练样例收集规则

1 镜头长度　2 镜头稳定性　3 人脸特征　4 文本特征

幻灯片镜头分类

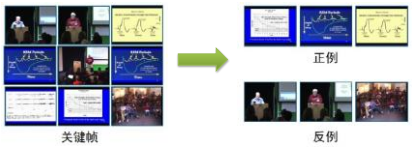

根据得到的正负样例，通过对每种类型镜头的关键帧进行特征提取来训练一个二分类器并用其分类剩余未知标签的镜头。

由于同一个视频中幻灯片的配色方案十分相似，可以采用基于颜色描述符和位置约束线性编码方案来表示图像特征。

非幻灯片图像中的幻灯片区域检测

- III类型图像中幻灯片区域的亮度要比周围环境的亮度高，因此可以通过使用图像二值化的方法检测到显著性区域
- 虽然这种方法可以从相当一部分III类型的图像中成功提取到幻灯片区域，但是当图像中存在其他显著性区域时，基于单一阈值的二值化方法就可能无法检测到幻灯片区域。

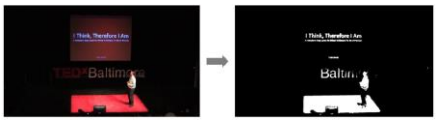

基于多阈值的幻灯片区域检测

为了从非幻灯片镜头中找出III类型的图像并从中提取出幻灯片区域，可以采用一种基于多阈值二值化与感兴趣区域排序的方法。算法的主要思想是：给定一张非幻灯片镜头图像，首先将其转化为灰度图像，并选取多个阈值将灰度图像转化为多个二值化图像。然后从二值化图像中找出候选区域，并根据幻灯片的特点过滤掉候选区域中不太可能为幻灯片的区域。如果过滤完成后候选区域的集合不为空，则判断该图像为III类型的图像，否则为II类型的图像。最后，对剩余的区域进行置信度排序，选出置信度最高的区域作为检测到的幻灯片区域。

具体地说，以32为步长从16到240依次递增来选取一系列阈值并将灰度图像进行二值化操作，如图所示。然后，对每一个阈值得到的二值化图像通过结构分析和形状描述模块检测所有可能存在的轮廓，于是每一张待检测的关键帧共得到8组轮廓的集合

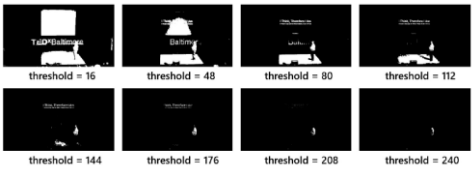

使用不同阈值的图像二值化结果

制定了如下规则过滤掉不符合幻灯片区域特征的轮廓并通过排序算法找出潜在的幻灯片区域：

规则一，轮廓区域面积S_c占整幅图像面积的比例不小于τ_a。该规则的目的是过滤掉面积过小的轮廓区域。因为过小的轮廓是幻灯片区域的可能性较低；而且即便是幻灯片区域，其内容也会因为无法被有效识别而不能被用作后续处理；

规则二，轮廓区域面积S_c占轮廓矩形包围盒面积S_b的比例不能小于τ_b；

规则三，轮廓的顶点数量不能少于τ_v；

规则四，矩形包围盒的长宽比需介于$[r_{min}, r_{max}]$之间。

基于规则的幻灯片检测框架

3.2.3 幻灯片去重

由于一张幻灯片在镜头中持续的时间较长，对视频每一帧都提取幻灯片的话，得到的幻灯片序列会包含很多重复的幻灯片，因此我们需要对幻灯片序列进行去重处理。所谓的去重处理，就是把内容实际相同的所有幻灯片都检测出来，只保留其中的一张幻灯片。

幻灯片序列去重的基本思想是通过比较相邻两帧幻灯片的图像相似性来判断它们是否重复，如果重复就删除后面的那帧幻灯片。

定义特征

使用SIFT (Scale invariant feature transform)特征点来度量幻灯片的相似性。 SIFT算法的实质是在不同的尺度空间上查找关键点(特征点)，并计算出关键点的方向。SIFT所查找到的关键点是一些十分突出，不会因光照，仿射变换和噪音等因素而变化的点，如角点、边缘点、暗区的亮点及亮区的暗点等。

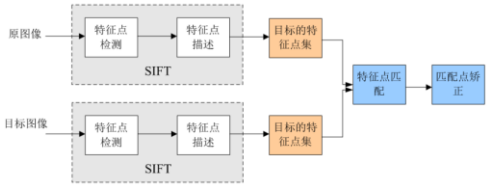

特征点的匹配是通过计算两组特征点的关键点的欧式距离实现的。欧式距离越小，则相似度越高，当欧式距离小于设定的阈值时，可以判定为匹配成功。

3. 3 幻灯片信息的解析

通常情况下，幻灯片的内容主要由文本、内嵌的图片、表格等素材构成。

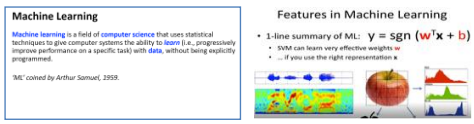

3. 3 .1 幻灯片文本信息的解析

为了视频生成文本目录，这里我们只考虑幻灯片中所包含的文本块而忽略其它的视觉元素。

可以采用一种基于深度神经网络的快速文本检测方法TextBoxes来检测幻灯片中潜在单词的包围盒。

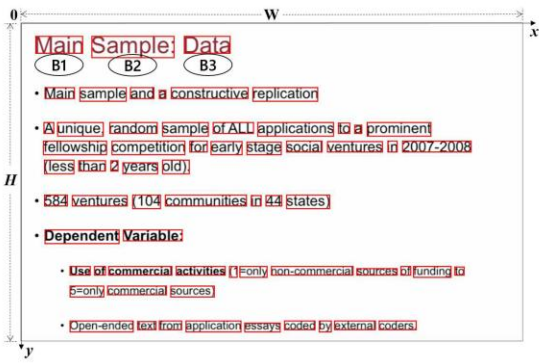

设定四个规则将满足条件的包围盒合并成文本行。

$R1$: 包围盒左下角位置的y坐标在误差允许范围内基本相同；
$R2$: 不同包围盒内的字体大小在误差允许范围内基本相同；
$R3$: 相邻包围盒之间的水平间距在误差允许范围内基本相同；
$R4$: 相邻包围盒之间的水平间距不能超过包围盒内字符平均宽度的两倍。

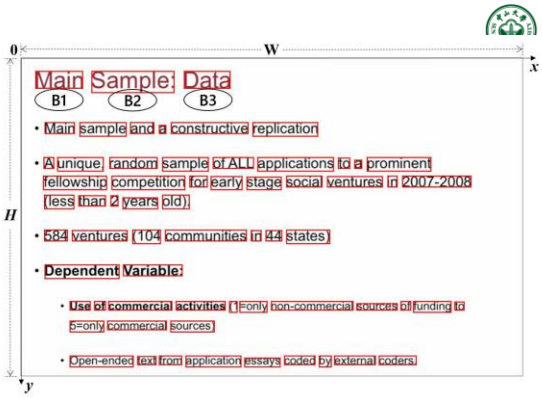

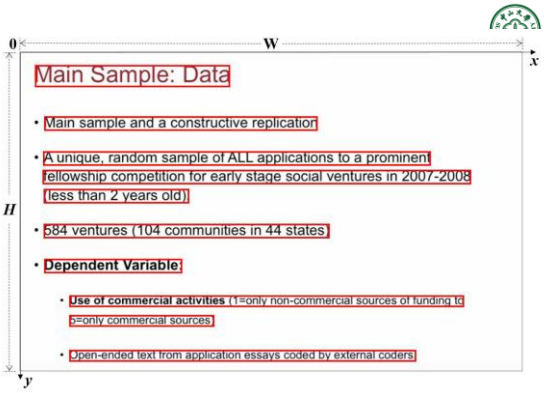

最后，通过以下三个规则将文本行合并为段落：

$R1'$: 上下相邻文本行的包围盒高度在误差允许范围内近似相等；
$R2'$: 上下相邻文本行的包围盒需满足左对齐、右对齐或居中对齐；
$R3'$: 上下相邻文本行包围盒的垂直间隙不超过文本行包围盒高度的三倍。

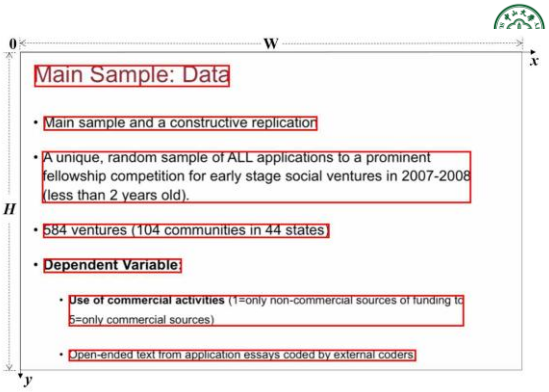

3.3.2 幻灯片标题处理

假设每张幻灯片最多只包含一个标题，且标题经过上一节的操作已经被组合在一个文本段落中。

对检测到的文本段落集合$\mathcal{P} = \{p_1, p_2, \cdots, p_n\}$的任一$p_i$，

根据其位置，字数、孤立性以及字体大小等几个特征来判断其是否为幻灯片标题。

位置($R1''$)：根据用户制作演示文稿的习惯，标题通常会被放在幻灯片的上半部分，且大多情况下是左对齐或水平居中的。因此，位于幻灯片左上方区域的段落比右下方区域的段落更可能是标题。

字数($R2''$)：和正文相比，标题一般相对精简。

孤立性($R3''$)：该特征用来衡量一个文本段落在幻灯片中的孤立程度。

字体的大小等

3.3.3 幻灯片视觉信息提取

幻灯片提取出来之后，还只是一张张的文档图像。文档图像不同于自然图像，它由文本、公式、图片和表格等视觉元素组合而成。要充分利用和理解幻灯片的内容，首先需要对幻灯片进行解析，而解析一张文档图像属于文档处理领域的版面分析任务。

➢在幻灯片里面解析出文本、公式、图片及表格等（视觉）元素。

第一步，构造连通区域

为了减小目标子区域的搜索空间，我们首先进行连通区域分析构造连通区域，然后通过轮廓搜索法得到连通区域的轮廓，构造连通区域能够减少轮廓的数量，极大提高轮廓搜索算法的效率。

构造连通区域步骤

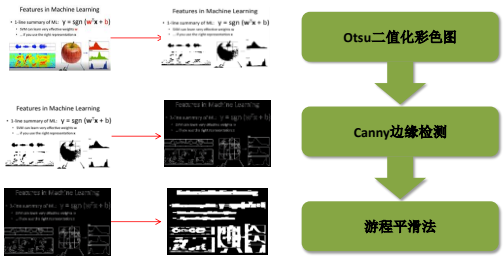

图像二值化

为了尽量地保留住图文信息的同时减小背景对构造连通区域的影响，需要先对图像二值化。图像二值化可以使用Otsu算法，Otsu算法利用一个阈值将图像的灰度值聚成两类：前景部分、背景部分，同时使这两类的类内方差最小，而类间方差最大。应用在图像二值化当中，就是选取一个阈值来尽可能地减少图像中的背景信息，保留住前景信息，该算法是一种比较常用的自适应二值化方法。

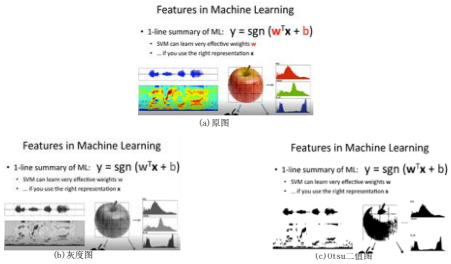

(a) 原图

(b) 灰度图

(c) Otsu二值图

Otsu二值化效果

Canny算子的边缘检测

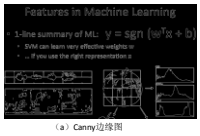

（a）Canny边缘图

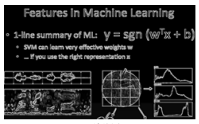

（b）Sobel边缘图

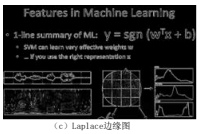

（c）Laplace边缘图

各种边缘检测算子的效果

游程平滑

为了构造连通区域，需要在上一步得到的Canny边缘图基础上合并邻近边缘点。

游程平滑法的基本思想是：对文本图像在水平方向上进行扫描，得到每一行白色像素的位置，然后计算同一行两个白色像素点之间出现的连续黑色像素点的个数N_{RLSA}。如果N_{RLSA}小于设定的阈值T_{RLSA}时，将这些连续的黑色像素点全部置为白色像素点。例如：若阈值T_{RLSA}设为3，白色像素点用1表示,黑像素点用0表示，那么使用游程平滑前的行像素为1001111100001，使用游程平滑后的行像素为:1111111100001。

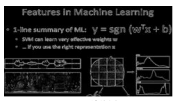

（a）Canny边缘图

（b）闭运算效果图

（c）游程平滑效果图

构造连通区域的效果

从图的效果上可以看出，使用闭运算构造连通区域的话，可能会将一行完整的文本拆分成多个部分。而使用游程平滑法，则能够将一行完整的文本连通起来，能够减少图像中轮廓的数量，提高后续轮廓搜索算法的效率。

第二步，候选区域的提取

在文档图像的版面分析过程中，常常需要对图像连通区域的边缘点进行跟踪并找出连通区域的边界，也称之为轮廓搜索。应用轮廓搜索算法提取连通区域的轮廓作为目标区域的候选区域。轮廓可以比较直观地描述一个区域形状，适用于作为边界完整的连通区域的代表。

候选区域轮廓已经提取出来之后，用矩形的包围盒（bounding box）来表示区域，而不是一个边界点集合。

联通区域图

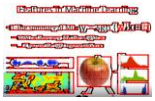

联通区域轮廓图

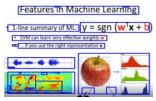

候选区域提取

轮廓搜索算法可以准确地提取出连通区域的轮廓，起到了初步提取候选区域的效果，但是其结果仍然包含许多无效区域，如没有实际内容的小斑点区域，还有一些有实际内容的有效区域却重叠在一起。为了确保候选区域提取的有效性，需要对的结果进行合并及筛选处理。

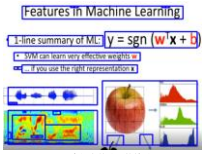

（a）未经合并处理的结果

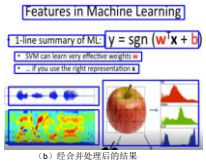

（b）经合并处理后的结果

区域合并的效果图

第四步，图片和表格的提取

文档图像版面内除了文本、公式区域外还存在图片、表格区域，本文定义的图片区域除了传统意义上的自然图像外还包括流程图、直方图、走势图等各种人为创造的图像。对图片、表格区域进行定位提取时，版面内的文本、公式区域已被定位，可以将文本域设置为背景，即文本域的像素点全部设置为255，此时文档图像还剩下候选的图片、表格区域。

与文本、公式区域筛选方法一样，为了提高区域定位的准确率，我们也根据图片、表格区域的相关特点，总结出了一套启发式筛选规则，用于对图片、表格区域进行进一步筛选，其规则主要是利用图片、表格区域轮廓的几何特征，进行启发式筛选：

（1）候选区域面积：计算全部图片、表格区域的轮廓面积。当满足其面积大于阈值T_{img}时(T_{img}设为500)，将其判定成为图片、表格区域。因为幻灯片版面上文本、公式区域以及剔除了，除了图片和表格的轮廓面积较大以外，其他无效区域的轮廓面积都比较小。

（2）候选区域宽高比：一般来说，图片、表格区域的形状不会是狭长的。因此如果某个候选区域的宽度与高度之间的比值超出一定范围，应将其判定为非图片、表格区域。本文设定宽高比阈值范围为：最小为0.33，最大为3。