第四章 视频摘要和缩略图

现有的视频搜索引擎通常在检索结果页面以列表或栅格的布局形式将视频的缩略图、标题、摘要以及时长等图文信息（视频封面）呈现给终端用户。这些信息在用户进行视频查找和相关性判断的过程起着至关重要的作用。其中，缩略图作为最常见也是空间约束最紧凑的视频内容摘要方法之一，为用户提供了最直观的视觉反馈。

4.1 视频摘要

视频摘要是专门用于描述视频主要内容的一种表达形式。生成一个符合用户搜索意图并且能够很好地展现视频内容的视频摘要，能够帮助用户快速定位到想了解的视频内容，可以大大的节省用户检索甚至是观看视频的时间。

视频摘要算法不仅为用户提供了方便的浏览方式，而且应用非常广泛，比如运动识别，事件检测，显著性检测，视频嵌入等。

视频摘要是一种帮助用户在没有完整地浏览视频内容的情况下快速感知视频内容的技术，它可以是静态图像，也可以是动态图像。通过浏览视频内容摘要，用户不仅能从大量视频文档集中快捷地定位到感兴趣的视频，也可以对单个视频内容进行非线性浏览，从而提高信息查找和视频浏览的效率。

视频摘要技术的主要过程是：通过使用计算机技术分析视频结构和理解视频内容，进而选择其中有效体现原始视频内容的关键帧，以达到对原始视频内容进行总结和概括的目的。视频是由一系列被称为帧的静态图像依据时间顺序或空间分布规律组合得到的图像集，可从多方面表达静态图像的语义信息。视频摘要是完整视频序列的一小部分，旨在以较少的视频帧为整个视频提供一个清晰且有意义的视觉轮廓。

视频摘要的表现形式

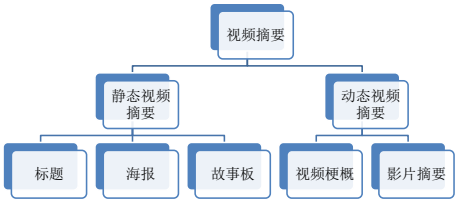

动态视频摘要由原视频内容中多个主要的凝练片段构成。动态视频摘要可极大缩短视频长度并有效地展示视频的重要内容，具有良好的观赏性，同时实现难度也较高。

视频梗概是一段原视频内容的集锦。其自身属性即是一段视频，由原视频中的某些精华片段拼接生成，此类片段可以是原视频中的重要主人翁、关键情景片段、剧情开头和结尾等。

多媒体影片摘要是一种由多种媒体形式组成的表现影片内容的方式，它在视频梗概的基础上融入了文本和镜头图像等其他信息。例如，在电影主题页面中，它可能包含文本形式的简短介绍、声音形式的精彩对话、视频形式的精彩剪辑等。此种形式不仅可以提供更加丰富的视频内容描述，也可以为用户提供多种浏览和搜索影片的方式。

静态视频摘要，即视频的概述表达，标题、海报、故事板是其主要的基本体现形式。静态视频摘要是从原始视频中选择出具有代表性的关键帧，通过这些关键帧，就可以了解视频的整体内容相比动态视频摘要技术，静态视频摘要技术的计算复杂度较低，不论是生成摘要还是后期浏览摘要都更为简单快捷。

生成方法

简单的生成方法

基于时间点对视频进行采样，即每间隔一定的时间抽取一个代表帧或者一个片段，这种生成方法很容易实现，但完全没有基于视频的内容。

基于视觉信息的生成方法

根据视频里出现的颜色、纹理、形状、运动方向和强度等视觉信息，基于模式识别的思维，应用各种视频和图像处理技术，进行镜头探测、关键帧提取、场景聚类、运动特征提取等一系列操作，最终生成具有代表性的关键帧序列或缩略视频。这种算法完全基于视觉特征，忽略了音频、字幕等信息对视频的作用。

生成方法

融合多特性的生成方法

在基于视觉方法的基础上融入其他媒体提供的信息，准确的判断视频片段的重要程度，这种算法是大多数视频摘要技术采用的方法。

基于视频句法语义的生成方法

从视频的句法结构分析入手，探寻镜头与镜头之间、场景与场景之间的结构规则，将视频的句法语义尽可能完整的保存在摘要中。

生成过程

- ✓ **视频分割**

任何视频摘要算法都遵循“先分后合”的原则，要进行视频内容理解和分析必须首先将视频切分成合理的基本单位，这些基本单位包括场景、镜头、帧等。

- ✓ **视频内容提取**

采用模式识别或者视频结构探测的方法来获取能够被计算机或者人感觉的信息。

- ✓ **合成摘要**

把判定为重要的视频片段组合在一起形成某种形式的摘要。

视频摘要技术正在向多模态、个性化以及融合的方向发展，具有很好的研究价值以及广阔的应用前景。

1) **多模态的视频摘要，即融合图像、视频、音频以及文本等多种媒体内容的视频摘要。**大量的实验证明，将各种媒体的特征有机地结合在一起，才能最大限度地让用户在短时间内迅速理解并获取视频的内容，如标题与故事板相结合的摘要形式必定会比单一的标题或故事板的摘要形式更容易让人理解。

2) **交互式的视频摘要。**现在的视频摘要多半是主观的、按照生成者意图定制的摘要，力求让用户理解或浏览视频内容。但未来的视频摘要将是交互式的，允许用户指定摘要的形式，摘要哪方面的内容，便于用户自己设计个性化的摘要。

4.2 缩略图

缩略图

缩略图是最常见也是空间约束最紧凑的视频内容摘要方法之一，为用户提供了最直观的视觉反馈。在从大量的视频列表中查找想要的视频时，一些用户甚至可以在没有阅读标题和摘要等文本信息的情况下仅通过浏览缩略图就可以做出相关性判断。

缩略图时一个通过显示视频中关键信息的文字和图片为用户提供对视频的内容进行快速了解的一种方法。传统的缩略图提取方法主要从视频中选出最合适的某张关键帧，目前主要是人工定制。

目前，多数的视频社交媒体主要有三种途径为视频添加缩略图：其一是用户手动为视频上传定制的缩略图；其二是首先系统从视频某些时间节点选取若干图像，然后用户在从这些图像中选取一张作为视频缩略图。其三是在用户没有指定缩略图的情况下，系统根据相应的规则或评价模型从视频中选择一张图像作为缩略图。

视频定制的缩略图质量较高、内容更多样也更具吸引力

存在的问题

- 手动选择最合适的缩略图是十分耗时且需要技巧的人工过程
- 传统单张关键帧作为视频缩略图带来的内容过于单一、视觉信息不够充分

在为视频生成缩略图时，不再局限于仅从视频的关键帧中选择其中的某一张作为缩略图：

✓ 选择最显著的关键帧作为载体图像，然后将其他关键帧的显著性区域嵌入到载体图像的非显著性区域上并合成为一张图像。这是因为对于一些时长较长的视频而言，仅选择一张关键帧不足以全面的反应视频的主要视觉内容，而经过合成的图像则在同样的空间限制下更为浏览者呈现了更加丰富的视觉线索。

✓ 仅从视觉通道对视频关键帧进行显著性评价来提取缩略图往往不能达到用户的满意。例如，如果一个教育类视频的镜头全部是关于演讲者的特写，那么提取到缩略图将会是一张演讲者特写的画面。通过这张图像用户很难获取视频中演讲者论述的主要话题。针对教育类视频的语音通道中所包含的大量叙述性的话语，然后通过关键词提取算法将视频中涉及到的最显著的话题整合在了载体图像上，得到一张图文并茂的视频缩略图，从而为用户了解视频的主要内容提供宝贵的图文线索。

所生成的缩略图，应充分考虑以下特性。代表性：所选取的缩略图必须反应视频的主要内容，如果使用非代表性或不相关图像作为视频缩略图将严重影响用户做出相关性判断；美观性：缩略图应该尽量避免选择模糊不清、昏暗以及色调单一等低质量的图像；吸引性：富有吸引力的缩略图可以得到更高的点击率；多样性：时长较长的视频往往会包含成千上万帧图像。尽管可以通过一定的评价模型挑选出最具代表性的图像作为视频封面，但是用户仅通过一张图像很难以全面的了解视频内容，进而可能做出错误的相关性判断。此外，不同的用户对同一视频感兴趣的内容也可能不一样，因此视频缩略图的内容在美观并可辨识的前提下应尽可能的具备多样性。

图文缩略图自动生成方法架构

给定一个视频，首先在视觉通道上对其进行内容提取，即：(1) 使用镜头分割算法将其分割为一系列镜头单元。由于镜头在切换时经常使用溶解、擦除以及淡入淡出等过渡效果，这些过渡的画面通常图像质量较差因而不被用于后续的处理；(2) 每一个镜头选取一张关键帧然后进行人物检测并根据图像的相似性进行聚类；(3) 使用质量评价模型来评估每个类内的关键帧的质量，从每个类内选择质量最高的关键帧做为该类的代表帧；(4) 使用图像显著性检测算法检测每个代表帧的显著性区域，代表帧及其显著性区域将作为生成图文摘要的视觉素材来源。

其次，从视频的语音通道中提取主题词，即：(1) 将视频的字幕或语音识别得到的文本转换为完整的语句；(2) 使用文本主题分割工具将转换后的文档切分为连续的主题单元；(3) 使用关键词检测工具从每个主题单元中检测关键词并计算其权重，这些关键词将作为生成图文摘要的文本素材来源。

最后，算法对内容预处理与提取模块提取到的视觉和文本素材进行选择、布置、色彩搭配，然后合成为一张完整且视觉美观的图文摘要。

1）关键帧及其显著性区域检测

- **镜头分割与关键帧提取**
  - 使用基于canny边缘的图像差分度量方法来检测视频镜头
  - 从每一个镜头中选择最稳定的一张图像作为该镜头的关键帧

对提取到的关键帧根据其视觉和内容的相似性进行聚类，然后从每一聚类簇中选出一张关键帧做后续处理。

- **关键帧聚类**
  - 人脸识别和跟踪（软件）
  - 提取关键帧特征向量，采用K-Means聚类方法对特征向量进行聚类
  - 计算每个类的权重

- **图像显著性区域检测**

在合成图文摘要之前，需要对视频关键帧进行显著性区域检测并结合关键帧的显著性、美观性等特征从中选出最合适的图像作为载体图像，然后将剩余的关键帧或其显著性区域以及提取到的关键词嵌入到载体图像的非显著性区域。通过显著性区域检测，不仅可以在对载体图像进行内容嵌入时尽量避开其显著性区域，而且可以裁剪掉剩余关键帧图像上的冗余内容，从而提高空间的利用率以及合成的图文摘要的可读性。

- 一种鲁棒的基于边界连通性的图像显著性评估方法来检测图像的显著性区域

将图像的空间布局结构特征化为图像边界，并用条理性的优化框架来整合多个底层线索，从而获得洁净而圆融的显著性灰度图，如图 (b)所示。接着，使用自适应阈值的方法将显著性灰度图转化为二值化的显著性图 (c)。去除二值化显著性图中的一些小的噪点得到图 (d)。最后，通过轮廓检测得到显著性区域的矩形包围盒图(e)。选择面积最大的包围盒作为图像的显著性区域。

(a) 原始图像　(b) 显著性图　(c) 二值化后的显著性图
(d) 开运算后的二值化显著性图　(e) 显著性区域包围盒

2）语音通道中的关键词提取

- **字幕文件预处理**

(a) 字幕文件 (.vtt)　(b) 去除时间戳并合并后的字幕文本　(c) 语句边界检测

- **关键词提取**
  - 无监督的基于图排序模型的方法：TextRank

3） 图文缩略图自动生成算法

所得到的用于生成视频图文缩略图的视觉和文本素材，对于一些时长较长的视频，聚类簇和关键词的数量往往也较大。为了保证合成的图文缩略图的可读性，需要严格限制载体图像中嵌入的图片和关键词数量。

主要思想

将布局优化问题分解为视觉内容布局最优化和文本内容布局最优化两个子问题，并且在视觉内容布局达到最优化后再对文本内容求解最优布局。

▪ 视觉内容布局优化

缩略图的视觉内容主要由载体图像和若干其他关键帧的显著性区域（ROI）组成。在选择载体图像时，应该考虑其内容代表性以及可以用来嵌入图文素材的空间比例。就代表性而言，可以通过关键帧所属类的大小来衡量，即应尽可能地选择规模较大的聚类簇的关键帧作为载体图像。

▪ 文本内容布局优化

在得到视觉内容排布的最优可行解以后，下一步的工作则是将文本嵌入到载体图像剩余的可用空间中。

- 在优化文本内容布局时，使可用区域的利用率尽可能地大
- 同时使嵌入的关键词的显著性之和尽可能地高

▪ 文本着色

文本着色是在合成视频图文缩略图中非常重要的一个步骤。一个好的着色方案不仅能引起浏览者的阅读兴趣，也会增加文本内容的可读性。

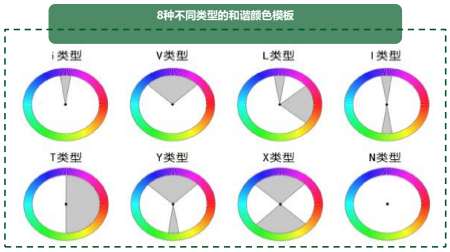

▪ 自动生成的图文缩略图