人机多轮对话系统的对话管理研究
中期检查

1 小组分工情况

我们小组组长为钟珊珊（22214624），小组成员包括宋鸿展（22214385）、许愿（22214397）、蔡晨语（22214409）。

首先，我们小组每一位成员广泛调研了所选题目领域，总结了人机对话系统的对话管理研究的背景介绍和相关工作，在小组会议上进行了分享和讨论。随后，我们根据小组成员的调研结果，讨论出以流行的相关研究 SA-BERT [1] 和 BERT-ResSel [2] 作为我们的基准模型展开深入研究，每位小组成员都尝试跑通基准模型，并在基准模型上进行探索。接着，我们分享自己的实验结果，每位成员更加明确自己的优化方向，简要而言，宋鸿展尝试从主题划分角度进行研究，许愿尝试细粒度划分 Bert 进行优化，蔡晨语从知识蒸馏角度进行探索。此外，考虑到 Ubuntu 数据集的准确度已经很高（$R_{10}@5 \approx 98\%$），钟珊珊负责探索是否有其他更有挑战性的数据集，并完成数据集领域微调。最后，我们小组通过分工撰写初稿和讨论形成终稿方式完成论文撰写，具体而言，钟珊珊负责 Introduction，蔡晨语负责 Related works 和 Abstract，许愿负责算法，宋鸿展负责实验。四人的具体小结如下：

许愿：首先是跑通 baseline 模型（Bert-ResSel），然后在此基础上加上了机器阅读理解中的 Bidaf 模块，建模 context 和 query 之间的关系，尝试改进了模型，并且在 Ubuntu 数据集上进行了实验。

钟珊珊：(1) 跑通了 SA-BERT [1] 和 BERT-ResSel [2]。(2) 完成了对 E-commerce [1]和 Douban [2]数据的预处理。(3) 基于通用语料库预训练的 Bert 进行后期训练，以帮助模型理解特定数据集领域。领域微调主要通过 MLM 和 NSP 任务，这两类任务对于从数据集中学习上下文关系非常有效。(4) 此外，由于 Ubuntu 数据量非常大，常常加载数据都需要大半天时间，非常不利于组员进行探索性实验，因此我对 Ubuntu 进行了降采样，得到了 mini-Ubuntu 数据集，以便于组员的使用。

宋鸿展：跑通了并理解了 SA-BERT 代码和 BERT-ResSel 代码结构并进行实验测试，同时尝试用主题模型对代码进行改进。

蔡晨语：复现了 SA-BERT 和 BERT-ResSel 两份代码，尝试从知识蒸馏方面对代码进行改进。

2 Introduction

自然语言对话系统，又称为聊天机器人，是自然语言处理 (NLP) 的热门话题之一，在工业界中具备广阔的应用前景。聊天机器人的市场规模预计将从 2021 年的 26 亿美

[1] https://github.com/cooelf/DeepUtteranceAggregation

[2] https://github.com/MarkWuNLP/MultiTurnResponseSelection

元增长到 2024 年的 94 亿美元，复合年增长率 (CAGR) 为 29.7% [3]，预计到 2021 年底将有 80% 的企业配备自动化聊天机器人 [4]。自然语言对话系统涉及到许多 NLP 领域的典型任务，自 NLP 正式提出起，大量研究者在这项任务上开展研究。特别是近几年来，大多数研究基于深度学习对自然语言对话系统进行建模，表现出出色的性能。

对话系统可以看作是用户信息 U 到机器人回复 R 的映射，即 $R = \phi(U)$，其中 $\phi(\cdot)$ 为映射函数。$\phi(\cdot)$ 常常使用管道式方法（Pipeline）建模。管道式方法将对话理解逐步拆解成自然语言理解（NLU）、对话管理模块（DM，包括对话状态跟踪（DST）和策略学习（PL））、自然语言生成（NLG）三步链式结构，根据不同模块的特性设计不同的模型来解决对应问题。其中，NLU [3, 4, 5] 对文本信息进行识别解析，转换成计算机可理解的结构化语义表示；DST [6, 7] 根据对话历史和 NLU 模块输出的语义表示，维护并更新当前的对话状态；PL [8, 9] 根据当前的对话状态执行下一步系统动作；NLG [10, 11] 将对话策略输出的语义表示转换成自然语言文本。

我们的课题目标针对的 DSTC8[12] 赛道二（NOESIS II）是典型的对话系统任务。NOESIS II 的主任务是选择多轮对话的下一轮回答，输入是一个对话上下文和 100 条候选回答，输出是 100 条回答的打分排序，评估指标是平均倒数排名（MRR）和 Top10 召回率。该任务提供了两个专业领域的数据集 Ubuntu 和 Advising。

NOESIS II 主要有两个难点，其一是每个对话的候选答案多至 100 个，匹配难度很高，针对这点需要在深度匹配模型上做改进；其二是数据集都是垂直领域的问答，模型必须对领域专业知识有一定理解，才能正确回答，针对这点需要补充领域知识。我们调研发现，最佳的方法在各个数据集上的性能有所不同，其中 Ubuntu 上的最佳方法在 Advising 方面排名第二，而最佳的 Advising 方法在 Ubuntu 上排名第五。因此，有必要提出性能更稳定的模型。

在本论文中，我们广泛调研了常用的对话系统模型，充分理解现有模型的设计思路，从对话系统管道式方法的各个阶段出发，思考模型优化方法。具体而言，我们使用主题划分的方法使得模型的领域适应能力更强，通过细粒度划分 Bert 使得模型对上下文关系更敏感，利用知识蒸馏的思想设计模型使得模型在多数据集上的性能更为稳定，使得模型大而精。我们不仅在 NOESIS II 任务上验证了模型的有效性，同时，我们通过中文数据集 E-commerce 和 Douban 证明了模型稳定的性能。

3 Related works

3.1 对话系统

构建一个自动对话代理是人工智能长期以来所追求的目标。之前的研究包括任务导向的对话系统，专注于完成垂直领域的任务；以及聊天机器人，旨在与人类就开放领域的话题进行一致和自然的对话。大多数现代聊天机器人都是数据驱动的，或是信息检索 [13] 或是序列生成 [14]。基于检索的系统具有信息丰富、响应流畅的优点，因为它是在候选响应集中选择下一个可能出现的最合适的回答。基于生成的方法在给定之前的对话

[3] 数据来源：https://markets.businessinsider.com

[4] 数据来源：https://outgrow.co

上下文的前提下，通过最大化其生成概率，用自然语言生成模型综合一个响应。在深度学习兴起之前，通常选用 TF-IDF 等统计模型进行应答选择。随着深度学习的不断发展以及相关硬件设施的不断出现，响应选择模型更多地选择深度神经网络。

3.2 响应选择

响应选择大致可分为单轮和多轮两大类，大多数早期的研究都是单回合，只考虑最后一个话语来匹配反应 [15]。最近的研究将其扩展到多回合对话场景，这更符合实际。Zhou 等人 [16] 提供了一种直接的单轮转多轮思路——将多轮问答语句合并为一列, 连接处用 _SOS_ 隔开, 将整个对话历史视为" 一句话" 去匹配下一句。将整个对话历史合并为一列, 做词嵌入 (word embedding) 后通过 GRU 模块提取词汇级特征, 与候选的 response 计算匹配得分。[17] 提出了顺序匹配网络 (sequence matching network, SMN), 它首先将应答与每个话语进行匹配，然后通过递归神经网络积累匹配信息。与以往研究不同的是，DUA 模型 [18] 首次区分了之前对话的重要性，并在多回合情景下，根据话语本身的每个词，从每个话语中积累了大量的部分。

3.3 注意力机制

注意力机制已经在自然语言处理 (Natural Language Processing, NLP) 和其他研究领域取得了巨大的成功。[19] 提出了深度注意匹配网络 (DAM) 模型, 该网络以堆叠的自注意和交叉注意构造不同粒度的表示。而以完全基于注意力的 Transformer 结构 [20] 为基础的 Bert 模型的提出则在若干个 NLP 经典问题上达到了 SOTA 效果。Transformer 不仅比以 RNN 为基础模型在机器翻译方面表现更好，同时由于注意力的计算可以完全并行，在训练和测试时运行速度极快。以往的注意机制研究表明，注意力在捕获语义依赖方面具有较强的能力，这启发我们利用注意机制改进多回合响应选择模型。Bert 强调不再像以往一样采用传统的单向语言模型或者把两个单向语言模型进行浅层拼接的方法进行预训练，而是采用新的 masked language model（MLM），以致能生成深度的双向语言表征。[21] 首次尝试使用预先训练的模型进行响应选择。它采用了一种简单的策略，即将上下文话语和应答逐字连接起来，然后发送到模型中进行分类。然而它忽略了一个事实，即说话者总是在谈话的过程中依次变换说话方式。SA-Bert[22] 则加入了说话者嵌入以及在上下文话语之间添加特殊的分割标记，让预训练模型 Bert 学习到说话者角色的变化。

4 实验进度

本节将主要说明有关对话选择的实验进度。首先将引入有关对话选择的相关评价指标，并介绍所使用的数据集，最后阐述我们改进模型过程中的实验结果。

4.1 评价指标

模型性能主要由两个召回率 Recall 和平均倒数排名 MRR(mean reciprocal rank) 的平均值来衡量。其中召回率 Recall@K 是指前 topK 结果中检索出相关结果数和库中所有的相关结果数的比率，表明的是系统的查全率。而 MRR 指数可以由以下公式得出：

$$MRR = \frac{1}{Q}\sum_{i=1}^{|Q|}\frac{1}{rank_i} \tag{1}$$

其中 Q 是评估集的问题总数,$rank_i$ 表示对于第 i 个问题 Q_i 预测到答案集中第一个正确答案的位置，如果对于问题 Q_i 没有正确回答则为 0，即正确答案的位置越前越好。

4.2 数据集

为了更好地和对话选择领域其他模型进行性能对比，实验选择 Ubuntu Corpus V1 进行模型性能测试。同时还选择了两个中文数据集 E-commerce 和 Douban 以测试模型的适应性和通用性。

- Ubuntu。此数据集为多方对话数据集，是网友在讨论 Ubuntu 操作系统的技术问题，例如 ubuntu 的硬件支持、nvidia 安装、证书等问题。
- Advising。此数据集是密歇根大学的课程顾问在和学生讨论下一学期的课程选择，根据学生的兴趣、时间、已上过的课程，推荐本学期合适的课程。学生和老师之间关于选课对话（两方对话）开发和测试集基于 100 个原始对话，每个对话被转述 5 次，然后在不同的地方切断。训练集是基于 500 个对话，也改写了 5 次，但随后重新混合了许多次。

4.3 实验结果

表1说明了不同模型在 Ubuntu 数据集上的实验结果，可以看出所提出的模型在 R10@2 和 R10@5 两个指标中优于现有的 Bert-DPT 模型和 SA-Bert 模型，但是由于基准模型指标提升空间较小所以改进并不明显，后续将进一步从其他方向尝试。

表 1: 不同模型在 Ubuntu 数据集上性能

Model	**R10@1**	**R10@2**	**R10@5**	**MRR**
Bert_DPT(baseline)	0.851	0.924	0.984	0.907
SA-Bert	0.850	0.925	0.983	0.906
Our model	0.849	**0.927**	**0.985**	0.907

5 难点和问题

以 Bert-ReSel 作为 baseline, 参考机器问答中的经典模型 bidaf [23], 将 biadaf 模块加入到 Bert 模型之后，双向建模 context 和 response 之间的关系。改进后的模型图如图1

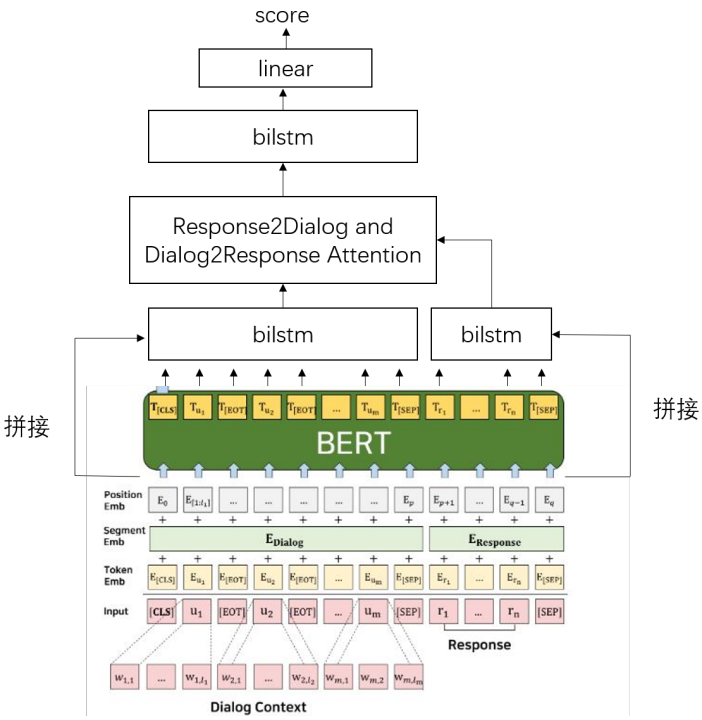

图 1: 改进后模型图

从目前的加上 bidaf 模块后的实验结果来看，提升效果并不显著，经分析原因可知是因为 bidaf 模块在建模 context 和 query 之间交互关系时是基于 token 级别的，而在 bert 内部也是基于 token 级别的交互，这样可能就导致忽略了对话中句子整体和回答之间的交互关系。

因此，接下来重点需要关注和解决的问题有：

1. 如何进一步的建模对话，即从句子级别去考虑对话和回答之间的关系.
2. 由于说话人信息在对话中的重要性，后续考虑将说话人信息也建模进去。

6 拟采用的解决方法

针对句子级别信息的建模，拟将 bert 得到的最后一层隐层输出，通过最大池化的方法将对话中的词向量聚合为句子向量，然后将对话句向量和回答句向量送入到 transfomer 中去，以此获得句子级别的交互关系。

关于说话人信息，我们将尝试模仿 transformer 中的位置编码的方式将说话人信息编码进模型。

参考文献

[1] Jia-Chen Gu, Tianda Li, Quan Liu, Zhen-Hua Ling, Zhiming Su, Si Wei, and Xiaodan Zhu. Speaker-aware bert for multi-turn response selection in retrieval-based chatbots. In *Proceedings of the 29th ACM International Conference on Information & Knowledge Management*, pages 2041–2044, 2020.

[2] Taesun Whang, Dongyub Lee, Chanhee Lee, Kisu Yang, Dongsuk Oh, and Heuiseok Lim. An effective domain adaptive post-training method for bert in response selection. *arXiv preprint arXiv:1908.04812*, 2019.

[3] Chien-Sheng Wu, Steven Hoi, Richard Socher, and Caiming Xiong. Tod-bert: Pre-trained natural language understanding for task-oriented dialogues. *arXiv preprint arXiv:2004.06871*, 2020.

[4] Rashmi Gangadharaiah and Balakrishnan Narayanaswamy. Recursive template-based frame generation for task oriented dialog. In *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics*, pages 2059–2064, 2020.

[5] Sam Coope, Tyler Farghly, Daniela Gerz, Ivan Vulić, and Matthew Henderson. Span-convert: Few-shot span extraction for dialog with pretrained conversational representations. *arXiv preprint arXiv:2005.08866*, 2020.

[6] Yexiang Wang, Yi Guo, and Siqi Zhu. Slot attention with value normalization for multi-domain dialogue state tracking. In *Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing (EMNLP)*, pages 3019–3028, 2020.

[7] Jiaying Hu, Yan Yang, Chencai Chen, Zhou Yu, et al. Sas: Dialogue state tracking via slot attention and slot information sharing. In *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics*, pages 6366–6375, 2020.

[8] Ryuichi Takanobu, Runze Liang, and Minlie Huang. Multi-agent task-oriented dialog policy learning with role-aware reward decomposition. *arXiv preprint arXiv:2004.03809*, 2020.

[9] Jun Xu, Haifeng Wang, Zheng-Yu Niu, Hua Wu, Wanxiang Che, and Ting Liu. Conversational graph grounded policy learning for open-domain conversation generation. In *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics*, pages 1835–1845, 2020.

[10] Ondřej Dušek and Filip Jurčíček. Sequence-to-sequence generation for spoken dialogue via deep syntax trees and strings. *arXiv preprint arXiv:1606.05491*, 2016.

[11] Sergey Golovanov, Rauf Kurbanov, Sergey Nikolenko, Kyryl Truskovskyi, Alexander Tselousov, and Thomas Wolf. Large-scale transfer learning for natural language generation. In *Proceedings of the 57th Annual Meeting of the Association for Computational Linguistics*, pages 6053–6058, 2019.

[12] Seokhwan Kim, Michel Galley, Chulaka Gunasekara, Sungjin Lee, Adam Atkinson, Baolin Peng, Hannes Schulz, Jianfeng Gao, Jinchao Li, Mahmoud Adada, et al. Overview of the eighth dialog system technology challenge: Dstc8. *IEEE/ACM Transactions on Audio, Speech, and Language Processing*, 29:2529–2540, 2021.

[13] Lasguido Nio, Sakriani Sakti, Graham Neubig, Tomoki Toda, Mirna Adriani, and Satoshi Nakamura. *Developing Non-goal Dialog System Based on Examples of Drama Television*, pages 355–361. 08 2014.

[14] Alan Ritter, Colin Cherry, and William B. Dolan. Data-driven response generation in social media. In *Proceedings of the 2011 Conference on Empirical Methods in Natural Language Processing*, pages 583–593, Edinburgh, Scotland, UK., July 2011. Association for Computational Linguistics.

[15] Hao Wang, Zhengdong Lu, Hang Li, and Enhong Chen. A dataset for research on short-text conversations. In *Proceedings of the 2013 Conference on Empirical Methods in Natural Language Processing*, pages 935–945, Seattle, Washington, USA, October 2013. Association for Computational Linguistics.

[16] Xiangyang Zhou, Daxiang Dong, Hua Wu, Shiqi Zhao, Dianhai Yu, Hao Tian, Xuan Liu, and Rui Yan. Multi-view response selection for human-computer conversation. In *EMNLP*, 2016.

[17] Yu Wu, Wei Wu, Chen Xing, Ming Zhou, and Zhoujun Li. Sequential matching network: A new architecture for multi-turn response selection in retrieval-based chatbots. In *Proceedings of the 55th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*, pages 496–505, Vancouver, Canada, July 2017. Association for Computational Linguistics.

[18] Zhuosheng Zhang, Jiangtong Li, Peng Fei Zhu, Zhao Hai, and Gongshen Liu. Modeling multi-turn conversation with deep utterance aggregation. In *International Conference on Computational Linguistics*, 2018.

[19] Xiangyang Zhou, Lu Li, Daxiang Dong, Yi Liu, Ying Chen, Wayne Xin Zhao, Dianhai Yu, and Hua Wu. Multi-turn response selection for chatbots with deep attention matching network. In *Proceedings of the 56th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*, pages 1118–1127, Melbourne, Australia, July 2018. Association for Computational Linguistics.

[20] Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N. Gomez, Łukasz Kaiser, and Illia Polosukhin. Attention is all you need. NIPS'17, page 6000–6010, Red Hook, NY, USA, 2017. Curran Associates Inc.

[21] Matthew Henderson, Ivan Vulić, Daniela Gerz, Iñigo Casanueva, Paweł Budzianowski, Sam Coope, Georgios Spithourakis, Tsung-Hsien Wen, Nikola Mrkšić, and Pei-Hao Su. Training neural response selection for task-oriented dialogue systems. In *Proceedings of the 57th Annual Meeting of the Association for Computational Linguistics*, pages 5392–5404, Florence, Italy, July 2019. Association for Computational Linguistics.

[22] Jia-Chen Gu, Tianda Li, Quan Liu, Zhen-Hua Ling, Zhiming Su, Si Wei, and Xiaodan Zhu. Speaker-aware bert for multi-turn response selection in retrieval-based chatbots. In *Proceedings of the 29th ACM International Conference on Information amp; Knowledge Management*, CIKM '20, page 2041–2044, New York, NY, USA, 2020. Association for Computing Machinery.

[23] Minjoon Seo, Aniruddha Kembhavi, Ali Farhadi, and Hannaneh Hajishirzi. Bidirectional attention flow for machine comprehension. *arXiv preprint arXiv:1611.01603*, 2016.