1 贡献比例与工作规划

在本节中，我们说明了小组成员的贡献比例，并具体列出了小组的工作规划。接下来的四个章节是完成作业过程中，每个人的调研内容、具体的实验探索和相关分析等。

1.1 贡献比例

我们小组组长为钟珊珊，小组成员包括宋鸿展、许愿、蔡晨语。我们小组的每位成员都非常认真负责，为报告的顺利完成献策献力，我们小组成员一致认为每个人的贡献比例相当。小组成员的个人小结为：

- 钟珊珊（25%）：（1）调研多轮对话回复选择的相关研究，跑通了 SA-BERT [1] 和 BERT-ResSel [2]。（2）完成了对 E-commerce [1]和 Douban [2]数据的预处理。（3）基于中文和英文通用语料库预训练的 Bert 进行 post training，尝试了 MLM 和 NSP 两种方法。（4）对 Ubuntu 进行了降采样，得到 mini-Ubuntu 数据集，以便于组员的使用。（5）尝试使用许愿建议的 URC 进行领域微调，发现 URC 的效果十分不错。（6）提出并实现了 finetune 阶段 matching network，并结合许愿的句向量分割代码对 matching network 进行了调优。（7）完成了报告中 introduction 的撰写和 fine tuning 的示意图；（8）负责 PPT 中绪论背景和模型设计两部分。

- 宋鸿展（25%）：（1）了解多轮对话选择任务并对 DSTC 赛道二任务进行分析，精读了 SA-bert 和 BERT-ResSel 两篇论文并跑通了代码。（2）阅读相关论文并尝试将主题模型与 BERT 模型结合但未达到预期，且主题模型本身需要在多样的语料中进行预训练，不便实现。（3）下载了 DSTC 赛道数据集并对含有 100 个回复选择的 Ubuntu 数据集进行了数据预处理方便后续实验。（4）完成了在各类数据集上不同模型的性能测试和记录分析。（5）对于不同的 post-training 方法进行了消融实验对比。（6）撰写了中英文报告中的 Experiments 实验部分内容。（7）负责汇报 PPT 中的实验分析和总结展望两部分。

- 许愿（25%）：（1）阅读了多篇有关多轮对话选择的论文，复现了 SA-bert 和 BERT-ResSel 模型的源代码，并选择 BERT-ResSel 作为 baseline。（2）主要负责算法部分的改进工作，第一个尝试是参考多跳问答中的 BiDAF 模型进行改进，及对 context 和 response 进行交互注意力机制的建模，效果一般，经分析是因为 BIDAF 依旧在建模 token 间的关系，和 BERT 内部的 Enocoder 功能重复。（3）第二个尝试是想要建模句向量之间的关系，因此依据分隔符对句子进行了切割，并通过平均池化获得句向量表示，然后将句向量送入到 transformer 中提取句子之间的关系，效果一般。（4）第三个尝试是通过阅读论文，提出使用 URC 作为我们的 post-traing 方法，URC 和句向量建模相结合取得了不错的效果。（5）绘制了 URC 和 MLM 两种

[1] https://github.com/cooelf/DeepUtteranceAggregation
[2] https://github.com/MarkWuNLP/MultiTurnResponseSelection

post-traing 方法的示意图。（6）撰写了英文报告中的 Utterance-oriented Strategy 模型算法部分内容。

- 蔡晨语（25%）：（1）阅读了多篇有关于多轮对话选择任务的论文，跑通了 SA-BERT 和 BERT-ResSel 两份代码。（2）基于 Ubuntu 数据集对 BERT 模型进行 post training （3）尝试了将 BERT 的 token 输出随机划分为一组之后平均池化成句向量再送入 transformer 进行句子之间的建模，发现效果并不太好；(4) 又将句向量送入全连接层，对效果的提升也不显著。(5) 随机切分效果不好之后进行了平均切分，将 BERT 输出的 512 个 token 分成 16 组进行平均池化之后送入 transformer 和全连接层，效果一般，经过和大家讨论后发现还是要依据分隔符划分 (6) 尝试了 mean-teacher 知识蒸馏对模型进行改进，发现代码很难修改，需要涉及到两个模型的设计（7）完成了报告中 Abstract、Related Work 和 Conclusion 的攥写以及报告的整合和翻译。

1.2 工作规划

第一周：每一位成员广泛调研了所选题目领域，总结了人机对话系统的对话管理研究的背景介绍和相关工作，在小组会议上进行了分享和讨论。我们根据小组成员的调研结果，讨论出以流行的相关研究 SA-BERT [1] 和 BERT-ResSel [2] 作为我们的基准模型展开深入研究。

第二周：每位小组成员都尝试跑通基准模型，并在基准模型上进行探索，看看两份代码能不能做一些优化。代码：

（1）https://github.com/JasonForJoy/SA-BERT

（2）https://github.com/taesunwhang/BERT-ResSel

第三周：分享自己的 baselines 实验结果，每位成员明确自己的优化方向，进行可行性探索或者优化：

（1）鸿展：主题

（2）许愿：Bert 逐层细粒度划分

（3）珊珊：新数据集/情感/因果/预训练分角色

（4）晨语：知识蒸馏

第四周：完成中期检查，珊珊负责分工情况和 introduction，晨语负责 related works，许愿负责算法，鸿展负责实验。

第五周：对接目前实验结果，讨论下一步的分工。确定使用许愿找到的 URC 作为 post training 策略，珊珊提出的 matching network 作为 finetune 网络。后续分工为：

（1）珊珊负责初期模型调优，将代码交付鸿展完成所有实验；两人负责 PPT 展示，并完成报告 introduction 和 experiments 的撰写；

（2）许愿负责报告中的算法部分，晨语负责完善整合以及翻译报告的其他内容。

后期：每个人根据分工推进工作，灵活开展讨论。

2 钟珊珊

2.1 任务介绍

DSTC8 第二赛道 NOESIS II 的主任务是选择多轮对话的下一轮回答。输入是一个对话上下文和 100 条候选回答，输出是 100 条回答的打分排序，评估指标是平均倒数排名（MRR）和 Top10 召回率。该任务提供了两个专业领域的数据集：

- Ubuntu。此数据集是网友在讨论 Ubuntu 操作系统的技术问题，例如 ubuntu 的硬件支持、nvidia 安装、证书等问题。
- Advising。此数据集是密歇根大学的课程顾问在和学生讨论下一学期的课程选择，根据学生的兴趣、时间、已上过的课程，推荐本学期合适的课程。

该任务主要有两个难点，其一是每个对话的候选答案多至 100 个，匹配难度很高，针对这点需要在深度匹配模型上做改进；其二是数据集都是垂直领域的问答，模型必须对领域专业知识有一定理解，才能正确回答，针对这点需要补充领域知识。具体内容见 “The Eighth Dialog System Technology Challenge”。

附：The News of DSTC8（包括了各个 Team 的 result）。

2.2 相关研究

Workshop 公开了三份工作。NOESIS II: Predicting Responses, Identifying Success, and Managing Complexity in Task-Oriented Dialogue [3] 是一份总结，提供了 task1 和 task4 的 baselines，总结了参赛队伍的方法和结果。Transformer-based Semantic Matching Model for Neotic Response Selection [4] 是得分第一的解决方案，似乎没有公开代码。Enhancing Response Selection with Advanced Context Modeling and Post-trainin [5] 似乎还是没有代码，但是有介绍自己的工具包。

附：DSTC8 总结报告 [6]。

2.3 代码

- 数据集：https://github.com/dstc8-track2/NOESIS-II
- text_matching：Python 3.6+ and Tensorflow-GPU 1.6. Pytorch 1.0。代码组织得挺好的。
- DSTC_8_solution：Python 3.6 Tensorflow 1.4.0。2020 年。从论文指标上看，这份代码的效果比今年的前三都要差。

2.4 Baselines 和实验结果

Bert-ResSel：在利用维基百科数据集预训练好的 Bert 上进行微调，微调具体内容为在目标数据集上进行 MLM（Masked）和 NSP（是否为下一句）任务。最后为了微调好的模型用在目标任务中，具体结构见 1。实验记录看起来比较正常。训完第一个 epoch

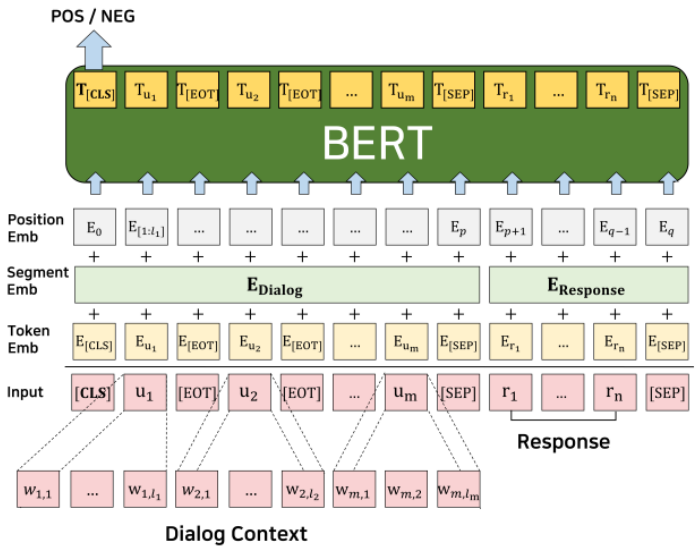

Figure 1: *BERT for Response Selection*

图 1: BERT-ResSel

的验证集结果为 Recall@1：85.03% | Recall@2：92.58% | Recall@5：98.42% | Recall@10：100.00% | MRR: 0.9070，与论文展示的比较符合。

SA-Bert：为预训练好的 Bert 增加了 speaker embeddings，并且为上下文增加了数据分割的提示符；根据提问人和回答人身份提出了语句选择策略；在利用维基百科数据集预训练好的 Bert 上进行微调，微调具体内容为在目标数据集上进行 MLM（Masked）和 NSP（是否为下一句）任务。实验跑得很慢，目前看第一个 epoch 不收敛。

3 蔡晨语

3.1 Introduction

(主要针对 subtask 1) 子任务 1 是多回合反应选择的基础和常规任务，旨在从 100 个候选回答中选择一个合适的回答。很可能这些候选项中没有一个是正确的，也就是说，99 或 100 将是不正确的。

子任务 1 探讨了基于检索的构建对话系统的方法，该方法学习会话上下文和响应候选对的匹配模型。这种方法具有提供信息丰富和流畅的响应的优点，因为它通过响应选择算法从存储库中为当前对话选择适当的响应。早期对基于检索的聊天机器人的研究主要集中在单回合响应选择。但是我们这个任务是针对于多回合的响应，这就要求我们更多融合语义信息

（针对于对话系统）对话系统分类：按应用领域分类分为任务导向对话系统、闲聊对话系统；按回复生成方式分类可分为：检索式对话系统、生成式对话系统、检索式 + 生成式对话系统

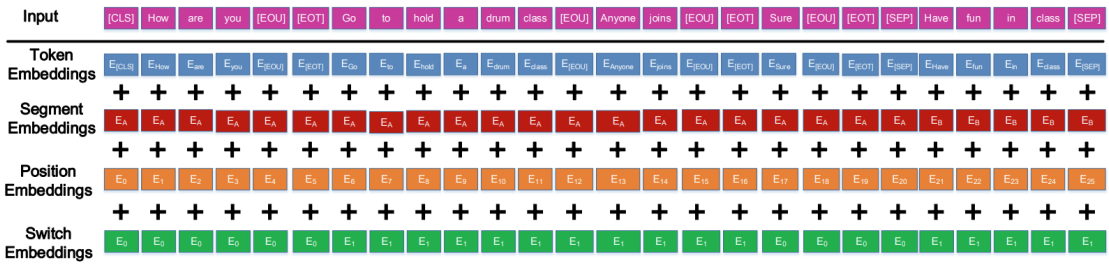

Figure 2: Input representation. The input embeddings is the sum of the token embeddings, the segmentation embeddings, the position embeddings and the switch embeddings.

图 2: 词向量编码

$$MRR = \frac{1}{Q}\sum_{i=1}^{|Q|}\frac{1}{rank_i}$$

图 3: MRR 的定义

3.2 论文

1. 珊珊的代码 DSTC_8_solution 对应的论文，所采取的方法是使用预训练的 Bert 和 Transformer，以及给每个词向量加入这种编码信息如图 2 所示 [7]

2. 上面那篇论文有一个更详细版 [8]

3.3 评价指标

1. （因为不知道是什么也先写在这怕自己忘了）MRR：结果列表中，第一个结果匹配，分数为 1，第二个匹配分数为 0.5，第 n 个匹配分数为 1/n，如果没有匹配的句子分数为 0。最终的分数为所有得分之和，再求平均

其中，|Q| 是用户的个数，rank_i 是对于第 i 个用户，推荐列表中第一个在 ground-truth 结果中的 item 所在的排列位置。

3.4 代码

3.4.1 BERT-ResSel

跟 vision transformer 的思想有点相似，也是再加入各种 embedding 之后，用 BERT 输出的第一个 token 作为基准来计算损失函数。在该代码的基础上尝试采用随机 token 划分，但是没有 work。

Dataset		Train	Valid	Test
Subtask 1	Ubuntu	225,367	4827	5529
	Advising	100,000	500	500
Subtask 2	Ubuntu	112262	9565	9027
Subtask 3	Advising	500	500	500
Subtask 4	Ubuntu	153	10	10

图 4: 数据集分布

4 宋鸿展

4.1 Overview

有关 DSTC8 举办方的 overview[6]:

- 任务：从一百个选择中给出下一语句，判断 100 个选择中是否存在正确答案 (即给出 100 个选择的可能性分布)

  subtask1vssubtask2: 多方对话是否需要解缠

- 评价指标：

  Recall@k(Recall@K 召回率是指前 topK 结果中检索出的相关结果数和库中所有的相关结果数的比率，衡量的是检索系统的查全率。) MRR(mean reciprocal rank)

  最终指标为 MRR 和 recall@10 的平均值

- 数据集介绍见图4

  Ubuntu IRC 对话（多方对话）

  Advising 学生和老师之间关于选课对话（两方对话）开发和测试集基于 100 个原始对话，每个对话被转述 5 次，然后在不同的地方切断。训练集是基于 500 个对话，也改写了五次，但随后重新混合了许多次。

- 赛方收到提交的一些模型：

  – BERT model

  – RoBERTa model(a Robustly Optimized BERT Pre-training approach)

  最佳的方法在各个数据集上都有所不同，其中 Ubuntu 上的最佳方法在 Advising 方面排名第二，而最佳的 Advising 方法在 Ubuntu 上排名第五。

- 赛道 top3 性能见图5

  关于 subtask1 的赛道 top3 性能如图

4.2 关于 nlp 对话

1.token(符号): 包括单词和标点 tokenization(分词)：我是中国人->[' 我', ' 是', ' 中国人']

TABLE IV
RESULTS OF THE TOP 3 PERFORMERS IN TRACK 2 - MAIN TASK (SUBTASK 1)

Ubuntu					Advising				
Team	R@1	R@5	R@10	MRR	Team	R@1	R@5	R@10	MRR
Baseline	0.212	0.421	0.565	0.325	Baseline	0.222	0.493	0.622	0.355
15	**0.761**	**0.958**	**0.979**	**0.848**	17	**0.564**	**0.806**	**0.878**	**0.677**
12	0.719	0.948	0.976	0.819	15	0.306	0.632	0.762	0.455
5	0.663	0.943	0.974	0.786	13	0.254	0.560	0.690	0.401

图 5: 前三性能

4.3 论文阅读

4.3.1 Speaker-Aware BERT for Multi-Turn Response Selection in Retrieval-Based Chatbots[9]

- 时间为 2020.10
- 代码开源：SA-BERT 代码

  环境依赖：Python 3.6 Tensorflow 1.13.1
- 研究了基于检索的聊天机器人中使用预训练语言模型进行多回合响应选择的问题，提出了 Speaker-Aware BERT 模型（SA-BERT），设计了一种基于说话人感知的解纠缠策略来解决纠缠对话。
  - speaker-embedding: 为了使预先训练好的语言模型能够感知会话过程中说话人的变化信息，通过在标记表示中添加说话人嵌入以及在上下文话语之间添加特殊的分割标记来增强该模型。(标记 speaker 提高对话理解)
  - speaker-aware 一种启发式的话者感知分离策略，它可以根据说话者的信息选择少量最重要的话语。(标记 spoken-from 和 spoken-to)
  - 设计了领域适应（domain adaption）旨在将特定的领域内知识纳入到预先训练的语言模型中。
- 最终对于 R100@1 on DSTC 8-Track 2-Subtask 2 Corpus 有百分之 15.5 的提高
- 结果：

  关于 DSTC8-subtask2 的结果见图6

  关于 Ubuntu 数据集的结果见图7
- 关于 Speaker Embedding 的消融实验：结果如图8

4.3.2 BERT-based response selection in dialogue systems using utterance attention mechanisms[10]

- 时间：recieved 2020.5 accepted 2022.7

Table 4: Evaluation results of SA-BERT and ablation tests of the speaker-aware disentanglement strategy (SDS) on the DSTC 8-Track 2-Subtask 2 Corpus.

Set	Model	MRR	R_{100}@1
Valid	IMN [3]	0.443	0.322
	IMN [3] + SDS	0.504	0.375
	BERT	0.335	0.258
	BERT + SDS	0.560	0.440
	SA-BERT - SDS	0.344	0.265
	SA-BERT	**0.594**	**0.477**
	SA-BERT (Ensemble)	0.611	0.496
Test	SA-BERT (Ensemble)	0.621	0.506

图 6: DSTC8-subtask2

Table 2: Evaluation results of SA-BERT and previous methods on the Ubuntu Dialogue Corpus V1 and V2.

	Ubuntu Corpus V1				Ubuntu Corpus V2			
	R_2@1	R_{10}@1	R_{10}@2	R_{10}@5	R_2@1	R_{10}@1	R_{10}@2	R_{10}@5
SMN [10]	0.926	0.726	0.847	0.961	-	-	-	-
DUA [12]	-	0.752	0.868	0.962	-	-	-	-
DAM [13]	0.938	0.767	0.874	0.969	-	-	-	-
MRFN [8]	0.945	0.786	0.886	0.976	-	-	-	-
IMN [3]	0.946	0.794	0.889	0.974	0.945	0.771	0.886	0.979
IoI [9]	0.947	0.796	0.894	0.974	-	-	-	-
MSN [11]	-	0.800	0.899	0.978	-	-	-	-
BERT	0.950	0.808	0.897	0.975	0.950	0.781	0.890	0.980
SA-BERT	**0.965**	**0.855**	**0.928**	**0.983**	**0.963**	**0.830**	**0.919**	**0.985**

图 7: Ubuntu

Table 6: Results on the test set of Ubuntu Corpus V2, by ablating the speaker embeddings (SE).

Pre-Train	SE	R_2@1	R_{10}@1	R_{10}@2	R_{10}@5
No	No	0.950	0.781	0.890	0.980
No	Yes	0.950	0.786	0.890	0.981
Yes	No	0.961	0.825	0.915	0.984
Yes	**Yes**	**0.963**	**0.830**	**0.919**	**0.985**

图 8: SE 消融实验结果

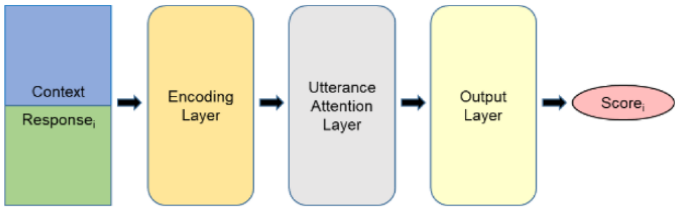

Fig. 2. Model system structure.

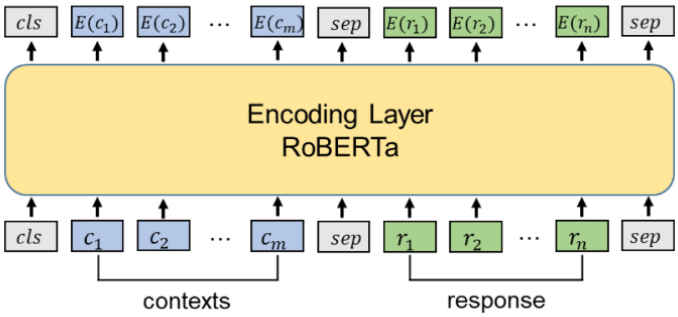

Fig. 3. Encoding layer.

图 9: model structure

Table 4
Overall performances of models. We used, hit@1, hit@k, MRR as evaluation metrics for each dataset.

Model	DSTC8 Ubuntu			DSTC8 Advising		
	Hit @1	Hit @5	MRR	Hit @1	Hit @5	MRR
ESIM	57.58	83.2	70.23	19.72	45.2	34.1
ESIM w/ RoBERTa	64.62	85.99	74.22	23.89	51.47	37.19
BERT	65.6	87.89	75.6	24.87	47.53	36.48
RoBERTa	67.49	87.38	76.34	25.86	**52.44**	38.36
Our method w/ mean pooling	69.11	88.77	77.81	**26.6**	51.72	**38.54**
Out method w/ LSTM	**69.6**	**88.82**	**78.01**	26.35	51.47	38.39

图 10: model result

- 没有代码但是感觉 related work 还行，介绍了 BERT 和 RoBERTa
- word representation 是通过自我注意机制来反映整个对话或个别话语中意向词语之间的语境信息，而 utterance representation 是通过交叉注意机制来反映话语之间的语境信息。(主要是利用注意机制)
- 结构见图9
- 结果见图10

4.3.3 Deep Contextualized Utterance Representations for Response Selection and Dialogue Analysis[8]

- 时间：2020.10
- 和 [9] 同一个作者，内容也差不多，代码地址相同
- 结果如图11

THE OFFICIAL RESULTS OF OUR PROPOSED METHODS ON THE UNSEEN TEST SETS FOR THE TRACK 2 OF DSTC 8. NA - NOT APPLICABLE.

Subtask	Measure	Ubuntu	Advising
Subtask 1	R_{100}@1	0.649	0.224
	R_{100}@5	0.904	0.526
	R_{100}@10	0.949	0.676
	MRR	0.760	0.374

ABLATION RESULTS FOR A SINGLE MODEL ON THE VALIDATION SET OF UBUNTU DATASET IN SUBTASK 1.

	R_{100}@1	R_{100}@5	R_{100}@10	MRR
Ours	0.638	0.895	0.938	0.749
-Adaptation	0.622	0.881	0.909	0.733
-Speaker emb.	0.616	0.877	0.902	0.728

图 11: result

TABLE III
TRANSFER TO DSTC8 TASK

(a) Ubuntu Dataset

	dev				test			
	R@1	R@10	MRR	avg	R@1	R@10	MRR	avg
BERT no-aug	71.21	94.97	79.73	87.35	72.07	95.15	80.34	87.75
Ours	74.43	95.77	82.03	88.90	73.96	95.88	81.96	88.92

(b) Advising Dataset

	dev				test			
	R@1	R@10	MRR	avg	R@1	R@10	MRR	avg
BERT no-aug	27.34	68.72	40.14	54.43	24.02	65.69	36.82	51.25
Ours	28.33	69.70	41.20	55.45	25.25	65.20	38.00	51.60

图 12: Result

4.3.4 Pre-Trained and Attention-Based Neural Networks for Building Noetic Task-Oriented Dialogue Systems[7]

- 时间：2020.4
- 和 [9] 同一个作者，内容也差不多, 代码地址相同 (我都快要怀疑他学术不端了)

4.3.5 Label and Context Augmentation for Response Selection at DSTC8[11]

- 时间：recieved 2020.10 accepted 2021.4
- 无代码, subtask1 的第二名和第三名
- 提出了一种基于检索的扩展方法，可以从扩展的、更丰富的角色描述集合中构建角色语句；介绍了 BERT Bi-Encoder 和 Cross-Encoder；label augmentation,context augmentation; 用交叉编码器取代双编码器来表示上下文-响应依赖关系，这可能有助于进一步提高表示质量。当迭代次数调到 3 时，我们的 DSTC8 解决方案性能最佳。
- 结果如图12

4.4 代码运行

4.4.1 SA-bert

代码运行无任何问题，以 batchsize=5 进行了测试

- logtrain:

  INFO:tensorflow:epoch: 0 train: Mins Used: 1575.80, Loss: 0.3275, Accuarcy: 68.00

  INFO:tensorflow:Valid begin

  numtestsamples: 500000 testaccuracy: 0.79853320516482 Accuracy: 0.92747, Precision: 0.5934595337570256 Recall: 0.87216 F1: 0.7063110923942995 Loss: 0.2884069932573244

  MAP (mean average precision: 0.9068830317460327 MRR (mean reciprocal rank): 0.9068830317460327 Top-1 precision: 0.85036 Numquery: 50000

- logtest:

  numtestsamples: 500000 testaccuracy: 0.797997205196619 Accuracy: 0.92721, Precision: 0.5922235327612153 Recall: 0.87366 F1: 0.7059251298869629 Loss: 0.2891346478086227

  MAP (mean average precision: 0.9068732114363937 MRR (mean reciprocal rank): 0.9068782116364017 Top-1 precision: 0.8501340053602144 Numquery: 49998

- computemetrics:

  Accuracy: 0.92721, Precision: 0.5922235327612153 Recall: 0.87366 F1: 0.7059251298869629 Loss: 0.2891346478086228

  MAP (mean average precision: 0.9068732114363937 MRR (mean reciprocal rank): 0.9068782116364017 Numquery: 49998

  Recall10@1: 0.8501340053602144 Recall10@2: 0.9258170326813072 Recall10@5: 0.98367934717388

  Accuracy: 0.9034080681613632, Precision: 0.9289314194577353 Recall: 0.87366 F1: 0.9004483380567022 Loss: 0.414971827139088

  MAP (mean average precision: 0.9817759377041749 MRR (mean reciprocal rank): 0.9817792711708468 Numquery: 49998

  Recall2@1: 0.9635585423416937

4.4.2 ResSel

代码 train 可以，但是 evaluate 有问题

- train: 在模型训练完之后的 evaluation 中存在 Ran out of input

  File spawn, line 115, in main self = reduction.pickle.load(from-parent)

  EOFError: Ran out of input

  windows 独有错误：numworkers=0

- bert-dpt evaluate: AttributeError: 'HParams' object has no attribute 'bert-pretrained-dir'

4.4.3 中文数据集

4.5 代码改进

4.5.1 Topic

有看到几份代码，有 pytorch 也有 tensorflow

- tbert(tensorflow):https://github.com/wuningxi/tBERT 我感觉这个文章的思路是很好的，但是数据集不太匹配，而且代码参数好多（因为它好像适配了好多数据集等等）我尝试改了一下，没改动
- Topicbert(tensorflow、pytorch):https://github.com/YatinChaudhary/TopicBERT/tree/master/To 文：https://arxiv.org/pdf/2010.16407.pdf这个是做文件分类的，然后他直接有一个 jointmodel 的函数（bert+nvdm), 本来以为很好改，但是感觉输入有些不匹配，模型图也没太看懂，所以也没改动
- 或者直接暴力加 LDA 等主题模型：主要是没有找到对应数据集的比较好的代码，自己写比较难的样子

4.5.2 TOD-bert

找到一个任务导向型的 tod-bert,2020EMNLP, 里面有 DSTC2 的数据集，所以拿来试试了 https://github.com/jasonwu0731/ToD-BERT 它的 introduction：一般文本和任务型对话之间语言模式的潜在差异使得现有的预训练语言模型在实际应用中不再那么有用。在这项工作中，我们统一了九个人-人和多回合面向任务的对话数据集，用于语言建模。为了更好地模拟预训练期间的对话行为，我们将用户和系统令牌合并到掩蔽语言模型中。我们提出了一个对比的目标函数来模拟响应选择任务。我们预先训练的任务导向对话 BERT (TOD-BERT) 在四个下游任务导向对话应用中表现优于像 BERT 这样的强基线，包括意图识别、对话状态跟踪、对话行为预测和响应选择。实验结果还表明，TOD-BERT 具有较强的短镜头能力，可以缓解面向任务对话的数据稀缺问题。

现在以及替换了模型进行训练

4.6 实验记录分析

5 许愿

5.1 Introduction

给定一个话语序列 C = u1, u2,⋯,un 作为对话历史，基于检索的对话模型从一组候选 rii=1->m 中选择适当的响应 r，这些候选 r 通常从现有人类对话的索引中检索. 这项研究的核心问题在于建立一个上下文响应匹配模型 s(C,r) 来衡量候选 r 在 C 之后成为正确响应的可能性有多大, 即有一个相似度打分。

- 框架 I：基于表示的模型，表示函数——> 聚类函数（抽取上下文信息）——> 匹配函数/相似度函数

Representation-based Models			
Model	Representation Function $\phi(\cdot)$	Aggregation Function $\rho(\cdot)$	Matching Function $g(\cdot)$
ARC-I [Hu *et al.*, 2014]	CNN	-	MLP
DeepMATCH [Wang *et al.*, 2015]	Dependency tree	-	Nonlinear function
Dual-LSTM [Lowe *et al.*, 2015]	LSTM	-	Bilinear function
DocChat [Yan *et al.*, 2018]	CNN+Attention Pooling	-	Euclidean distance
TACNTN [Wu *et al.*, 2018a]	CNN	-	Neural tensor function
DL2R [Yan *et al.*, 2016]	BiLSTM+CNN	Identity	MLP
Multi-View [Zhou *et al.*, 2016]	Word2vec/CNN	GRU	Bilinear function
TADAM [Xu *et al.*, 2020]	Transformer	GRU	MLP

图 13: 基于表示的代表模型图

Interaction-based Models			
Model	Encoding Function $\psi(\cdot)$	Interaction Function $f(\cdot,\cdot) \Rightarrow \eta(\cdot)$	Aggregation Function $\rho(\cdot)$
DeepMatch$_{topic}$ [Lu and Li, 2013]	Topic feature	Similarity-based ⇒MLP	-
ARC-II [Hu *et al.*, 2014]	CNN	Similarity-based ⇒ CNN	-
KEHNN [Wu *et al.*, 2018c]	Word2vec & BiGRU	Similarity-based ⇒ CNN	-
CSRAN [Tay *et al.*, 2018]	BiLSTM	Attention-based⇒BiLSTM+Pooling	-
ESIM [Chen and Wang, 2019]	BiLSTM	Attention-based ⇒ BiLSTM+Pooling	-
Poly-encoders [Humeau *et al.*, 2020]	BERT	Attention-based ⇒ Pooling	-
SMN [Wu *et al.*, 2017]	Word2vec/GRU	Similarity-based ⇒ CNN	GRU
DAM [Zhou *et al.*, 2018b]	Transformer/Cross-attention	Similarity-based ⇒ CNN	CNN
DUA [Zhang *et al.*, 2018b]	GRU+attention	Similarity-based ⇒ CNN	GRU
MRFN [Tao *et al.*, 2019a]	Word2vec/CNN/RNN/Transformer	Attention-based ⇒ GRU	GRU
IoI [Tao *et al.*, 2019b]	Transformer	Attention-based ⇒ LSTM	LSTM
MSN [Yuan *et al.*, 2019]	BiLSTM	Attention-based ⇒ BiLSTM	BiLSTM

图 14: 基于表示的代表模型图

- 代表模型如图13
- 框架 II：基于交互的模型
- 代表模型如图14
- 框架 III：基于 PLM 的模型

5.2 相关模型链接

1. Training neural response selection for task-oriented dialogue systems-ACL2019(KERAS 版本代码)

2. An effective domain adaptive post-training method for bert in response selection-2020（pyorch 版本代码）

taesunwhang/BERT-ResSel: PyTorch Implementation for INTERSPEECH'20 "An Effective Domain Adaptive Post-Training Method for BERT in Response Selection" (github.com)

3. Filtering before Iteratively Referring for Knowledge-Grounded Response Selection in Retrieval-Based Chatbots—EMNLP2020(引入外部知识库)

JasonForJoy/FIRE: EMNLP 2020: Filtering before Iteratively Referring for Knowledge-Grounded Response Selection in Retrieval-Based Chatbots (github.com)(tensorflow,py2.7)

4. Learning an effective contextresponse matching model with self-supervised tasks for retrieval-based dialogues–AAAI2021(无代码)

5. TOD-BERT: Pre-trained natural language understanding for task-oriented dialogue-EMNLP2020(适用很多下游任务，包括回复检索)

jasonwu0731/ToD-BERT: Pre-Trained Models for ToD-BERT (github.com)

6. Transformer architectures and pre-training strategies for fast and accurate multi-sentence scoring（权衡效率与表现）—-ICLR2020

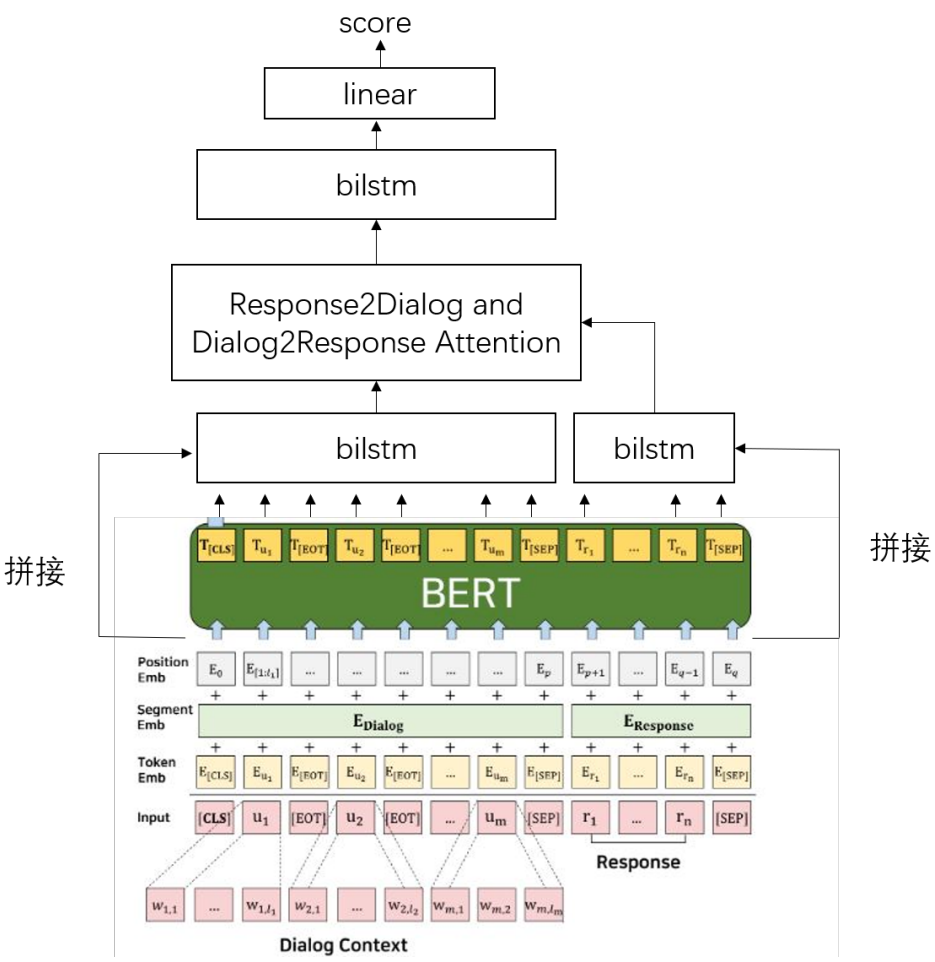

图 15: 改进后模型图

sfzhou5678/PolyEncoder: An unofficial implementation of Poly-encoder (Poly-encoders: Transformer Architectures and Pre-training Strategies for Fast and Accurate Multi-sentence Scoring) (github.com)

7.Pytorch 版本 baseline

2021ACL:

yxuansu/HCL: [ACL'21] Dialogue Response Selection with Hierarchical Curriculum Learning (github.com)

2021AAAI(框架 1)

xyease/TADAM (github.com)

5.3 模型改进尝试

以 Bert-ReSel 作为 baseline, 参考机器问答中的经典模型 bidaf, 将 biadaf 模块加入到 Bert 模型之后，双向建模 context 和 response 之间的关系。改进后的模型图如图??

在 Ubuntu 数据集上的实验结果如图16

Model	R10@1	R10@2	R10@5	MRR
Bert_DPT(baseline)	0.851	0.924	0.984	0.907
Our_model	0.849	**0.927**	**0.985**	0.907

图 16: 在 Ubuntu 数据集上的实验结果

参考文献

[1] Jia-Chen Gu, Tianda Li, Quan Liu, Zhen-Hua Ling, Zhiming Su, Si Wei, and Xiaodan Zhu. Speaker-aware bert for multi-turn response selection in retrieval-based chatbots. In *Proceedings of the 29th ACM International Conference on Information & Knowledge Management*, pages 2041–2044, 2020.

[2] Taesun Whang, Dongyub Lee, Chanhee Lee, Kisu Yang, Dongsuk Oh, and Heuiseok Lim. An effective domain adaptive post-training method for bert in response selection. *arXiv preprint arXiv:1908.04812*, 2019.

[3] Chulaka Gunasekara, Jonathan K Kummerfeld, Luis Lastras, and Walter S Lasecki. Noesis ii: Predicting responses, identifying success, and managing complexity in task-oriented dialogue. In *AAAI: Workshop on the 8th Edition of the Dialog System Technology Challenges*, 2020.

[4] Yiying Yang, Kaijie Zhou, Xuan Li, Dawei Zhu, Xiaoyuan Yao, and Jianping Shen. Transformer-based semantic matching model for noetic response selection. In *8th Dialogue Syst. Technol. Challenge*, 2020.

[5] Shuangzhi Wu, Yufan Jiang, Xu Wang, Wei Miao, Zhenyu Zhao, Xie Jun, and Mu Li. Enhancing response selection with advanced context modeling and post-training. In *Proceedings of workshop of the 34th AAAI Conference on Artificial Intelligence (AAAI-20)*, 2020.

[6] Seokhwan Kim, Michel Galley, Chulaka Gunasekara, Sungjin Lee, Adam Atkinson, Baolin Peng, Hannes Schulz, Jianfeng Gao, Jinchao Li, Mahmoud Adada, et al. Overview of the eighth dialog system technology challenge: Dstc8. *IEEE/ACM Transactions on Audio, Speech, and Language Processing*, 29:2529–2540, 2021.

[7] Jia-Chen Gu, Tianda Li, Quan Liu, Xiaodan Zhu, Zhen-Hua Ling, and Yu-Ping Ruan. Pre-trained and attention-based neural networks for building noetic task-oriented dialogue systems, 2020.

[8] Jia-Chen Gu, Tianda Li, Zhen-Hua Ling, Quan Liu, Zhiming Su, Yu-Ping Ruan, and Xiaodan Zhu. Deep contextualized utterance representations for response selection and dialogue analysis. *IEEE/ACM Transactions on Audio, Speech, and Language Processing*, 29:2443–2455, 2021.

[9] Jia-Chen Gu, Tianda Li, Quan Liu, Zhen-Hua Ling, Zhiming Su, Si Wei, and Xiaodan Zhu. Speaker-aware bert for multi-turn response selection in retrieval-based chatbots, 2020.

[10] Yeongjoon Park, Youngjoong Ko, and Jungyun Seo. Bert-based response selection in dialogue systems using utterance attention mechanisms. *Expert Systems with Applications*, 209:118277, 2022.

[11] Myeongho Jeong, Seungtaek Choi, Jinyoung Yeo, and Seung-won Hwang. Label and context augmentation for response selection at DSTC8. *IEEE ACM Trans. Audio Speech Lang. Process.*, 29:2541–2550, 2021.