自然语言对话系统[1]

摘要

自然语言对话系统是一项经典的自然语言处理 (NLP) 任务，在工业界中具备广阔的应用前景。自然语言对话系统涉及到许多 NLP 领域的典型任务，自 NLP 正式提出起，大量研究者在这项任务上开展研究。特别是近几年来，大多数研究基于深度学习对自然语言对话系统进行建模，表现出出色的性能。在本介绍性综述报告中，笔者以深度学习自然语言对话系统为调研对象，按时间顺序梳理该领域的发展过程，寻找其发展规律。首先，笔者聚焦于 NLP 顶会，全面回顾了 2000 年以来深度学习自然语言对话系统的发展历程，定位深度学习在自然语言对话系统的兴起节点。基于兴起节点，笔者介绍深度学习自然语言对话系统的热点研究成果，讨论了广泛应用于对话系统的不同模型的原理、特点和应用。此外，笔者总结了深度学习自然语言对话系统中智能客服人机切换（MHCH）广泛使用的基准数据集和评测指标，并对 MHCH 领域相关模型的性能进行讨论，见微知著，展示深度学习自然语言对话系统的现状。最后，根据近期研究成果，笔者确定了一些可能的研究趋势。

1 引言

自然语言对话系统，又称为聊天机器人，是 NLP 的热门话题之一，被广泛应用在人们生活中。聊天机器人的市场规模预计将从 2021 年的 26 亿美元增长到 2024 年的 94 亿美元，复合年增长率 (CAGR) 为 29.7% [2]，预计到 2021 年底将有 80% 的企业配备自动化聊天机器人 [3]。

如图 1所示，自然语言对话系统常常应用在两类型场景中：

- 面向任务的对话系统（TOD）。面向任务的对话系统解决特定领域中的特定问题，例如天气查询、电影票预订、餐厅订桌等。
- 开放域对话系统（OOD）。开放域对话系统不是专注于任务完成，而是旨在与不受任务和领域限制的用户聊天，通常完全由数据驱动。

面向任务和开放域的对话系统都可以看作是用户信息 U 到机器人回复 R 的映射，即 $R = \phi(U)$，其中 $\phi(\cdot)$ 为映射函数。$\phi(\cdot)$ 可以粗略划分为两类：管道式方法（Pipeline）和端到端方法（End-to-end）。

管道式方法将对话理解逐步拆解成自然语言理解（NLU）、对话管理模块（DM，包括对话状态跟踪（DST）和策略学习（PL））、自然语言生成（NLG）三步链式结构，根据不同模块的特性设计不同的模型来解决对应问题。其中，NLU [1, 2, 3] 对文本信息进行识别解析，转换成计算机可理解的结构化语义表示；DST [4, 5] 根据对话历史和 NLU 模块输出的语义表示，维护并更新当前的对话状态；PL [6, 7] 根据当前的对话状态执行下一步系统动作；NLG [8, 9] 将对话策略输出的语义表

[1] 不包括摘要和参考文献，正文字数为 6110

[2] 数据来源：https://markets.businessinsider.com

[3] 数据来源：https://outgrow.co

示转换成自然语言文本。端到端 [10, 11, 12] 的方法一步到位，直接根据用户信息给出合理的回复。其中，基于检索的系统试图从某个回应集中找到已存在的回应；生成式系统应用序列到序列模型将用户消息和对话历史映射到一个可能不会出现在训练语料库中的回应序列；集成系统通过两种方式将生成法和基于检索的方法相结合，将检索到的回应与生成的回应进行比较，从中选择最优的回应，同时使用生成模型来细化检索到的回应。虽然管道式方法与端到端方法对自然语言对话系统建模的理解不同，但是二者很多方法是互通的，例如检索式方法也可以应用到 NLG 当中。

面对任务型对话系统和开放域对话系统，无论是管道式方法还是端到端方法，都存在对话上下文（Context Awareness）[13, 14, 15, 16]、连贯（Response Coherence）[17, 18, 19]、多样性（Response Diversity）[20, 21, 22]、个性化（Speaker Consistency and Personality-based Response）[23, 24, 25]、同理心（Empathetic Response）[26, 27, 28, 29] 等挑战。此外，由于标注训练样本的有限性，如何在有限数据条件下提高端到端任务导向对话系统的响应质量是一个热点研究课题。近年来，随着持续学习和大模型的兴起，知识基础（Knowledge-Grounded System）[30, 31, 7, 32] 和交互式训练（Interactive Training）[33, 34] 也成为深度学习对话系统领域关注的热点问题。

在本介绍性综述报告中，笔者以深度学习自然语言对话系统为调研对象，按时间顺序梳理该领域的发展过程，寻找其发展规律。首先，笔者聚焦于 NLP 顶会，全面回顾了 2000 年以来深度学习自然语言对话系统的发展历程，定位深度学习在自然语言对话系统的兴起节点。基于兴起节点，笔者介绍深度学习自然语言对话系统的热点研究成果，讨论了广泛应用于对话系统的不同模型的原理、特点和应用。此外，笔者总结了深度学习自然语言对话系统中 MHCH 广泛使用的基准数据集和评测指标，并对 MHCH 领域相关模型的性能进行讨论，见微知著，展示深度学习自然语言对话系统的现状。最后，根据近期研究成果，笔者确定了一些可能的研究趋势。

2 相关工作

2.1 文献调研

1950 年，图灵发表论文“计算机器与智能”，NLP 大体可认为由此开始。随之从 1980 年代末期开始，语言处理引进了机器学习的算法，NLP 产生革新。虽然 1986 年多层神经网络解决线性不可分问题，深度学习开启第二次浪潮，但是神经网络也受到了其他更加简单归类模型的挑战，支持向量机等模型在 20 世纪 90 年代到 21 世纪初成为流行的机器学习算法，深度学习在 21 世纪才正式成为 NLP

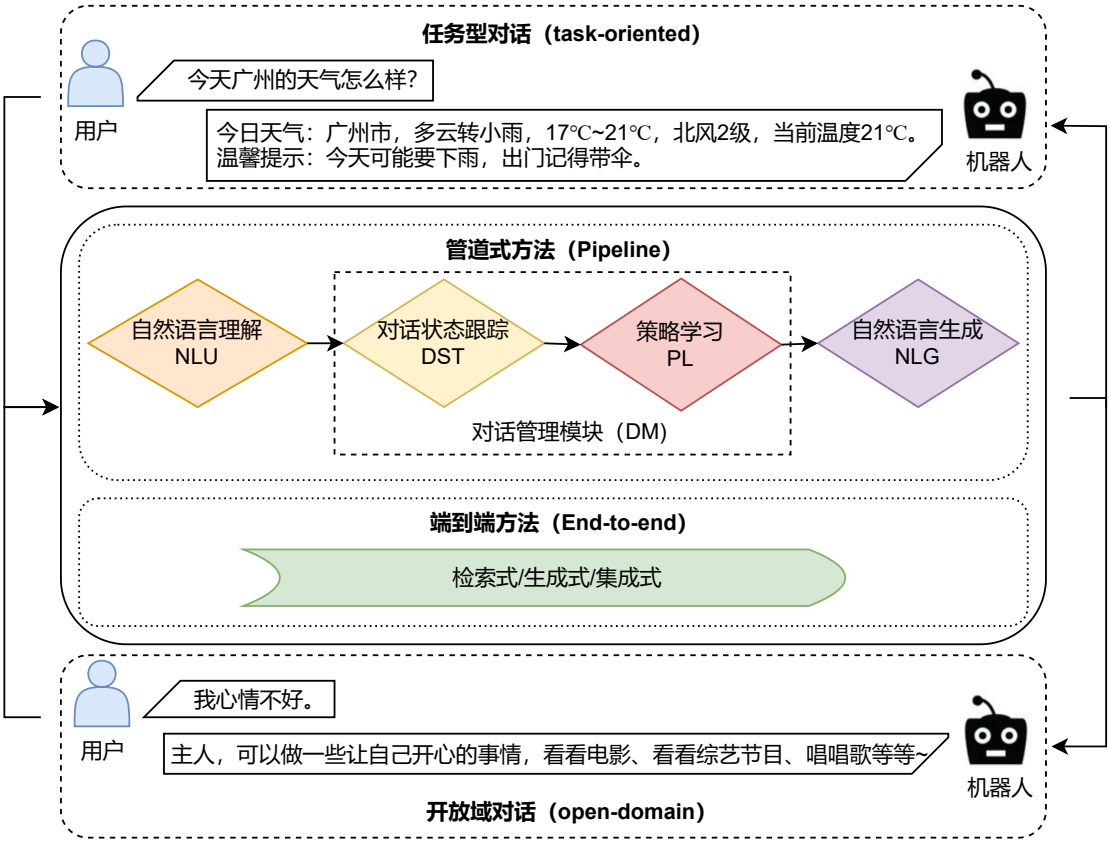

图 1: 自然语言对话系统的类型与基本流程

领域热门研究方向。作为 NLP 领域的主要范畴，自然语言对话系统的发展路线大体与 NLP 接近。

综合上述发展历程，笔者确定 2000 年为统计起始节点，统计 2000 年至今深度学习自然语言对话系统的相关研究，初步定位深度自然语言对话系统的重要发展节点。因为文献卷帙浩繁，质量好坏不一，笔者聚焦 NLP 领域的顶级会议 ACL [4]。ACL 是 NLP 领域影响力最大、最具活力的国际学术组织之一，自成立之日起就致力于推动计算语言学及 NLP 相关研究的发展和国际学术交流，是一个用于分析深度自然语言对话系统发展的绝佳选择。具体而言，笔者通过谷歌学术粗略检索 NLP 领域的顶级会议 ACL 自 2000 年起自然语言对话系统的相关论文，梳理自然语言对话系统的发展。笔者使用的检索词为 “dialog source:Association source:for source:Computational source:Linguistics”，实际检索出的论文来源于名称包含 ACL 的刊物。笔者的文献调研结果如下：

- 2000 至 2005 年笔者使用谷歌学术检索出 64 篇相关论文，相关论文均为非深度学习领域。例如 2005 年的研究 [35] 将生成澄清请求（Clarification requests）应用在任务型对话中。

[4] https://dblp.uni-trier.de/db/conf/acl/index.html

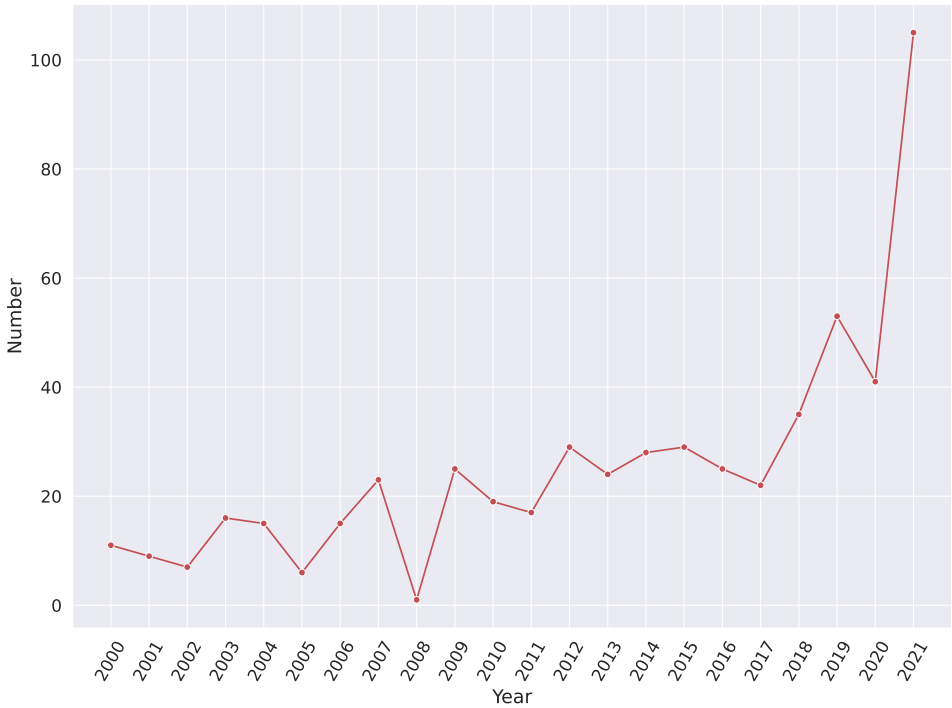

图 2: 以年为单位统计 ACL 中对话领域的论文数量

- 2006 至 2010 年谷歌学术检索结果共 83 条，相关论文均非深度学习领域。例如 2007 年的研究 [36] 使用词袋模型（Bag-of-words model）建模。
- 2011 至 2015 年共检索出 127 篇相关论文。隐马尔可夫成为该时期的热门方向。例如 2011 年的研究 [37] 使用马尔可夫算法和强化学习来解决任务型对话；2014 年的研究 [38] 使用马尔可夫算法来解决任务型对话。此外，逻辑回归 [39] 等传统方法也被应用在建模上。
- 2016 至 2020 年共检索出 180 篇相关论文。我们可以发现该时期相关文献数目明显变多。在该阶段，深度学习成为热门工具应用在自然语言对话系统中，并获得了出色的性能。例如 2019 年提出的 EmoDS [27] 使用 BiLSTM 对情感建模；2019 年提出的 OpenDialKG [32] 关注知识图谱和注意力机制对对话系统可解释性的作用。在该阶段，各类深度学习模型被应用在自然语言对话系统中。在该阶段后期，基于注意力机制的预训练模型 [40, 41] 兴起，迅速地广泛使用在各类对话系统任务中 [42]。
- 2021 年至今 ACL 中与自然语言对话系统相关的文献共 187 篇，对话系统领域论文暴增。近期，研究者关注自然语言对话系统的跨领域 [43, 44, 45]、多任务 [46, 47, 48] 问题中，大型预训练模型 [40, 41] 被广泛应用在对话特征提

取上 [49, 50]，自然语言对话系统在预训练模型大一统的情况下呈现着百花齐放的态势。

以年为单位统计 ACL 中对话领域的论文数量，结果如图 2所示。结合这一更细化的数据，我们可以初步得出如下结论：（1）2012 年左右这个时间节点，机器学习促进了对话系统的发展，随后在 2016 年左右，深度学习兴起，逐渐成为对话系统的有效工具；（2）2018 年左右，预训练模型的提出大大激发了 NLP 领域的研究，对话系统领域的研究数量激增。

2.2 方法聚焦

基于文献调研，我们可以发现，计算资源的飞速发展，数据量的剧增，使得大数据、大模型成为对话系统的热门选择，预训练、多任务、多模态等综合数据优势的方法成为热点研究方向。在本节中，笔者简单介绍预训练、多任务、多模态三类方法的热门或前沿研究成果，总结不同方法的原理、特点和应用。

2.2.1 预训练

预训练的目的是使用尽可能多的训练数据，从中提取出尽可能多的共性特征，从而让模型对特定任务的学习负担变轻。预训练的做法一般是将大量低成本收集的训练数据放在一起，经过某种预训方法去学习其中的共性，然后将其中的共性“移植”到特定任务的模型中，再使用相关特定领域的少量标注数据进行“微调”，这样的话，模型只需要从“共性”出发，去“学习”该特定任务的“特殊”部分即可。目前对话系统领域最常用的预训练模型为 Bert [41]。虽然 Bert [41] 是 2018 年提出的工作，但是目前为止，自然语言预训练领域 Bert 仍然是主流选择。

在结构上，BERT 具有以下两个特点：(1) Bert 非常的深，层数达 12 层，且不宽，中间层只有 1024 (Transformer 中间层有 2048)；(2) MLM (Masked Language Model)，即同时利用左侧和右侧的词语进行训练。Bert 预训练和微调流程如图 3所示。使用 Bert 进行预训练，除了输出层之外，预训练和微调都使用相同的架构。相同的预训练模型参数用于初始化不同下游任务的模型。在微调过程中，所有参数都会被微调。[CLS] 是在每个输入示例前面添加的特殊符号，[SEP] 是特殊的分隔符标记（例如分隔问题/答案）。

2.2.2 多任务学习

传统方法旨在使用一种特定模型仅解决一项任务，而多任务的思想是将多个彼此相关但不完全相同任务进行联合训练，从而将所有任务包含的知识用于改善

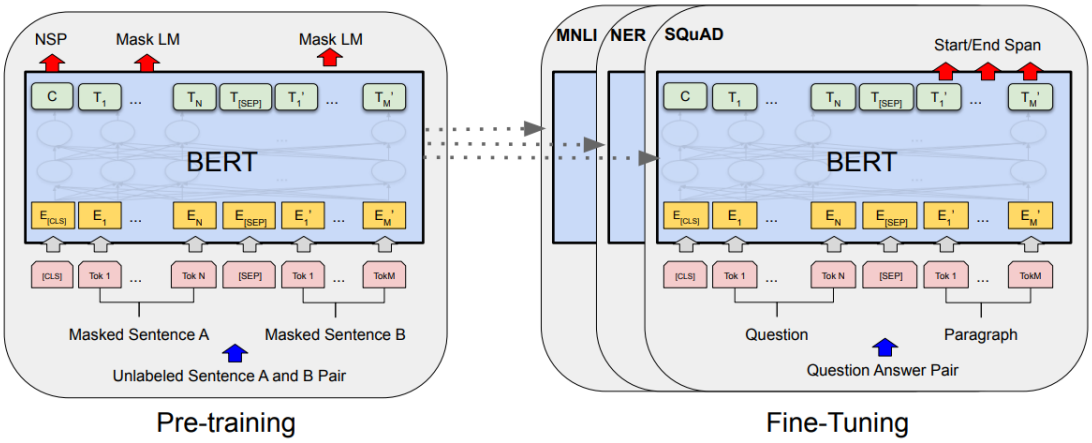

图 3: Bert 预训练和微调流程图解 [51]。

模型在目标任务的性能上。在这部分，笔者选取了针对对话系统领域一个非常新颖的问题的 RSSN [47]，简要介绍多任务学习在深度学习对话系统中的应用。

智能客服属于任务型对话。随着人工智能的发展，基于深度学习的聊天机器人成为客服行业一个高性价比的解决方案，在智能客服领域体现出巨大的研究和应用价值。然而，聊天机器人回复不准确的问题屡见不鲜，这极大地损害了用户体验。大部分研究者尝试从数据和模型角度出发来提升机器人回复准确度，但是仍然无法确保百分百准确。因此，部分研究 [52, 53, 47, 45] 从 MHCH 角度着手，在智能客服服务中接入人机切换模型，将机器人客服无法处理的对话及时转接到人工客服处，人工客服对用户问题进行应答，并对用户进行安抚，必能使服务整体满意度得到提升，从而减少因为客服服务导致的交易失败。

RSSN [47] 是 MHCH 领域前沿的研究成果，发表在 EMNLP 2021 。如图 4所示，RSSN 将对话满意度预测和人机切换预测整合在一个多任务学习框架，利用局部的用户满意度作为桥梁，全局满意度预测和人机切换预测可以有效地交换关键信息。在这一多任务学习模型中，对话满意度预测和人机切换预测通过共享编码器和权重参数共享实现多任务共同学习。近期，EMNLP 2022 审稿结果公布。笔者的工作 CEM [45]J 将因果的思想融入到 MHCH 任务中，实现了对用户满意度和人工成本细粒度的把控。

2.2.3 多模态

在机器学习领域，每一种信息的来源或者形式，都可以称为一种模态。 [54] 例如，人有触觉，听觉，视觉，嗅觉；信息的媒介，有语音、视频、文字等；多种多样的传感器，如雷达、红外、加速度计等。以上的每一种都可以称为一种模态。同时，模态也可以有非常广泛的定义，比如二维与三维图片可以当作是两种模态，

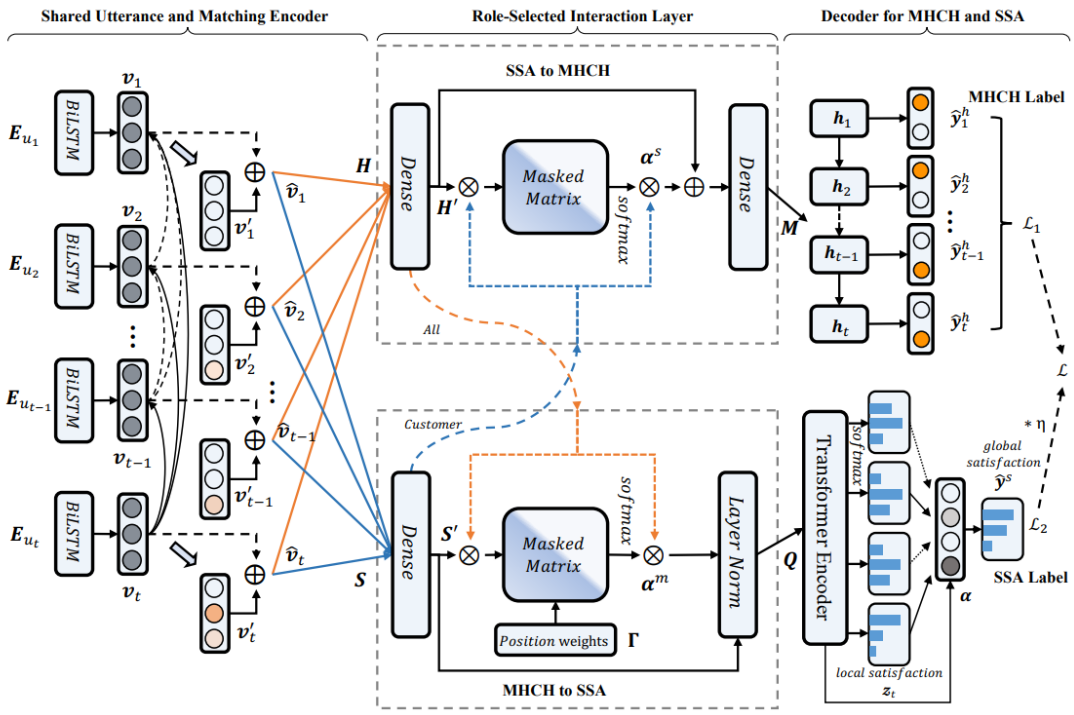

图 4: RSSN 结构图解 [51]

在两种不同情况下采集到的分布不同的数据集，也可以认为是两种模态。

近几年来，多模态成为深度学习的热门研究领域，语言与图片两种模态的结合是当前研究中最常见的多模态场景。在深度学习自然语言对话系统中，基于多模态建模的研究屡见不鲜，数量逐年攀升。笔者以 UniTranSeR [51] 为例简单介绍多模态在深度学习对话系统的应用。

如图 5所示，针对现有的单模态对话系统难以很好的应对图像、文本和知识混合的多模态任务型对话需要，马志远等人提出了一种新的基于特征对齐和意图推理的多模态对话模型 UniTranSeR。该模型通过一个视觉-文本 Transformer 来映射不同模态的语义信息进入到一个统一的向量空间中去，从而解决了多模态信息的异构性嵌入难题。在使用 Transformer 进行统一模态嵌入的基础上，该模型进一步设计了一个特征对齐层去学习对话中跨模态的细粒度语义对齐，然后通过一个基于注意力的意图推理层去有效的捕获用户的真实对话意图，从而生成准确的多模态对话回复。实验结果验证了 UniTranSeR 模型的有效性，并且在多模态任务型对话领域极具代表性的 MMD 数据集上达到了 SOTA 性能。

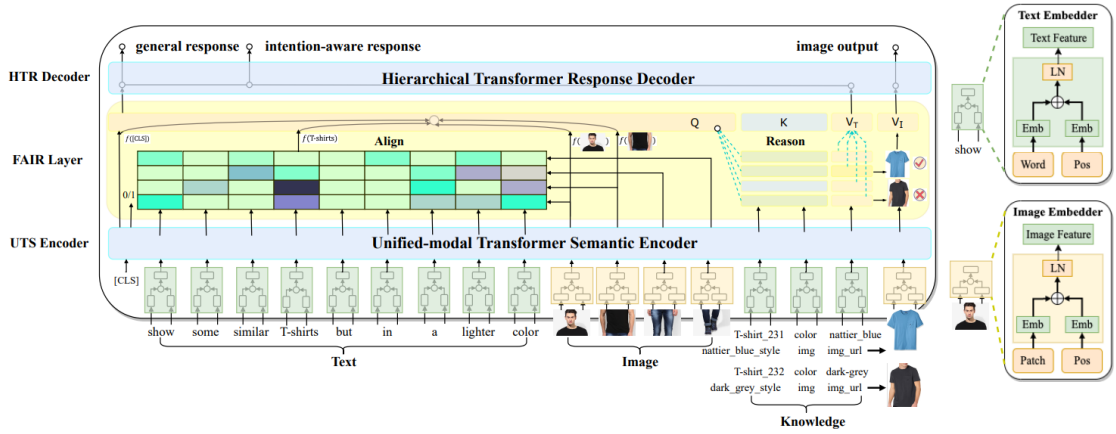

图 5: UniTranSeR 结构图解 [51]

3 实验

自然语言对话系统涉及的任务非常多，基准数据集丰富，不同任务的评测指标各有不同。为了让实验部分更有针对性，笔者选取了笔者最熟悉的 MHCH 领域进行介绍。

3.1 数据集

MHCH 常用的四个数据集为 Clothing[53]、Makeup1[53]、Clothes[47] 和 Makeup2[47]。数据统计见表1。Clothing 与 Makeup1 中的对话不包含用户对智能客服的评分。数据集的对话的每一句话都有是否切换人工的标签，该标签由 5 名专家进行标注，对话中的每一句被标注为是否切换人工时都没有考虑上下文是否会转换人工，且当前数据集仅仅包含了用户与智能客服的对话，人工客服不参与到对话，因此单个对话中可能有多个切换人工的标签。用户对智能客服提出明确的切换人工要求、用户收到不满意的答案或表达负面情绪、用户或智能客服重复语义上相似的话语时，都可能被标注为切换人工。需要注意的是，数据集不包含任何用户个人信息。

3.2 指标

根据现有研究 [53, 47, 45]，评估指标 F1、Macro F1（Mac. F1）和 GT-T（Golden Transfer within Tolerance）[53] 常被用于 MHCH 任务的评估当中。F1 聚焦于模型在切换成人工这部分数据上的拟合优度，而 Macro F1 综合考虑了切换成人工和保持智能客服整个数据集上模型的综合表现。GT-T 通过误差范围 T 来评

表 1: 数据集的总体统计

统计项	Clothing	Makeup1	Clothes	Makeup2
# (对话)	3500	4000	10000	3540
# (用户不满的对话)	-	-	2302	1180
# (用户中立的对话)	-	-	6399	1180
# (用户满意的对话)	-	-	1299	1180
# (切换人工的语句)	6713	7446	16921	7668
# (不切换人工的语句)	28901	32488	237891	86778
Avg # (每个对话中的语句)	10.18	9.98	25.48	26.68

表 2: Clothing 和 Makeup1 上模型分类性能比较 (%)。粗体表示最佳结果，下划线表示次佳结果。

模型	Clothing					Makeup1				
	F1	Mac.F1	GT-I	GT-II	GT-III	F1	Mac.F1	GT-I	GT-II	GT-III
HRN [55]	57.3	73.5	62.3	71.8	76.5	58.2	74.1	62.3	72.5	78.1
HAN [56]	58.2	74.1	62.9	72.2	76.7	60.1	75.3	65.4	74.9	79.9
BERT [41]	56.0	72.9	59.3	68.1	73.1	57.0	73.3	61.5	71.0	76.5
CRF-ASN [57]	57.6	73.4	61.5	72.6	78.0	56.8	73.6	63.7	74.2	79.8
HBLSTM-CRF [58]	59.0	74.4	63.6	73.7	78.8	60.1	75.4	67.0	76.3	81.2
DialogueRNN [59]	59.0	74.3	63.1	73.8	79.0	61.3	76.1	66.3	76.0	81.2
CASA [60]	59.7	74.7	64.8	74.9	79.7	60.4	75.7	67.8	77.0	81.8
LSTMLCA [61]	61.8	76.1	66.4	76.3	81.1	62.1	76.6	67.8	76.9	81.7
CESTa [62]	60.5	75.2	64.0	74.6	79.6	60.2	75.2	65.2	75.9	81.5
DAMI [53]	67.3	**79.7**	**70.3**	**79.1**	**83.9**	67.1	79.5	67.8	76.9	82.1
CEM-DAMI (C) [45]	**67.5**	**79.7**	69.7	77.6	81.5	**67.5**	**79.9**	**70.4**	**78.1**	**82.2**

估人机切换任务，允许模型在 T 范围内预测不准确，以实现允许存在偏差的预测。GT-T 的调整系数 会惩罚提前或延迟切换，大于 0 表示惩罚延迟切换，λ 小于 0 表示惩罚提前切换。在实验中 λ 常常设置为 0，T 的值常常设置为 1 到 3（GT-I、GT-II、GT-III）。2022 年最新的研究 CEM [45] 提出了衡量无效成本的指标 IC。

3.3 模型表现

如表 2和表 3所示，笔者从 CEM 的论文 [45] 中获取到 MHCH 领域相关模型表现。从实验结果中可以发现，当前最具竞争力的模型是多任务模型 RSSN，CEM 成为一个优化 MHCH 模型的有利工具。

表 3: Clothes 和 Makeup2 上模型分类性能比较 (%)。粗体表示最佳结果，下划线表示次佳结果。

模型	Clothes					Makeup2				
	F1	**Mac.F1**	**GT-I**	**GT-II**	**GT-III**	**F1**	**Mac.F1**	**GT-I**	**GT-II**	**GT-III**
HAN [56]	59.8	78.7	71.7	73.1	74.0	54.3	75.4	68.5	70.1	71.3
BERT+LSTM [41]	60.4	78.9	73.4	74.9	75.9	42.2	84.2	72.9	66.4	77.6
HEC [58]	59.8	78.7	71.2	72.3	73.0	57.1	76.8	68.0	69.5	70.5
DialogueRNN [59]	60.8	79.2	73.1	74.6	75.6	58.3	77.4	68.8	70.5	71.6
CASA [60]	62.0	79.8	73.6	75.0	75.9	58.4	77.5	70.6	72.7	73.9
LSTMLCA [61]	62.6	80.1	72.4	73.9	74.8	57.4	77	70.2	71.7	72.6
CESTa [62]	60.6	79.1	73.4	74.8	75.6	59.3	78.0	69.6	71.2	72.2
DAMI [53]	66.7	82.2	74.2	75.9	77.1	61.1	79.0	73.3	74.4	75.2
MT-ES [63]	61.7	79.7	74.6	75.9	76.8	57.1	76.9	69.9	71.7	72.8
JointBiLSTM [64]	62.0	79.9	75.0	76.1	76.9	59.3	78.0	70.1	72.0	73.1
DCR-Net [65]	62.1	79.9	71.4	72.8	73.7	58.8	77.7	70.0	72.1	73.4
RSSN [47]	67.1	82.5	75.8	77.1	78	63.5	80.2	74.9	76.5	77.7
CEM-RSSN (U) [45]	66.6	82.4	**79.8**	80.5	81.0	**67.6**	**82.8**	**80.2**	**81.1**	81.8
CEM-RSSN (C) [45]	66.1	82.1	78.6	79.6	80.2	65.2	81.6	77.3	78.2	78.9
CEM-RSSN (full) [45]	**67.9**	**82.9**	79.6	**80.7**	**81.4**	64.8	80.9	79.4	**81.1**	**82.3**

4 总结与研究趋势

苹果的 Siri、微软的 Cortana、Facebook 的 M、谷歌 Assistant、亚马逊的 Alexa 等行业对话系统给人们的生活带来了巨大的便利。工业和日常生活中对聊天机器人的需求不断增加，促使越来越多的研究人员研究对话系统任务，大量优秀的对话系统研究涌现，对话系统领域日新月异。

本介绍性综述报告从时间角度探究对话系统中关键技术的发展历程。近十年来的研究显示，无论是任务型对话系统还是开放域对话系统中，都对深度学习方法有压倒性的偏爱。近三年的研究显示，大数据、大模型是对话系统的显著特征，且研究者对对话系统的研究不断细化，对话系统领域不断出现跨领域的新颖模型和新颖问题。在此背景下，如何实现多模态数据融合、如何实现多任务混合训练、如何实现模型持续学习和迁移学习等问题是现有的挑战，也是未来的研究趋势。

5 致谢

笔者对南洋理工大学 Jinjie Ni 等人的优秀工作 [66] 致以崇高的敬意与谢意。正是在他们详实的综述性工作的指引下，笔者才得以较为顺利得完成这份作业。

参考文献

[1] Chien-Sheng Wu, Steven Hoi, Richard Socher, and Caiming Xiong. Tod-bert: Pre-trained natural language understanding for task-oriented dialogues. *arXiv preprint arXiv:2004.06871*, 2020.

[2] Rashmi Gangadharaiah and Balakrishnan Narayanaswamy. Recursive template-based frame generation for task oriented dialog. In *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics*, pages 2059–2064, 2020.

[3] Sam Coope, Tyler Farghly, Daniela Gerz, Ivan Vulić, and Matthew Henderson. Span-convert: Few-shot span extraction for dialog with pretrained conversational representations. *arXiv preprint arXiv:2005.08866*, 2020.

[4] Yexiang Wang, Yi Guo, and Siqi Zhu. Slot attention with value normalization for multi-domain dialogue state tracking. In *Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing (EMNLP)*, pages 3019–3028, 2020.

[5] Jiaying Hu, Yan Yang, Chencai Chen, Zhou Yu, et al. Sas: Dialogue state tracking via slot attention and slot information sharing. In *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics*, pages 6366–6375, 2020.

[6] Ryuichi Takanobu, Runze Liang, and Minlie Huang. Multi-agent task-oriented dialog policy learning with role-aware reward decomposition. *arXiv preprint arXiv:2004.03809*, 2020.

[7] Jun Xu, Haifeng Wang, Zheng-Yu Niu, Hua Wu, Wanxiang Che, and Ting Liu. Conversational graph grounded policy learning for open-domain conversation generation. In *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics*, pages 1835–1845, 2020.

[8] Ondřej Dušek and Filip Jurčíček. Sequence-to-sequence generation for spoken dialogue via deep syntax trees and strings. *arXiv preprint arXiv:1606.05491*, 2016.

[9] Sergey Golovanov, Rauf Kurbanov, Sergey Nikolenko, Kyryl Truskovskyi, Alexander Tselousov, and Thomas Wolf. Large-scale transfer learning for natural language generation. In *Proceedings of the 57th Annual Meeting of the Association for Computational Linguistics*, pages 6053–6058, 2019.

[10] Weikang Wang, Jiajun Zhang, Qian Li, Mei-Yuh Hwang, Chengqing Zong, and Zhifei Li. Incremental learning from scratch for task-oriented dialogue systems. *arXiv preprint arXiv:1906.04991*, 2019.

[11] Wanwei He, Min Yang, Rui Yan, Chengming Li, Ying Shen, and Ruifeng Xu. Amalgamating knowledge from two teachers for task-oriented dialogue system with adversarial training. In *Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing (EMNLP)*, pages 3498–3507, 2020.

[12] Shiquan Yang, Rui Zhang, and Sarah Erfani. Graphdialog: Integrating graph knowledge into end-to-end task-oriented dialogue systems. *arXiv preprint arXiv:2010.01447*, 2020.

[13] Alessandro Sordoni, Michel Galley, Michael Auli, Chris Brockett, Yangfeng Ji, Margaret Mitchell, Jian-Yun Nie, Jianfeng Gao, and Bill Dolan. A neural network approach to context-sensitive generation of conversational responses. *arXiv preprint arXiv:1506.06714*, 2015.

[14] Jiwei Li, Michel Galley, Chris Brockett, Jianfeng Gao, and Bill Dolan. A diversity-promoting objective function for neural conversation models. *arXiv preprint arXiv:1510.03055*, 2015.

[15] Iulian Serban, Alessandro Sordoni, Yoshua Bengio, Aaron Courville, and Joelle Pineau. Building end-to-end dialogue systems using generative hierarchical neural network models. In *Proceedings of the AAAI Conference on Artificial Intelligence*, volume 30, no 1, 2016.

[16] Chen Xing, Yu Wu, Wei Wu, Yalou Huang, and Ming Zhou. Hierarchical recurrent attention network for response generation. In *Proceedings of the AAAI Conference on Artificial Intelligence*, volume 32, no 1, 2018.

[17] Jiawei Wu, Xin Wang, and William Yang Wang. Self-supervised dialogue learning. *arXiv preprint arXiv:1907.00448*, 2019.

[18] Siqi Bao, Huang He, Fan Wang, Rongzhong Lian, and Hua Wu. Know more about each other: Evolving dialogue strategy via compound assessment. *arXiv preprint arXiv:1906.00549*, 2019.

[19] Changzhen Ji, Xin Zhou, Yating Zhang, Xiaozhong Liu, Changlong Sun, Conghui Zhu, and Tiejun Zhao. Cross copy network for dialogue generation. *arXiv preprint arXiv:2010.11539*, 2020.

[20] Lisong Qiu, Juntao Li, Wei Bi, Dongyan Zhao, and Rui Yan. Are training samples correlated? learning to generate dialogue responses with multiple references. In *Proceedings of the 57th Annual Meeting of the Association for Computational Linguistics*, pages 3826–3835, 2019.

[21] Wei-Jen Ko, Avik Ray, Yilin Shen, and Hongxia Jin. Generating dialogue responses from a semantic latent space. *arXiv preprint arXiv:2010.01658*, 2020.

[22] Hui Su, Xiaoyu Shen, Sanqiang Zhao, Xiao Zhou, Pengwei Hu, Randy Zhong, Cheng Niu, and Jie Zhou. Diversifying dialogue generation with non-conversational text. *arXiv preprint arXiv:2005.04346*, 2020.

[23] Qian Liu, Yihong Chen, Bei Chen, Jian-Guang Lou, Zixuan Chen, Bin Zhou, and Dongmei Zhang. You impress me: Dialogue generation via mutual persona perception. *arXiv preprint arXiv:2004.05388*, 2020.

[24] Hyunwoo Kim, Byeongchang Kim, and Gunhee Kim. Will i sound like me? improving persona consistency in dialogues through pragmatic self-consciousness. In *Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing (EMNLP)*, pages 904–916, 2020.

[25] Alex Boyd, Raul Puri, Mohammad Shoeybi, Mostofa Patwary, and Bryan Catanzaro. Large scale multi-actor generative dialog modeling. *arXiv preprint arXiv:2005.06114*, 2020.

[26] Yukun Ma, Khanh Linh Nguyen, Frank Z Xing, and Erik Cambria. A survey on empathetic dialogue systems. *Information Fusion*, 64:50–70, 2020.

[27] Zhenqiao Song, Xiaoqing Zheng, Lu Liu, Mu Xu, and Xuan-Jing Huang. Generating responses with a specific emotion in dialog. In *Proceedings of the 57th Annual Meeting of the Association for Computational Linguistics*, pages 3685–3695, 2019.

[28] Peixiang Zhong, Chen Zhang, Hao Wang, Yong Liu, and Chunyan Miao. Towards persona-based empathetic conversational models. In *Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing (EMNLP)*, pages 6556–6566, 01 2020.

[29] Hannah Rashkin, Eric Michael Smith, Margaret Li, and Y-Lan Boureau. Towards empathetic open-domain conversation models: A new benchmark and dataset. *arXiv preprint arXiv:1811.00207*, 2018.

[30] Zhiliang Tian, Wei Bi, Xiaopeng Li, and Nevin L Zhang. Learning to abstract for memory-augmented conversational response generation. In *Proceedings of the 57th Annual Meeting of the Association for Computational Linguistics*, pages 3816–3825, 2019.

[31] Xueliang Zhao, Wei Wu, Can Xu, Chongyang Tao, Dongyan Zhao, and Rui Yan. Knowledge-grounded dialogue generation with pre-trained language models. *arXiv preprint arXiv:2010.08824*, 2020.

[32] Seungwhan Moon, Pararth Shah, Anuj Kumar, and Rajen Subba. Opendialkg: Explainable conversational reasoning with attention-based walks over knowledge graphs. In *Proceedings of the 57th Annual Meeting of the Association for Computational Linguistics*, pages 845–854, 2019.

[33] Diane Bouchacourt and Marco Baroni. Miss tools and mr fruit: Emergent communication in agents learning about object affordances. *arXiv preprint arXiv:1905.11871*, 2019.

[34] Braden Hancock, Antoine Bordes, Pierre-Emmanuel Mazare, and Jason Weston. Learning from dialogue after deployment: Feed yourself, chatbot! *arXiv preprint arXiv:1901.05415*, 2019.

[35] Verena Rieser and Johanna D Moore. Implications for generating clarification requests in task-oriented dialogues. In *Proceedings of the 43rd Annual Meeting of the Association for Computational Linguistics (ACL' 05)*, pages 239–246, 2005.

[36] Jing Jiang and ChengXiang Zhai. A systematic exploration of the feature space for relation extraction. In *Human Language Technologies 2007: The Conference of the North American Chapter of the Association for Computational Linguistics; Proceedings of the Main Conference*, pages 113–120, 2007.

[37] Nina Dethlefs and Heriberto Cuayáhuitl. Hierarchical reinforcement learning and hidden markov models for task-oriented natural language generation. In *Proceedings of the 49th Annual Meeting of the Association for Computational Linguistics: Human Language Technologies*, pages 654–659, 2011.

[38] Ke Zhai and Jason D Williams. Discovering latent structure in task-oriented dialogues. In *Proceedings of the 52nd Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*, pages 36–46, 2014.

[39] Kristy Boyer, Joseph F Grafsgaard, Eun Young Ha, Robert Phillips, and James Lester. An affect-enriched dialogue act classification model for task-oriented dialogue. In *Proceedings of the 49th annual meeting of the association for computational linguistics: Human language technologies*, pages 1190–1199, 2011.

[40] Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N Gomez, Łukasz Kaiser, and Illia Polosukhin. Attention is all you need. *Advances in neural information processing systems*, 30, 2017.

[41] Jacob Devlin, Ming-Wei Chang, Kenton Lee, and Kristina Toutanova. Bert: Pre-training of deep bidirectional transformers for language understanding. *arXiv preprint arXiv:1810.04805*, 2018.

[42] Ananya B Sai, Akash Kumar Mohankumar, Siddhartha Arora, and Mitesh M Khapra. Improving dialog evaluation with a multi-reference adversarial dataset and large scale pretraining. *Transactions of the Association for Computational Linguistics*, 8:810–827, 2020.

[43] Jun Zhang, Yan Yang, Chencai Chen, Liang He, and Zhou Yu. Kers: A knowledge-enhanced framework for recommendation dialog systems with multiple subgoals. In *Findings of the Association for Computational Linguistics: EMNLP 2021*, pages 1092–1101, 2021.

[44] Dirk Hovy and Diyi Yang. The importance of modeling social factors of language: Theory and practice. In *The 2021 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies*. Association for Computational Linguistics, 2021.

[45] Shanshan Zhong, Jinghui Qin, Zhongzhan Huang, and Daifeng Li. Causal inference for chatting handoff. *arXiv preprint arXiv:2210.02862*, 2022.

[46] Yohan Lee. Improving end-to-end task-oriented dialog system with a simple auxiliary task. In *Findings of the Association for Computational Linguistics: EMNLP 2021*, pages 1296–1303, 2021.

[47] Jiawei Liu, Kaisong Song, Yangyang Kang, Guoxiu He, Zhuoren Jiang, Changlong Sun, Wei Lu, and Xiaozhong Liu. A role-selected sharing network for joint machine-human chatting handoff and service satisfaction analysis. *arXiv preprint arXiv:2109.08412*, 2021.

[48] Deeksha Varshney, Asif Ekbal, and Pushpak Bhattacharyya. Modelling context emotions using multi-task learning for emotion controlled dialog generation. In *Proceedings of the 16th Conference of the European Chapter of the Association for Computational Linguistics: Main Volume*, pages 2919–2931, 2021.

[49] Takato Yamazaki and Akiko Aizawa. Phrase-level action reinforcement learning for neural dialog response generation. In *Findings of the Association for Computational Linguistics: ACL-IJCNLP 2021*, pages 5028–5038, 2021.

[50] Piotr Żelasko, Raghavendra Pappagari, and Najim Dehak. What helps transformers recognize conversational structure? importance of context, punctuation, and labels in dialog act recognition. *Transactions of the Association for Computational Linguistics*, 9:1179–1195, 2021.

[51] Zhiyuan Ma, Jianjun Li, Guohui Li, and Yongjing Cheng. Unitranser: A unified transformer semantic representation framework for multimodal task-oriented dialog system. In *Proceedings of the 60th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*, pages 103–114, 2022.

[52] Janarthanan Rajendran, Jatin Ganhotra, and Lazaros C Polymenakos. Learning end-to-end goal-oriented dialog with maximal user task success and minimal human agent use. *Transactions of the Association for Computational Linguistics*, 7:375–386, 2019.

[53] Jiawei Liu, Zhe Gao, Yangyang Kang, Zhuoren Jiang, Guoxiu He, Changlong Sun, Xiaozhong Liu, and Wei Lu. Time to transfer: Predicting and evaluating machine-human chatting handoff. In *Proc. of AAAI*, pages 5841–5849, 2021.

[54] Louis-Philippe Morency, Paul Pu Liang, and Amir Zadeh. Tutorial on multimodal machine learning. In *Proceedings of the 2022 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies: Tutorial Abstracts*, pages 33–38, 2022.

[55] Rui Lin, Shujie Liu, Muyun Yang, Mu Li, Ming Zhou, and Sheng Li. Hierarchical recurrent neural network for document modeling. In *Proceedings of the 2015 Conference on Empirical Methods in Natural Language Processing*, pages 899–907, 2015.

[56] Zichao Yang, Diyi Yang, Chris Dyer, Xiaodong He, Alex Smola, and Eduard Hovy. Hierarchical attention networks for document classification. In *Proceedings of the 2016 conference of the North American chapter of the association for computational linguistics: human language technologies*, pages 1480–1489, 2016.

[57] Zheqian Chen, Rongqin Yang, Zhou Zhao, Deng Cai, and Xiaofei He. Dialogue act recognition via crf-attentive structured network. In *The 41st international acm sigir conference on research & development in information retrieval*, pages 225–234, 2018.

[58] Harshit Kumar, Arvind Agarwal, Riddhiman Dasgupta, and Sachindra Joshi. Dialogue act sequence labeling using hierarchical encoder with crf. In *Proceedings of the aaai conference on artificial intelligence*, volume 32, 2018.

[59] Navonil Majumder, Soujanya Poria, Devamanyu Hazarika, Rada Mihalcea, Alexander Gelbukh, and Erik Cambria. Dialoguernn: An attentive rnn for emotion detection in conversations. In *Proceedings of the AAAI Conference on Artificial Intelligence*, volume 33, pages 6818–6825, 2019.

[60] Vipul Raheja and Joel Tetreault. Dialogue act classification with context-aware self-attention. *arXiv preprint arXiv:1904.02594*, 2019.

[61] Zhigang Dai, Jinhua Fu, Qile Zhu, Hengbin Cui, Yuan Qi, et al. Local contextual attention with hierarchical structure for dialogue act recognition. *arXiv preprint arXiv:2003.06044*, 2020.

[62] Yan Wang, Jiayu Zhang, Jun Ma, Shaojun Wang, and Jing Xiao. Contextualized emotion recognition in conversation as sequence tagging. In *Proceedings of the 21th Annual Meeting of the Special Interest Group on Discourse and Dialogue*, pages 186–195, 2020.

[63] Jing Ma, Wei Gao, and Kam-Fai Wong. Detect rumor and stance jointly by neural multi-task learning. In *Companion proceedings of the the web conference 2018*, pages 585–593, 2018.

[64] Praveen Kumar Bodigutla, Aditya Tiwari, Josep Valls Vargas, Lazaros Polymenakos, and Spyros Matsoukas. Joint turn and dialogue level user satisfaction estimation on multi-domain conversations. *arXiv preprint arXiv:2010.02495*, 2020.

[65] L. Qin, W. Che, Y. Li, M. Ni, and T. Liu. Dcr-net: A deep co-interactive relation network for joint dialog act recognition and sentiment classification. *Proceedings of the AAAI Conference on Artificial Intelligence*, 34(5):8665–8672, 2020.

[66] Jinjie Ni, Tom Young, Vlad Pandelea, Fuzhao Xue, and Erik Cambria. Recent advances in deep learning based dialogue systems: A systematic survey. *Artificial Intelligence Review*, pages 1–101, 2022.